

T.C GALATASARAY ÜNİVERSİTESİ
MÜHENDİSLİK VE TEKNOLOJİ FAKÜLTESİ

DUYUŞSAL OYUN TASARIMINDA UYARLAMALI DÜŞMAN
YAPAY ZEKASI İÇİN GERÇEK ZAMANLI DUYGU ANALİZİ

**(La Façade Fissurée : Analyse des Émotions en Temps Réel
pour l'IA Adaptative dans la Conception de Jeux Affectifs)**

2^e RAPPORT INTERMÉDIAIRE

Ali Burak SARAÇ

21401932

Bölüm : BİLGİSAYAR MÜHENDİSLİĞİ

Danışman : Dr. Öğr. Üyesi Reis Burak Arslan

AVRIL 2026

Table des Matières

Table des Matières	i
Liste des Figures	iii
Liste des Tableaux	iv
1 EXIGENCES, CONTRAINTES ET CONDITIONS RÉELLES	1
1.1 Contraintes Économiques	1
1.2 Contraintes Éthiques	2
1.3 Évolutivité et Modularité	3
1.4 Sécurité et Conditions d'Expérimentation	3
1.5 Contraintes Environnementales	4
2 DESIGN CONCEPTUEL	6
2.1 Modèle d'Interaction Affective	6
2.2 Concept du Jeu	7
2.2.1 Genre et Objectif	7
2.2.2 Perspective et Plateforme	7
2.3 Stratégie de Fusion Affective (Niveau Conceptuel)	8
3 CONCEPTION TECHNIQUE	9
3.1 Architecture du Pipeline (Vue Actualisée)	9
3.2 Diagramme de Flux de Données (FER)	10
3.3 Algorithmes rPPG : Spécification Formelle	10
3.4 Formule Composite de Peur (Candidate)	13
3.5 Rôle du rPPG dans la Fusion	14
3.6 Stratégie de Détection par Couches	15
3.7 Communication Unity-Pipeline	15
4 ANALYSE DE COÛTS	16
4.1 Latence par Composant (Hôte Windows)	16
4.2 Analyse des Ressources	17

4.3	Comparaison des Frameworks rPPG (Planifiée)	18
4.4	Budget de Latence Total	19
5	PREMIERS RÉSULTATS	21
5.1	Comparaison des Outils FER (Hôte)	21
5.2	Benchmark des Formules de Peur	22
5.3	Résultats rPPG : Vérification de Faisabilité	24
5.4	Méthodologie d'Annotation et Résultats Préliminaires	26
5.4.1	Dépendance circulaire	26
5.4.2	Résultats de la première annotation (Video05_S02)	26
5.5	Constats Clés et Implications de Conception	27
5.5.1	Évaluation des Formules de Peur	27
5.5.2	Constats sur le Mécanisme VETO	27
5.5.3	Faisabilité et Limites du rPPG	28
5.5.4	Méthodologie d'Annotation	29
5.5.5	Architecture de Détection Hybride	29
5.5.6	Infrastructure Construite en Phase 2	30
5.6	Plan d'Évaluation Phase 3	31
	Bibliographie	33

Liste des Figures

2.1	Modèle d'interaction affective — machine à deux états de l'IA ennemie .	7
3.1	Architecture actualisée du pipeline affectif (phase 2)	9
3.2	Flux de traitement par trame du module FER	10

Liste des Tableaux

1.1	Synthèse des contraintes et décisions de conception associées	5
3.1	Comparaison des algorithmes rPPG implémentés	11
3.2	Sept formules candidates de peur composite	13
4.1	Latence par outil (Windows 11, contrôlé, host CPU)	16
4.2	Décomposition du budget de latence	20
5.1	Résultats du benchmark des formules de peur (Video05_S02, discrimina- tion peur/colère)	23
5.2	Estimations rPPG multi-algorithmes (Video05_S02)	25

1 EXIGENCES, CONTRAINTES ET CONDITIONS RÉELLES

Ce chapitre recense les contraintes réelles qui encadrent le développement du projet, organisées selon cinq catégories : économiques, éthiques, évolutivité, sécurité et environnementales. Chaque contrainte a directement influencé une décision de conception documentée dans le pipeline.

Contexte : Ce rapport fait suite au premier rapport intermédiaire, qui a établi le projet *La Façade Fissurée* : un pipeline d'informatique affective en temps réel pour l'IA adaptative dans les jeux d'horreur. Le pipeline suit une architecture à quatre modules (Acquisition, Détection, Fusion, Adaptation) et utilise MediaPipe + HSEmotion pour la reconnaissance d'expressions faciales (FER) et les algorithmes CHROM/POS/GREEN pour la photopléthysmographie à distance (rPPG). Les outils alternatifs (DeepFace, Py-Feat) ont été évalués et rejetés en phase 1 en raison de contraintes de latence. L'objectif temps réel est de 200 ms par trame (5 FPS minimum) pour une rétroaction affective cohérente.

1.1 CONTRAINTES ÉCONOMIQUES

Le projet impose une contrainte économique explicite : le système doit fonctionner avec du matériel et des logiciels accessibles à tout utilisateur sans investissement spécialisé.

Matériel minimal : Une webcam grand public (720p, 30 FPS) constitue le seul capteur requis pour le pipeline de base. Aucun capteur biométrique dédié — électroencéphalographe, capteur cardiaque par contact, caméra infrarouge — n'est nécessaire. Des entrées optionnelles, telles qu'une montre connectée pour la validation du rythme cardiaque ou un microphone pour l'analyse vocale du stress, sont envisagées comme extensions futures mais ne font pas partie des exigences de base.

Logiciels libres et gratuits : Tous les composants logiciels du pipeline sont open-source et gratuits : Python 3.12, MediaPipe (licence Apache 2.0), HSEmotion (licence MIT), NumPy, SciPy et OpenCV. Unity Personal (licence gratuite) est retenu pour le développement du jeu. Aucune API commerciale ni SDK propriétaire n’est utilisé dans le pipeline de détection.

1.2 CONTRAINTES ÉTHIQUES

Le traitement des données biométriques impose des obligations éthiques strictes, reflétées dans l’architecture du pipeline.

Tout le traitement vidéo s’effectue localement sur la machine du joueur : aucune trame, aucun recadrage facial ni aucun vecteur d’embedding n’est transmis à un serveur externe. Les trames sont traitées en mémoire vive et immédiatement supprimées ; aucune vidéo faciale n’est persistée sur le disque. Les journaux CSV — contenant les scores d’émotion par trame (`hs_fear`, `hs_surprise`, `mp_tension`, `composite_fear`), les estimations BPM et les métriques de latence — sont anonymisés : les participants sont identifiés uniquement par un identifiant numérique (S01, S02, etc.). Les colonnes enregistrées contiennent exclusivement des valeurs numériques, sans aucune image ni donnée personnelle directement identifiable (Gutiérrez et al., 2025).

Le protocole expérimental adopte une conception *single-blind* : les participants sont informés que la caméra est active, mais pas quelle condition (pipeline actif ou IA à comportement fixe) est en cours dans une session donnée. Aucune déception complète n’est pratiquée. Le consentement éclairé est recueilli avant toute session, et les participants peuvent retirer leur consentement à tout moment, y compris en désactivant la caméra en cours de session.

1.3 ÉVOLUTIVITÉ ET MODULARITÉ

Chacun des quatre modules du pipeline expose un contrat de données défini, permettant le remplacement indépendant d'un module sans modification des autres.

Le module de détection FER utilise actuellement MediaPipe et HSEmotion comme paire principale. Le contrat de sortie du module — colonnes nommées `hs_fear`, `hs_surprise`, `mp_tension` et `composite_fear` dans le fichier CSV — est indépendant des outils sous-jacents. Un outil futur produisant les mêmes colonnes pourrait s'intégrer sans modifier le reste du pipeline.

Les algorithmes rPPG (CHROM, POS, GREEN) partagent une interface commune dans `Pipeline/rppg_algorithms.py` : entrée = série temporelle RGB, sortie = estimation BPM + SNR. L'ajout d'un nouvel algorithme (par exemple PhysNet) ne requiert que l'implémentation de cette interface. La formule composite est un paramètre configurable ; en changer ne nécessite aucune refactorisation structurelle.

1.4 SÉCURITÉ ET CONDITIONS D'EXPÉRIMENTATION

Le protocole expérimental est conçu pour garantir la sécurité des participants tout en préservant la validité écologique des sessions.

Aucun équipement n'est fixé sur le participant et aucune mesure invasive n'est effectuée. La conception *single-blind* évite d'introduire un biais comportemental lié à la conscience du traitement : la caméra est active dans toutes les conditions, de sorte que les participants ne peuvent pas déduire la condition en cours à partir de la présence ou de l'absence de la caméra. Le droit de retrait est garanti à tout moment, sans pénalité.

1.5 CONTRAINTES ENVIRONNEMENTALES

Les sessions de jeu se déroulent dans un contexte environnemental contraint, différent des configurations de laboratoire standard utilisées dans les benchmarks de FER (Kopalidis et al., 2024).

Éclairage dynamique : Le moniteur constitue la source de lumière principale ou unique ($\sim 50\text{--}100$ lux, variable). Les changements de couleur d'écran lors des moments de forte intensité (éclairs soudains, flash de sursaut) modifient directement les valeurs RGB utilisées par les algorithmes rPPG, constituant une source connue d'artefact spécifique au contexte de jeu. Shao et al. (2025) proposent le Découplage d'Interférence de Fond — une deuxième région d'intérêt placée sur une surface d'arrière-plan statique capture la composante de bruit du moniteur, qui est ensuite soustraite du signal rPPG facial en exploitant la communauté de bruit entre le visage et son environnement. Cette technique est un candidat à l'amélioration en phase 3 pour neutraliser les artefacts de flash d'écran.

Mouvement naturel des participants : Contrairement aux protocoles rPPG de laboratoire où les participants restent immobiles, les sessions de jeu induisent des mouvements naturels : hochements de tête, inclinaisons, expressions réactives. Ce mouvement est une contrainte réelle pour les algorithmes rPPG (dont la précision se dégrade avec le mouvement de la tête) et est intentionnellement préservé dans le protocole afin de refléter les conditions d'utilisation réelles. Le front, structurellement ancré à l'os frontal et dépourvu de musculature d'expression, est identifié par Moghimi & Grailu (2024) comme la région rPPG la plus stable sous mouvement naturel ; cependant, l'occlusion partielle du front (cheveux, sweat-shirts à capuche, accessoires) est un scénario réaliste dans les environnements de jeu et sera abordée en phase 3.

Couverture de détection faciale : Une détection faciale précise dans les conditions de faible luminosité et faible contraste du jeu est critique pour qu’HSEmotion reçoive des recadrages bien définis. Alqahtani et al. (2025) démontrent l’efficacité de YOLOv7 et YOLOv6 pour la détection de visages partiellement occultés dans des scénarios de faible luminosité ; cependant, ces modèles requièrent une inférence GPU et introduisent une surcharge de dépendances incompatible avec un pipeline prioritairement CPU. L’approche hybride cascade de Haar (détection rapide) et MediaPipe FaceLandmarker (reprise en cas d’échec) a été sélectionnée pour des raisons pratiques : les deux composants fonctionnent efficacement sur CPU et sont déjà intégrés dans le pipeline de détection. Les résultats sur Video05_S02 ont confirmé une couverture de détection faciale de 99,9 % avec cette approche. L’implémentation complète est détaillée dans le chapitre CONCEPTION TECHNIQUE.

Tableau 1.1: Synthèse des contraintes et décisions de conception associées

Catégorie	Contrainte principale	Décision de conception
Économique	Webcam grand public uniquement (matériel minimal)	Pipeline CPU-first ; GPU optionnel
Éthique	Aucune transmission de données faciales	Traitement intégralement local ; CSV anonymisés
Évolutivité	Modules indépendants, paire FER fixe	Contrat CSV unifié ; interface rPPG commune
Sécurité	Pas de déception complète	<i>Single-blind</i> ; droit de retrait garanti
Environnement	Éclairage dynamique + mouvement naturel	Artefacts documentés comme limitation ; détection Haar+MP

2 DESIGN CONCEPTUEL

Ce chapitre présente le design conceptuel du projet à deux niveaux : (1) le modèle d'interaction affective, qui définit comment le pipeline se connecte au comportement du joueur et à l'IA du jeu ; (2) le concept du jeu, dont la conception est encore en cours. Le mécanisme *Relax-to-Win* est le seul comportement adaptatif architecturalement confirmé à ce stade.

2.1 MODÈLE D'INTERACTION AFFECTIVE

Le système implémente une boucle de rétroaction biométrique fermée entre l'état émotionnel du joueur et le comportement de l'IA ennemie, indépendamment du genre ou de la perspective visuelle du jeu :

1. Le pipeline détecte les signaux affectifs du joueur principalement via l'analyse d'expressions faciales (FER). Les algorithmes rPPG (CHROM, POS, GREEN) ont été implémentés en phase 2 et des tests préliminaires sur Video05_S02 produisent des estimations physiologiquement plausibles pour les trois algorithmes (résultats au chapitre PREMIERS RÉSULTATS) ; leur intégration dans la boucle de jeu en direct et la validation empirique par une montre connectée sont planifiées pour la phase 3.
2. Les signaux FER sont combinés en un score de peur composite via l'une des sept formules candidates, actuellement en attente d'évaluation systématique sur des données de vérité terrain annotées.
3. Ce vecteur est transmis à l'IA ennemie du jeu via une connexion socket locale, qui ajuste son comportement en conséquence.
4. La réaction du jeu génère de nouveaux stimuli émotionnels pour le joueur, bouclant le cycle.

Le mécanisme *Relax-to-Win* (Moschovitis & Denisova, 2022; Hossan et al., 2025) est le comportement adaptatif confirmé : lorsque le pipeline détecte un état de calme, les ennemis reviennent à un comportement de patrouille passive ; lorsqu’une peur ou un stress élevé est détecté, ils passent à un comportement actif coordonné (Figure 2.1).




Figure 2.1: Modèle d’interaction affective — machine à deux états de l’IA ennemie

2.2 CONCEPT DU JEU

2.2.1 Genre et Objectif

Le jeu est un jeu d’horreur dans lequel le joueur doit naviguer dans un environnement peu éclairé en évitant la détection par des ennemis. Les détails de conception (structure des niveaux, objectifs, mécaniques spécifiques) sont en cours de définition et seront documentés dans le troisième rapport, lors de la phase de développement du jeu.

2.2.2 Perspective et Plateforme

La perspective de jeu n’est pas encore finalisée. Une vue à la première personne (3D FPS) est envisagée comme direction principale ; une vue de dessus (2D) constitue une alternative. La décision sera prise en phase 3 en fonction des contraintes d’intégration du pipeline affectif et des délais de développement.

La contrainte technique imposée par le pipeline est indépendante de la perspective retenue : le visage du joueur doit rester visible par la webcam tout au long d’une session, ce qui contraint la posture et la configuration physique, mais non le genre de jeu.

2.3 STRATÉGIE DE FUSION AFFECTIVE (NIVEAU CONCEPTUEL)

Au niveau conceptuel, le pipeline produit un score de peur composite que l'IA ennemie utilise pour transiter entre deux états comportementaux (Figure 2.1). Le score est actuellement calculé à partir des sorties des outils FER (MediaPipe et HSEmotion) via l'une des sept formules candidates, dont l'évaluation est détaillée dans le chapitre PREMIERS RÉSULTATS.

Au-delà de la FER, l'estimation du rythme cardiaque par photopléthysmographie à distance (rPPG) est destinée à jouer un rôle dans l'évaluation finale de l'état affectif. Le mécanisme d'intégration exact est encore en cours de développement et sera déterminé par les résultats des benchmarks de la phase 3. Trois options conceptuelles sont à l'étude : (1) la fusion directe du rythme cardiaque rPPG dans le vecteur d'état affectif, (2) l'utilisation du rPPG comme contexte de tendance de base à long terme tandis que la FER pilote les décisions en temps réel, et (3) l'utilisation du rPPG comme seuil de qualité pour supprimer la sortie FER lors de périodes de conflit physiologique-facial. Ces options sont détaillées dans le chapitre CONCEPTION TECHNIQUE et seront évaluées à la suite des expériences de la phase 3.

La stratégie de fusion est encore en cours de développement. La formule finale, le mode d'intégration du rPPG et les paramètres de seuil régissant les transitions de l'IA ennemie (la valeur de `composite_fear` déclenchant un changement d'état, et la durée de l'état actif) sont des paramètres de calibrage à déterminer sur la base des benchmarks d'annotation de vérité terrain et des résultats expérimentaux de la phase 3.

3 CONCEPTION TECHNIQUE

Ce chapitre traduit les choix conceptuels du chapitre DESIGN CONCEPTUEL en spécifications techniques formelles, en s'appuyant sur l'architecture de haut-niveau introduite dans le premier rapport intermédiaire. Les sections suivent le flux de données du pipeline : détection faciale, analyse FER, algorithmes rPPG, formule composite, stratégie de fusion et communication avec le jeu.

3.1 ARCHITECTURE DU PIPELINE (VUE ACTUALISÉE)

Par rapport à l'architecture de haut-niveau du premier rapport intermédiaire, la phase 2 a précisé les outils et remplacé la détection faciale générique par une approche hybride. La Figure 3.1 présente l'architecture actualisée.




Figure 3.1: Architecture actualisée du pipeline affectif (phase 2)

3.2 DIAGRAMME DE FLUX DE DONNÉES (FER)

La Figure 3.2 détaille le traitement par trame du module FER. Chaque trame reçue de la webcam passe d’abord par la détection faciale hybride avant l’analyse émotionnelle parallèle.




Figure 3.2: Flux de traitement par trame du module FER

3.3 ALGORITHMES RPPG : SPÉCIFICATION FORMELLE

Les trois algorithmes implémentés dans `Pipeline/rppg_algorithms.py` extraient un signal de pouls à partir d’une série temporelle RGB $[R(t), G(t), B(t)]$ obtenue par moyennage d’une région d’intérêt (ROI) frontale — suivant le modèle de réflexion dichromatique de la peau de Wang et al. (2017) — puis estiment la fréquence cardiaque par transformée de Fourier.

GREEN : signal de comparaison minimal.

$$S = G(t) - \overline{G} \quad (1)$$

CHROM (Wang et al., 2017) : suppression de la réflexion spéculaire par projection chromatique.

$$X = R - G, \quad Y = 0.5R + 0.5G - B, \quad S = X - \frac{\sigma_X}{\sigma_Y} Y \quad (2)$$

où σ_X et σ_Y sont les écarts-types calculés sur la fenêtre glissante.

Note : l'implémentation courante du script (`rppg_algorithms.py`) utilise une variante par ratio de moyennes glissantes $(\bar{X}/\bar{Y} - 1)$; la formule dérivée formellement (Wang et al., 2017) utilise la forme par soustraction chromatique présentée ci-dessus. Les deux variantes seront comparées en phase 3.

POS (Wang et al., 2017) : normalisation temporelle puis projection orthogonale, robuste aux variations de teinte cutanée. Après normalisation de chaque canal par sa moyenne glissante :

$$\hat{C}(t) = \frac{C(t)}{\mu_C} - 1, \quad C \in \{R, G, B\}, \quad S = (\hat{G} - \hat{B}) + \alpha (\hat{G} + \hat{B} - 2\hat{R}) \quad (3)$$

avec $\alpha = \sigma_{H_1}/\sigma_{H_2}$ adaptatif, où $H_1 = \hat{G} - \hat{B}$ et $H_2 = \hat{G} + \hat{B} - 2\hat{R}$. Cette formulation correspond à la fois à l'implémentation du script et à la dérivation formelle de Wang et al. (2017).

Estimation BPM : Le signal S est filtré (filtre passe-bande Butterworth d'ordre 4, 0,7–3,0 Hz = 42–180 BPM), puis analysé par FFT sur une fenêtre glissante (actuellement 30 s ; la méthode n'est pas encore finalisée et sera optimisée en phase 3, pas de 5 s). La fréquence dominante est affinée par interpolation parabolique du pic FFT.

Tableau 3.1: Comparaison des algorithmes rPPG implémentés

Algorithme	Robustesse mouvement	MAE théorique	Rôle
GREEN	Faible	$\sim 3,0$ BPM	Référence inférieure
CHROM	Moyenne	$\sim 1,5$ BPM	Alternative robuste
POS	Élevée	$\sim 1,1$ BPM (Acharya et al., 2025)	Candidat principal

ROI et notes environnementales. La ROI frontale couvre actuellement l'ensemble du cadre de détection du visage. Moghimi & Grailu (2024) identifient le milieu du front (région de la veine sus-trochléaire) comme la ROI primaire optimale pour les contextes à forte expressivité, atteignant $>98\%$ de précision du rythme cardiaque sur un jeu de données comparable (640×480 à 25 FPS). Les régions à mouvement non rigide (joues, bouche, menton) doivent être exclues dans les contextes de jeu où les expressions faciales sont fréquentes. La phase 3 évaluera une ROI restreinte au front (30–35 % supérieur du cadre de détection). De plus, Shao et al. (2025) démontrent que le Découplage d'Interférence de Fond — capture du bruit environnemental depuis une ROI d'arrière-plan puis soustraction du signal facial — neutralise les artefacts de flash d'écran ; cette technique est également un candidat pour la phase 3.

Améliorations prévues pour la phase 3. Quatre améliorations sont planifiées pour l'évaluation en phase 3 :

1. **ROI frontale** (Moghimi & Grailu, 2024) : restreindre l'extraction rPPG aux 30–35 % supérieurs du cadre de détection du visage ; évaluer une stratégie de repli pour les fronts occultés (cheveux, accessoires).
2. **Vérification des algorithmes** (Wang et al., 2017) : comparer la variante CHROM par ratio courante avec la forme standard par soustraction chromatique ; vérifier les coefficients POS. POS est prioritaire compte tenu de son SNR supérieur au benchmark (5,16 dB contre 3,86 dB pour CHROM sur 60 vidéos dans quatre conditions).
3. **Lissage temporel et filtrage par confiance** (Savchenko, 2025) : moyenne glissante ($\delta = 50$ trames à 30 FPS) sur `composite_fear` ; seuil de confiance ($t = 0,7$ sur le softmax HSEmotion) pour exclure les trames ambiguës.
4. **Découplage d'Interférence de Fond** (Shao et al., 2025) : capture du bruit du moniteur depuis une ROI d'arrière-plan et soustraction du signal rPPG facial pour neutraliser les artefacts de flash d'écran.

3.4 FORMULE COMPOSITE DE PEUR (CANDIDATE)

Sept formules composites ont été systématiquement évaluées lors du benchmark de phase 2 (chapitre PREMIERS RÉSULTATS). La formule candidate principale identifiée est :

$$\text{composite_fear} = 0.40 \times \text{hs_fear} + 0.20 \times \text{hs_surprise} + 0.40 \times \text{mp_tension} \quad (4)$$

Cette formule est présentée comme candidate en attente de validation multi-sujets et multi-sessions. Elle distingue la peur de la colère — qui partagent le même quadrant d'arousal élevé dans le modèle circomplexe — en s'appuyant sur la probabilité directe de peur (hs_fear) plutôt que sur l'arousal brut. La composante hs_surprise (poids 0,20) est incluse pour capter les événements de sursaut où la surprise est l'expression dominante avant que la peur ne s'enregistre.

Le Tableau 3.2 résume les sept formules candidates. Les résultats complets du benchmark sont présentés dans le chapitre PREMIERS RÉSULTATS.

Tableau 3.2: Sept formules candidates de peur composite

ID	Composition
F0	$0,60 \times \text{hs_arousal} + 0,40 \times \text{mp_tension}$ (base arousal)
F1	$0,60 \times \text{hs_fear} + 0,40 \times \text{mp_tension}$ (peur + tension)
F2	Équation 4 (peur + surprise + tension — candidate)
F3	Variante pondérée : poids hs_fear réduit avec compensation hs_surprise
F4	Équilibrée : poids égaux sur les trois signaux
F5	Arousal doux : mélange hs_arousal et hs_fear
F6	Veto doux : poids hs_fear élevé avec terme de suppression de colère

3.5 RÔLE DU RPPG DANS LA FUSION

Le rôle exact du signal rPPG dans la décision de fusion reste sous investigation. Trois options architecturales sont envisagées :

- **Option A — Fusion directe :** Le BPM rPPG est intégré directement dans le vecteur d'état affectif **a**, pondéré par le SNR du signal. La tendance à la hausse du rythme cardiaque peut renforcer une détection FER faible.
- **Option B — Filtre de tendance de base :** Le rPPG fournit uniquement un contexte de tendance à long terme (rythme cardiaque de repos avant la session vs. en jeu). La FER conduit la détection temps-réel ; le rPPG module le niveau d'arousal global de la session.
- **Option C — Filtre de qualité :** Le rPPG est utilisé pour pondérer ou supprimer la sortie FER lors des périodes où la physiologie mesurée est en désaccord avec les expressions faciales détectées, réduisant les faux positifs potentiels.

Le choix entre ces options sera évalué selon trois critères : (1) impact sur le taux de faux positifs lors des périodes de confondant lumineux (écran), (2) surcoût de latence lié à l'intégration du signal rPPG dans la décision par trame, et (3) robustesse à la dégradation du signal rPPG lors des mouvements de tête. L'option B est actuellement privilégiée comme approche à risque minimal, puisqu'elle découple le rPPG des décisions FER en temps réel. La décision finale sera prise après réception des résultats de la comparaison des frameworks rPPG planifiée dans le chapitre ANALYSE DE COÛTS.

3.6 STRATÉGIE DE DÉTECTION PAR COUCHES

Le pipeline traite chaque trame en quatre couches temporellement enchaînées :

1. **Couche 1** (MediaPipe, ~ 6 ms) : extraction de 52 blendshapes faciaux $\rightarrow$ score `mp_tension` continu.
2. **Couche 2** (HSEmotion, ~ 10 ms) : classification softmax $\rightarrow$ probabilités `hs_fear`, `hs_surprise` et 6 autres émotions.
3. **Couche 3** (formule, < 1 ms) : application de l'Équation 4 $\rightarrow$ score `composite_fear` normalisé $[0,1]$.
4. **Couche 4** (rPPG, fenêtre courante ; méthode non encore finalisée) : accumulation de la ROI frontale $\rightarrow$ estimation BPM mise à jour toutes les 5 s (thread non-bloquant).

Un mécanisme VETO (suppression post-score basée sur des seuils contextuels) a également été évalué. Les résultats du benchmark (chapitre PREMIERS RÉSULTATS) n'ont montré aucun impact positif d'aucune configuration VETO par seuil ; des approches alternatives (suppresseur multiplicatif doux, VETO contextuel) restent en cours d'investigation.

3.7 COMMUNICATION UNITY-PIPELINE

À chaque trame, le module de fusion émet le vecteur d'état affectif $\mathbf{a} = [\text{composite_fear}, \text{valence}, \text{BPM}]$ via une connexion socket locale vers Unity. Les mises à jour FER sont émises par trame (~ 30 Hz) ; les mises à jour BPM sont émises toutes les 5 s à la fin d'une nouvelle fenêtre rPPG. Les protocoles TCP (livraison fiable et ordonnée) et UDP (latence minimale) seront tous deux évalués en phase 3 afin de déterminer le meilleur compromis pour la transmission de données affectives en temps réel.

4 ANALYSE DE COÛTS

Ce chapitre documente le coût computationnel du pipeline proposé, mesuré en latence par composant, utilisation des ressources et budget global de latence. Ces mesures orientent les décisions d’optimisation et détermineront la viabilité de la fusion en temps réel.

4.1 LATENCE PAR COMPOSANT (HÔTE WINDOWS)

La latence de chaque composant a été mesurée sur une machine Windows 11 en conditions contrôlées (Video05_S02, 197 s, 30 FPS nominal). Le Tableau 4.1 résume les résultats d’un passage complet sur la vidéo.

Tableau 4.1: Latence par outil (Windows 11, contrôlé, host CPU)

Outil	Moy. (ms)	Méd. (ms)	P95 (ms)	FPS eff.	CPU moy.	RAM
MediaPipe	6.2	5.9	7.4	148	4 %	431 MB
HSEmotion	10.1	9.9	11.8	104	67.5 %	255 MB
DeepFace	41.4	40.9	48.9	26	17.1 %	557 MB
Py-Feat (GPU)	863	—	—	1.2	—	—

Lorsque MediaPipe et HSEmotion sont exécutés dans une boucle partagée avec détection faciale hybride unifiée (Haar + récupération MediaPipe), la boucle FER double outil a atteint **54,6 FPS** sur Video05_S02, avec **99,9 %** de couverture de détection faciale sur cet enregistrement.

4.2 ANALYSE DES RESSOURCES

L'asymétrie CPU entre les outils est marquée. MediaPipe utilise un runtime C++ optimisé et ne dépend pas de GPU, consommant 4 % du CPU. HSEmotion s'appuie sur PyTorch en mode CPU (CUDA désactivé sur Windows post-TensorFlow 2.10, où NCCL n'est pas disponible) ; sa consommation a atteint en moyenne 67,5 % du CPU lors du traitement hors ligne contrôlé de Video05_S02 (197 s) ; l'utilisation soutenue lors d'une inférence en jeu en direct devrait être inférieure, car PyTorch est invoqué par trame plutôt qu'en mode batch continu.

Py-Feat et DeepFace ont tous deux été exclus du projet sur la base de ces mesures. La pipeline XGBoost *Action Unit* de Py-Feat est liée au CPU, produisant une latence de 863 ms par image même avec une GPU RTX 4070 disponible — catégoriquement incompatible avec toute application temps réel. DeepFace à 41,4 ms (26 FPS) est $4,1 \times$ plus lent que HSEmotion sans avantage significatif en termes de précision pour cette tâche. Aucun autre benchmark n'est prévu pour ces deux outils.

La fusion dans une boucle partagée réduit les frais généraux par rapport à l'exécution indépendante des outils. Une seule détection faciale hybride (Haar $\rightarrow$ MediaPipe) est réutilisée pour MP et HS, éliminant les doublons de détection.

Optimisation future : Débloquer l'accélération GPU pour HSEmotion en Phase 3 réduirait considérablement la consommation CPU et porterait le débit combiné plus près du maximum théorique de MediaPipe. Cela nécessite de reconfigurer l'environnement Windows CUDA ou de basculer vers une plate-forme avec NCCL natif.

4.3 COMPARAISON DES FRAMEWORKS RPPG (PLANIFIÉE)

La conteneurisation a été adoptée pour isoler les conflits de dépendances Python entre les frameworks rPPG (pyVHR requiert des versions spécifiques plus anciennes de NumPy et OpenCV incompatibles avec rPPG-Toolbox et l’environnement hôte), et non comme stratégie de déploiement. Trois conteneurs sont préparés : pyVHR (CHROM/-POS/GREEN), rPPG-Toolbox (PhysNet, EfficientPhys) et l’implémentation autonome hôte.

Une évaluation fiable du rPPG nécessite des valeurs de référence cardiaques indépendantes issues d’une montre connectée portée lors des sessions d’enregistrement ; cet équipement est en cours d’acquisition. La montre connectée est attendue fin avril 2026. Selon le calendrier de livraison, les benchmarks rPPG pourraient ne pas être achevés avant la fin de la phase 3. L’absence de matériel de référence cardiaque validé constitue une limitation active pour l’évaluation du rPPG et est documentée comme risque projet.

Une fois la vérité terrain disponible, la comparaison des frameworks produira :

- **Tableau 9.2 (rPPG)** : Comparaison des estimations BPM entre pyVHR (CHROM/-POS/GREEN), rPPG-Toolbox (PhysNet, EfficientPhys) et l’implémentation autonome sur les vidéos éligibles (sans coupures de scène). Métrique : concordance BPM par rapport à la vérité terrain montre, durée de calcul par fenêtre.
- **Tableau 9.3** : Analyse des compromis entre les frameworks conteneurisés et l’implémentation autonome pour l’intégration en phase 3.

Le script de comparaison `Pipeline/benchmark_compare.py` automatisera cette collecte.

4.4 BUDGET DE LATENCE TOTAL

Le chiffre de 54,6 FPS de la Section 9.1 mesure le débit de traitement FER seul (MediaPipe + HSEmotion + formule), hors délai de capture caméra. Le budget ci-dessous ajoute la période de trame caméra de 33 ms, qui domine la latence de bout en bout. En concaténant les latences des couches (chapitre CONCEPTION TECHNIQUE, section Stratégie de Détection par Couches) et des délais de transmission socket, le budget de latence total est estimé à :

$$L_{\text{total}} = L_{\text{camera}} + L_{\text{Haar+MP}} + L_{\text{HS}} + L_{\text{formula}} + L_{\text{socket}} \quad (1)$$

où :

- $L_{\text{camera}} = 33$ ms (délai d'une trame à 30 FPS)
- $L_{\text{Haar+MP}} \approx 9$ ms (détection hybride)
- $L_{\text{HS}} \approx 10$ ms (HSEmotion softmax)
- $L_{\text{formula}} < 1$ ms (application de la formule F2)
- $L_{\text{socket}} \approx 1$ ms (émission socket locale)

Résultat : $L_{\text{total}} \approx 53$ ms par trame. Cela correspond à environ **19 FPS** effective pour le pipeline fermé. Cette latence est bien inférieure au budget de 200 ms (5 FPS) fixé en phase 1 pour maintenir une rétroaction cohérente.

Le canal rPPG s'exécute dans un thread d'arrière-plan non-bloquant et ne contribue pas à la latence FER par trame. Estimation de la surcharge : extraction des pixels de la ROI ≈ 1 ms par trame ; FFT sur la fenêtre courante $\approx 50\text{--}100$ ms (exécutée toutes les 5 s, non-bloquant). Cela introduit une latence de mise à jour de 5 s pour les estimations BPM ; la FER en temps réel n'est pas affectée. Ces estimations sont d'ordre de grandeur, en attente d'une mesure instrumentée en phase 3.

Tableau 4.2: Décomposition du budget de latence

Composant	Latence
Capture caméra	33 ms
Détection Haar+MP	9 ms
Analyse HSEmotion	10 ms
Application formule	<1 ms
Émission socket	1 ms
Total	53 ms

5 PREMIERS RÉSULTATS

Ce chapitre synthétise les premiers résultats empiriques de la phase 2, couvrant la comparaison des outils FER, l'évaluation des formules de peur, la faisabilité de rPPG, et la méthodologie d'annotation. Aucune recommandation définitive n'est encore faite; tous les résultats sont des constats préliminaires en attente d'une validation multi-sujets et multi-sessions.

5.1 COMPARAISON DES OUTILS FER (HÔTE)

Les résultats Phase 2 effectués en conditions contrôlées sur la machine hôte Windows révèlent un problème central : les seuils de blendshape *Action Unit* publiés par MediaPipe sont calibrés sur des données démographiques larges et ne se généralisent pas aux sujets individuels.

Pour le participant S01 au cours d'une session neutre (contenu non-émotionnel), aucun des blendshapes liés à la peur n'a atteint le seuil d'activation (p. ex., les valeurs maximales observées étaient de 0,22 pour *eyebrows_inner_raise*, bien en dessous du seuil typiquement utilisé de 0,5). En contraste, une session de stress (test visuel avec vidéo) a produit des blendshapes augmentés cohérents avec les états affectifs anticipés.

Il reste à déterminer si ces faibles activations reflètent une variation physiologique réelle, les conditions d'enregistrement, ou la sensibilité de calibration démographique de MediaPipe. Cette observation — que les niveaux d'activation MediaPipe peuvent varier significativement entre sujets — a contribué à la décision d'adopter le pipeline hybride décrit dans le chapitre CONCEPTION TECHNIQUE : HSEmotion fournit une classification softmax indépendante du sujet qui ne repose pas sur des seuils d'activation UA fixes, complétant les scores de blendshape de MediaPipe. Yang et al. (2026) proposent l'**Alignement de Distribution des Blendshapes** (BDA), une étape de calibration légère (<1 ms) qui mappe la plage de blendshape d'un individu vers un espace canonique par régression linéaire ; cette approche est une candidate pour la phase 3 afin de traiter la variabilité d'activation inter-sujets.

La justification de la sélection des outils et les comparaisons de latence sont documentées dans le chapitre ANALYSE DE COÛTS.

5.2 BENCHMARK DES FORMULES DE PEUR

Méthodologie : Sept formules candidates ont été évaluées systématiquement contre une vérité de terrain manuelle sur Video05_S02 (197 s). La vérité de terrain comportait 9 événements de peur annotés manuellement et 5 événements d'erreur (colère/confusion) servant de négatifs de contraste. L'évaluation s'est déroulée en deux phases : la Phase A a balayé l'ensemble des combinaisons formule-graine ($7 \times 10 = 70$ exécutions) afin d'identifier les meilleures paires ; la Phase B a évalué les 3 formules et 3 graines retenues sur l'ensemble des configurations VETO ($3 \times 3 \times 5 = 45$ exécutions), pour un total de 115 exécutions d'essai.

Note : L'annotation de vérité terrain pour Video05_S02 est préliminaire. Le modèle v2 avec horodatages manuels (`start_s/end_s`) est préparé mais pas encore rempli ; les résultats ci-dessous sont basés sur les timings auto-détectés v1. Une re-annotation manuelle complète est planifiée. Ces résultats constituent une évaluation de premier passage et ne doivent pas être traités comme définitifs ; une validation multi-sujets et multi-sessions est nécessaire avant qu'une formule puisse être adoptée.

Métrique primaire : Le ratio de discrimination peur/colère au niveau de la trame. Objectif : $> 3,0\times$.

Les résultats de ce benchmark sont résumés au Tableau 5.1.

Tableau 5.1: Résultats du benchmark des formules de peur (Video05_S02, discrimination peur/colère)

ID Formule	Peur Moy.	Colère Moy.	Ratio	État
F0_CURRENT	0.42	0.32	$1.3\times$	CASSÉ
F1_FEAR_TENSION	0.68	0.12	$5.5\times$	Ratio maximal
F2 (Candidate)	0.55	0.14	$4.0\times$	Candidat principal
F3_FEAR_HEDGED	0.48	0.19	$2.5\times$	À évaluer
F4_BALANCED	0.51	0.17	$3.0\times$	À évaluer
F5_SOFT_AROUSAL	0.46	0.21	$2.2\times$	À évaluer
F6_SOFT_VETO	0.61	0.06	$9.5\times$	Extrême (risque de surcompression)

Conclusions :

La formule F0 (l'approche d'arousal actuelle) n'atteint que $1.3\times$, ce qui est proche du hasard (le ratio attendu si les deux événements étaient indiscernables). F1_FEAR_TENSION atteint le plus haut ratio ($5.5\times$) mais à un prix : elle manque systématiquement les événements de sursaut où la surprise est l'expression dominante avant que la peur ne s'enregistre.

La formule candidate F2 atteint $4,0\times$, ce qui dépasse l'objectif de $3,0\times$ tout en capturant un spectre plus large d'événements aversifs. Elle est actuellement en évaluation. L'inclusion de la composante *hs_surprise* est soutenue par Abdeldayem et al. (2026), qui documentent que la peur (UA 1+2+4) et la surprise (UA 1+2+5) ne diffèrent que par l'activation de UA 4 (froncement) ou UA 5 (élévation de la paupière supérieure), entraînant une confusion systématique peur-surprise à travers les benchmarks FER ; le signal combiné de F2 capture les deux schémas d'activation.

Résultats VETO : À travers les 45 configurations de Phase B ($3 \times 3 \times 5$), aucune configuration VETO n’a amélioré le score F1 sur la base de référence sans VETO (V0). La configuration VETO de référence (V1) a supprimé 3 vrais positifs tout en capturant 0 faux positifs — un bilan négatif. Ces résultats indiquent que *le mécanisme par seuil est la mauvaise approche* pour ce signal, pas que les VETOs sont architecturalement invalides. Des approches alternatives — supprimeur multiplicatif doux, VETO contextuel conscient des biais de session — sont en cours d’examen.

Status de recommandation : Aucune recommandation définitive ne peut être faite sans annotation multi-sujets et multi-sessions complète. Les résultats sont limités à une seule vidéo (Video05_S02) et une seule condition. Une validation croisée sur d’autres sujets et sessions est obligatoire avant d’adopter une formule dans le déploiement.

5.3 RÉSULTATS RPPG : VÉRIFICATION DE FAISABILITÉ

Test préliminaire CHROM : L’algorithme CHROM autonome a été appliqué sur Video05_S02 (197 s). Un ROI frontal unique a été défini manuellement ; les valeurs RGB ont été extraites par moyenne spatiale des pixels de la région. Une fenêtre glissante (30 s lors de ce test ; taille non encore finalisée), avec un chevauchement de 83 % et un pas de 5 s, a été appliquée.

Résultat indicatif : **58,5 BPM**, avec les 34 fenêtres produisant des estimations dans la plage physiologiquement plausible (40–120 BPM). Ces valeurs n’ont pas été validées contre une référence cardiaque indépendante ; elles constituent une indication de plausibilité, et non une mesure empirique validée. L’évaluation rigoureuse est prévue en phase 3 après acquisition d’une montre connectée (attendue fin avril 2026).

Wang et al. (2017) comparent sept algorithmes rPPG sur 60 vidéos dans quatre conditions (teinte de peau, luminance, récupération de mouvement, activité physique), classant POS au-dessus de CHROM en SNR global (5,16 dB contre 3,86 dB pour CHROM), notamment en mouvement et sous illumination variable. Le résultat CHROM de 58,5 BPM sert de référence de faisabilité. POS est identifié comme le candidat principal d’algorithme pour la phase 3, en particulier compte tenu du contexte de jeu avec une variation fréquente de l’illumination induite par le moniteur.

Test de fusion multi-algorithmes : Le script `test_fusion.py` a été appliqué sur Video05_S02 avec les trois algorithmes en simultané. Les estimations obtenues sont résumées dans le Tableau 5.2.

Tableau 5.2: Estimations rPPG multi-algorithmes (Video05_S02)

Algorithme	Estimation (BPM)	Statut
CHROM	55,0	Plausible
POS	58,0	Plausible
GREEN	53,7	Plausible

Les trois algorithmes produisent des estimations voisines, toutes dans la plage physiologiquement plausible (40–120 BPM). Ces valeurs ne sont pas validées contre une référence cardiaque indépendante ; elles confirment la faisabilité opérationnelle des trois algorithmes sur ce type d’enregistrement.

Défi connu : Le contexte du jeu vidéo (flashes d’écran, changements de couleur lors des moments intenses) constitue un confondant pour les algorithmes rPPG basés sur RGB : les valeurs RGB changent en raison de la source lumineuse (l’écran) plutôt que du pouls physiologique (Acharya et al., 2025). Shao et al. (2025) traitent précisément ce défi par le Découplage d’Interférence de Fond : une deuxième ROI sur une surface d’arrière-plan statique capture la composante de bruit partagée entre le visage et son environnement due aux reflets du moniteur, et ce bruit est soustrait du signal rPPG facial. Cette technique est un candidat à la mitigation en phase 3. Ce défi sera également abordé dans le protocole d’évaluation de la phase 3.

5.4 MÉTHODOLOGIE D'ANNOTATION ET RÉSULTATS PRÉLIMINAIRES

5.4.1 Dépendance circulaire

Une incohérence méthodologique a été identifiée dans la première itération d'annotation (v1) : les événements ont été détectés et annotés en utilisant la formule F0 comme détecteur de pics. Cependant, F0 est elle-même une formule candidate à évaluer dans le benchmark. Cette dépendance circulaire biaise le benchmark *contre* les formules qui détectent des événements que F0 a manqués.

Solution : Le modèle d'annotation v2 ajoute des colonnes *manuelles* start_s et end_s : l'annotateur indépendant regarde la vidéo et enregistre directement les instants d'événement, sans recourir à aucune détection basée sur une formule. Cette approche élimine la dépendance circulaire.

5.4.2 Résultats de la première annotation (Video05_S02)

La première annotation de Video05_S02 (197 s), basée sur les timings v1 (le modèle v2 est préparé mais la saisie manuelle des horodatages reste à compléter), a produit :

- **9 événements True Positive (peur véritable)** après déduplication
- **5 événements False Positive (colère/confusion)** servant de négatifs

Un post-hoc mesure de la *sustained%* (pourcentage de trames au-dessus du seuil de composite_fear) montre une forte discrimination :

- TP (peur véritable) : 45–54 % des trames
- FP (colère) : 11,8 % des trames
- Écart : $4\times$ ($\sim$ même ordre que les ratios du benchmark de formule)

Cette cohérence valide que la vérité de terrain v1 capture une distinction significative et que les métriques du benchmark sont fiables.

5.5 CONSTATS CLÉS ET IMPLICATIONS DE CONCEPTION

5.5.1 Évaluation des Formules de Peur

Le benchmark de phase 2 a établi que les formules basées sur l'arousal sont inadaptées à la détection de la peur dans les contextes de jeu. La formule F0 (60 % arousal HSEmotion + 40 % tension MediaPipe) n'atteint qu'un ratio de discrimination peur/colère de $1,3\times$ — proche du hasard — car la colère et la peur occupent des régions d'arousal élevé chevauchantes dans le modèle circomplexe de l'affect. La formule candidate F2 atteint $4,0\times$, dépassant l'objectif de $3,0\times$. La composante `hs_surprise` capture les événements de sursaut où la surprise précède l'enregistrement de la peur dans HSEmotion, un schéma soutenu par Abdeldayem et al. (2026), qui documentent une confusion systématique UA 4/UA 5 entre peur et surprise à travers les benchmarks FER. F1 (peur + tension seulement) atteint $5,5\times$ mais manque les événements de sursaut à dominante surprise — un compromis précision/rappel à évaluer sur des données multi-sujets.

5.5.2 Constats sur le Mécanisme VETO

À travers les 45 configurations de Phase B ($3 \times 3 \times 5$), aucune configuration VETO par seuil n'a amélioré les performances de détection par rapport à la référence sans VETO. Le VETO de référence (V1) a supprimé 3 vrais positifs et capturé 0 faux positifs — un bilan négatif. Cela indique que la suppression par seuil fixe est inadaptée aux caractéristiques du signal ; cela ne signifie pas que les VETOs sont architecturalement invalides. Des approches alternatives (suppresseur multiplicatif doux, VETO temporel conscient du contexte) restent inexplorées et sont planifiées pour la phase 3.

5.5.3 Faisabilité et Limites du rPPG

La faisabilité du rPPG a été confirmée sur Video05_S02 (58,5 BPM CHROM, 34/34 fenêtres dans la plage plausible). Cependant, plusieurs limitations ont été identifiées :

- **Granularité de la fenêtre** : la fenêtre actuelle (30 s en phase 2, non encore finalisée) peut être trop grossière pour résoudre les pics brefs du rythme cardiaque induits par la peur. Les pics cardiaques aigus liés au sursaut peuvent survenir sur 2–10 s (Acharya et al., 2025). Une fenêtre plus courte ou une extraction déclenchée par événement est un item d’investigation pour la phase 3.
- **Interférence des expressions** : l’activation des UA faciaux lors des expressions de peur peut distordre la géométrie cutanée utilisée par les algorithmes rPPG. Une hypothèse — restreindre l’extraction rPPG aux fenêtres de visage neutre (HSEmotion = Neutre ET tension MediaPipe faible) — a été identifiée, en attente d’un retour de l’encadrant.
- **Illumination du moniteur** : les changements de couleur d’écran lors des sursauts affectent directement les valeurs RGB de la ROI (Acharya et al., 2025). Le Découplage d’Interférence de Fond (Shao et al., 2025) est un candidat à la mitigation en phase 3.
- **Limitation matérielle** : la vérité terrain de la montre connectée est indisponible avant fin avril 2026. Tous les résultats rPPG sont des vérifications de plausibilité uniquement ; la validation empirique est bloquée par la livraison du matériel.

5.5.4 Méthodologie d'Annotation

L'annotation v1 utilisait F0 comme détecteur de pics, introduisant une dépendance circulaire : le benchmark évaluait F0 contre une vérité terrain générée par F0 elle-même. Le modèle v2 élimine cela en exigeant des horodatages `start_s/end_s` manuels issus d'une annotation indépendante, sans recours à aucune détection basée sur une formule.

La métrique post-hoc *sustained%* (pourcentage de trames au-dessus du seuil composite_fear) montre un écart de $4\times$ entre les événements vrais positifs (45–54 % des trames au-dessus du seuil) et les faux positifs (11,8 %), cohérent avec les ratios du benchmark de formule et validant la méthodologie d'annotation. Les annotations de Video05_S02 sont préliminaires ; des vidéos et sujets supplémentaires seront annotés en phase 3 avec le modèle v2 pour permettre une validation inter-sujets.

5.5.5 Architecture de Détection Hybride

L'approche hybride de détection faciale Haar + MediaPipe a amélioré la couverture faciale pour HSEmotion de 30,4 % (cascade de Haar seule) à 99,9 % sur Video05_S02. Ceci est critique dans les conditions de jeu où les trames à faible contraste (environnements sombres) provoquent des échecs de détection Haar ; MediaPipe FaceLandmarker réussit là où Haar échoue. L'équivalence $r = 0,935$ entre les scores HSEmotion recadrés par Haar et par MediaPipe (à 10 % de marge) valide que le passage entre sources de détection n'introduit pas d'artefacts de classification. Des détecteurs alternatifs tels que YOLOv7 (Alqahtani et al., 2025) ont été considérés pour la robustesse en faible luminosité, mais la contrainte de priorité CPU et la surcharge de dépendances ont conduit au choix Haar + MediaPipe ; les résultats ont été satisfaisants.

5.5.6 Infrastructure Construite en Phase 2

Les outils et jeux de données suivants ont été développés et sont disponibles pour la phase 3 :

- `Pipeline/test_fusion.py` : boucle de fusion triple outil (MediaPipe + HSEmotion + rPPG), 54,6 FPS sur Video05_S02, 99,9 % de détection faciale, 40+ colonnes CSV
- `Pipeline/rppg_algorithms.py` : module partagé CHROM, POS, GREEN ; vérifié sur un signal synthétique à 72 BPM
- `Pipeline/annotate_helper.py` : générateur d'annotations v1 (pic+6 s) et v2 (flood-fill, horodatage manuel) avec score de formule F2 et options `-formula` et `-seed` configurables
- `Pipeline/formula_benchmark.py` : balayage systématique 7 formules $\times$ 10 graines $\times$ 5 VETO contre la vérité terrain annotée
- `Pipeline/benchmark_compare.py` : script d'automatisation de la comparaison Docker vs. hôte
- `Recordings/VideoBaseContext.csv` : 15 vidéos sur 5 sujets avec indicateurs d'éligibilité FER/rPPG/sursaut
- Infrastructure Docker : 6 conteneurs (3 rPPG : pyVHR, rPPG-Toolbox, hôte autonome ; 3 FER : DeepFace, Py-Feat, MP+HS)

5.6 PLAN D'ÉVALUATION PHASE 3

Les expériences suivantes sont planifiées pour la phase 3, sur la base des résultats de la phase 2 et de la littérature nouvellement étudiée. Toutes les expériences nécessitant une vérité terrain validée par montre connectée sont conditionnées à la disponibilité du matériel (attendue fin avril 2026) ; les benchmarks incomplets seront reportés dans le rapport final.

1. **Comparaison ROI frontale** (Moghimi & Grailu, 2024) : ROI primaire frontale (30–35 % supérieur du cadre de détection du visage) vs. ROI plein visage actuelle sur les vidéos éligibles rPPG (Video05_S02, série S01). Une stratégie de repli pour les fronts partiellement occultés sera également évaluée. Métrique principale : variance du BPM lors des événements de peur annotés vs. référence calme.
2. **Vérification et comparaison des algorithmes** (Wang et al., 2017) : variante CHROM par ratio vs. forme standard par soustraction chromatique ; POS comme candidat principal compte tenu de son SNR supérieur au benchmark (5,16 dB contre 3,86 dB pour CHROM sur un benchmark de 60 vidéos). Les trois algorithmes (CHROM, POS, GREEN) évalués contre la vérité terrain de la montre connectée une fois disponible.
3. **Lissage temporel et filtrage par confiance FER** (Savchenko, 2025) : moyenne glissante ($\delta = 50$ trames à 30 FPS) sur `composite_fear` ; seuil de confiance ($t = 0,7$ sur le softmax HSEmotion) pour exclure les trames ambiguës. Métriques : précision, rappel, F1 contre les annotations de vérité terrain v2.
4. **Découplage d'Interférence de Fond** (Shao et al., 2025) : extraction double ROI (front + référence d'arrière-plan) pour soustraire le bruit de luminosité du moniteur du signal rPPG. Évalué sur les vidéos à fort contenu de flash de moniteur.

5. **Calibration inter-sujets des seuils** (Yang et al., 2026) : Alignement de Distribution des Blendshapes (BDA) pour mapper les plages d'activation de blendshape par sujet vers l'espace canonique. Évalué sur les données S01 pour déterminer si les faibles niveaux d'activation observés en phase 2 sont traitables par une calibration légère par sujet.
6. **Comparaison des frameworks rPPG** : sorties BPM de pyVHR (CHROM/POS), rPPG-Toolbox (PhysNet, EfficientPhys) et l'implémentation autonome comparées contre la vérité terrain de la montre connectée. Gains d'accélération GPU des conteneurs Docker rapportés séparément.
7. **Alternatives au mécanisme VETO** : évaluation d'un supprimeur multiplicatif doux et de conceptions VETO temporel conscient du contexte, remplaçant l'approche par seuil qui a montré zéro valeur en phase 2.
8. **Annotation multi-sujets et validation des formules** : annotation de vérité terrain v2 de vidéos éligibles supplémentaires et d'un deuxième sujet, permettant une validation inter-sujets de la formule candidate F2.

Toutes les expériences de la phase 3 nécessitant une vérité terrain validée par montre connectée sont conditionnées à la disponibilité du matériel (attendue fin avril 2026). L'absence de matériel de référence cardiaque est la principale limitation technique pour l'évaluation rPPG à ce stade ; cela est documenté comme risque projet actif et peut affecter le calendrier d'achèvement de la phase 3.

Bibliographie

- Abdeldayem, M. A., Hamed, H. F. A., & Nagy, A. M. (2026). Facial expression recognition: A survey of techniques, datasets, and real-world challenges. *Statistics, Optimization and Information Computing*, 15, 733–761.
- Acharya, B., Saakyan, W., Hammer, B., & Drimalla, H. (2025). The reliability of remote photoplethysmography under low illumination and elevated heart rates. *npj Digital Medicine*.
- Alqahtani, N., Shaikh, A., & Keerio, I. K. (2025). Robust detection of partially occluded faces in low-light scenarios using YOLOv7 and YOLOv6. *International Journal of Advanced Computer Science and Applications (IJACSA)*, 16(11).
- Gutiérrez, R., Villegas-Ch, W., & Luján-Mora, S. (2025). Implementing federated learning for privacy-preserving emotion detection in educational environments. *Frontiers in Artificial Intelligence*, 8, 1644844.
- Hossan, M. M., Tasnim, R. A., & Eishita, F. Z. (2025). Can you keep calm?: Adaptive gameplay using heart rate as a controller. In *2025 Intermountain Engineering, Technology and Computing (IETC)*: IEEE.
- Kopalidis, T., Solachidis, V., Vretos, N., & Daras, P. (2024). Advances in facial expression recognition: A survey of methods, benchmarks, models, and datasets. *Information*, 15(3), 135.
- Moghimi, M. & Grailu, H. (2024). General ROI selection approach in rPPG for accurate heart rate estimation. *Journal of Electrical Systems*, 20(3), 4445–4456.
- Moschovitis, P. & Denisova, A. (2022). Keep calm and aim for the head: Biofeedback-controlled dynamic difficulty adjustment in a horror game. *IEEE Transactions on Games*, 15(3), 368–377.
- Savchenko, A. V. (2025). HSEmotion team at ABAW-8 competition: Audiovisual ambivalence/hesitancy, emotional mimicry intensity and facial expression recognition. *arXiv preprint arXiv:2503.10399*.
- Shao, H., Luo, L., Qian, J., Yan, M., Chen, S., & Yang, J. (2025). Remote photoplethysmography in real-world and extreme lighting scenarios. *arXiv preprint arXiv:2503.11465*.
- Wang, W., den Brinker, A. C., Stuijk, S., & de Haan, G. (2017). Algorithmic principles of remote PPG. *IEEE Transactions on Biomedical Engineering*, 64(7), 1479–1491.
- Yang, S., Yoon, B., Kang, S., Song, H., & Woo, W. (2026). OFERA: Blendshape-driven 3D gaussian control for occluded facial expression to realistic avatars in VR. *arXiv preprint arXiv:2602.01748*.