

T.C GALATASARAY ÜNİVERSİTESİ
MÜHENDİSLİK VE TEKNOLOJİ FAKÜLTESİ

DUYUŞSAL OYUN TASARIMINDA UYARLAMALI DÜŞMAN
YAPAY ZEKASI İÇİN GERÇEK ZAMANLI DUYGU ANALİZİ

**(La Façade Fissurée : Analyse des Émotions en Temps Réel
pour l'IA Adaptative dans la Conception de Jeux Affectifs)**

2^e RAPPORT INTERMÉDIAIRE

Ali Burak SARAÇ

21401932

Bölüm : BİLGİSAYAR MÜHENDİSLİĞİ

Danışman : Dr. Öğr. Üyesi Reis Burak Arslan

AVRIL 2026

Table des Matières

Table des Matières	i
Liste des Figures	iii
Liste des Tableaux	iv
1 PREMIERS RÉSULTATS	1
1.1 Comparaison des Outils FER (Hôte)	1
1.2 Benchmark des Formules de Peur	2
1.2.1 Phase 2 : Évaluation Mono-Sujet (Video05_S02)	2
1.2.2 Phase 3 : Évaluation Multi-Sujets Multi-Formules	4
1.3 Évaluation des Blendshapes MediaPipe	7
1.4 Résultats rPPG	10
1.4.1 Phase 2 : Vérification de Faisabilité	10
1.4.2 Phase 3 : Sessions Pilotes avec Vérité Terrain par Montre Connectée	10
1.5 Méthodologie d'Annotation	13
1.6 Résultats Clés et Implications de Conception	14
1.6.1 Évaluation des Formules de Peur	14
1.6.2 Mécanisme VETO	15
1.6.3 Faisabilité et Limitations du rPPG	15
1.6.4 Méthodologie d'Annotation	15
1.6.5 Architecture de Détection Hybride	16
1.7 Statut de l'Implémentation du Jeu Unity	17
1.8 Résultats de Détection Faciale	19
2 ANALYSE DES RÉSULTATS, PREMIÈRES IMPRESSIONS ET VÉRIFICATION	20
2.1 HSEmotion vs MediaPipe : Analyse Comparative	20
2.2 Analyse du Signal rPPG	22
2.3 Impressions sur le Design Expérimental	24
2.4 Vérification : Architecture du Pipeline	25

3	PROBLÈMES RENCONTRÉS ET SOLUTIONS PROPOSÉES	26
3.1	Généralisation Inter-Sujets de MediaPipe	26
3.2	Verrouillage FFT Demi-Harmonique du rPPG	27
3.3	Délai de Matériel de Vérité Terrain rPPG	28
3.4	Dépendance Circulaire dans l'Annotation de Vérité Terrain	29
3.5	Détection Faciale en Faible Luminosité	29
3.6	Panne Matérielle	30
3.7	Complexité du Code Source	31
4	MÉTRIQUES DE PERFORMANCE ET MÉTHODES D'ÉVALUATION	32
4.1	Méthodologie de Vérité Terrain	32
4.2	Métriques d'Évaluation FER	33
4.3	Métriques d'Évaluation rPPG	35
4.4	Métriques de Performance Système	35
4.5	Infrastructure d'Évaluation	36
	Bibliographie	38

Liste des Figures

1.1	Architecture modulaire rPPG — six modules à responsabilité unique . . .	12
1.2	Machine à états finis ennemie à quatre états	18
2.1	Architecture du pipeline phase 3 — mp_tension comme modificateur (pointillé), rPPG comme canal indépendant	25

Liste des Tableaux

1.1	Résultats du benchmark des formules de peur (Video05_S02, discrimination peur/colère)	3
1.2	Douze formules composites candidates de peur (F0–F11)	4
1.3	Résultats de détection combinés sur trois sessions — meilleure configuration par formule	5
1.4	Résultats de détection par session — F1, F7 et F8 aux paramètres optimaux combinés	7
1.5	Top 5 des configurations de tension MediaPipe — balayage combiné sur 3 sessions	8
1.6	Précision des algorithmes rPPG — Pilot 01 (extracteur MediaPipe, $n = 53$ fenêtres)	11
1.7	Événements de vérité terrain par session	14
4.1	Budget de latence du pipeline (valeurs mesurées en phase 3)	36

1 PREMIERS RÉSULTATS

Les résultats de ce chapitre couvrent deux phases du projet. Les Sections 1.1–1.4.1 présentent les résultats de phase 2 basés sur un seul sujet (S02) et une seule vidéo (Video05, 197 s). La phase 3 a considérablement élargi l'évaluation : trois sujets (S02, S06, S08) sous différentes conditions d'éclairage (sombre, lumineux, mixte), douze formules candidates (F0–F11), quatre-vingt-une configurations de tension MediaPipe, et deux sessions pilotes rPPG avec vérité terrain par montre connectée.

1.1 COMPARAISON DES OUTILS FER (HÔTE)

Les résultats de phase 2 effectués en conditions contrôlées sur la machine hôte Windows révèlent un problème central : les seuils de blendshape *Action Unit* publiés par MediaPipe sont calibrés sur des données démographiques larges et ne se généralisent pas aux sujets individuels.

Pour le participant S01 au cours d'une session neutre, aucun des blendshapes liés à la peur n'a atteint le seuil d'activation (p. ex., les valeurs maximales observées étaient de 0,22 pour *eyebrows_inner_raise*, bien en dessous du seuil typiquement utilisé de 0,5). En contraste, une session de stress (test visuel avec vidéo) a produit des blendshapes augmentés cohérents avec les états affectifs anticipés.

L'évaluation multi-sujets de phase 3 (Section 1.3) a confirmé et quantifié ces observations sur trois sujets : l'activation des blendshapes reste structurellement éparse, avec des valeurs au 95e percentile bien en dessous des seuils requis pour une détection autonome fiable. Cependant, la phase 3 a également révélé que la tension MediaPipe contribue de manière significative lorsqu'elle est utilisée comme *modificateur* des scores HSEmotion plutôt que comme signal indépendant (Section 1.2.2).

Il reste à déterminer si ces faibles activations reflètent une variation physiologique réelle, les conditions d'enregistrement, ou la sensibilité de calibration démographique de Medi-aPipe. Yang et al. (2026) proposent l'Alignement de Distribution des Blendshapes (BDA), une étape de calibration légère (<1 ms) qui mappe la plage de blendshape d'un individu vers un espace canonique par régression linéaire ; cette approche reste une candidate pour les travaux futurs afin de traiter la variabilité d'activation inter-sujets.

La justification de la sélection des outils et les comparaisons de latence sont documentées dans le chapitre Analyse de Coûts.

1.2 BENCHMARK DES FORMULES DE PEUR

1.2.1 Phase 2 : Évaluation Mono-Sujet (Video05_S02)

Méthodologie : Sept formules candidates (F0–F6) ont été évaluées systématiquement contre une vérité terrain manuelle sur Video05_S02 (197 s). La vérité terrain comportait 9 événements de peur annotés manuellement et 5 événements d'erreur de contrôle (colère/confusion) servant de négatifs de contraste. L'évaluation s'est déroulée en deux phases : la Phase A a balayé l'ensemble des combinaisons formule–graine ($7 \times 10 = 70$ exécutions) pour sélectionner les meilleures paires ; la Phase B a évalué les 3 formules et 3 graines retenues sur l'ensemble des configurations VETO ($3 \times 3 \times 5 = 45$ exécutions), pour un total de 115 exécutions d'essai.

Note : Ces résultats sont basés sur les timings v1 auto-détectés. Le modèle d'annotation v2 a été préparé mais pas encore utilisé à ce stade. Ces résultats constituent une évaluation de premier passage ; la validation multi-sujets et multi-sessions est présentée en Section 1.2.2.

Métrique primaire : Ratio de discrimination peur/colère au niveau de la trame. Objectif : $>3,0\times$.

Les résultats du benchmark des formules sont résumés au Tableau 1.1.

Tableau 1.1: Résultats du benchmark des formules de peur (Video05_S02, discrimination peur/colère)

ID Formule	Peur Moy.	Colère Moy.	Ratio	Statut
F0_CURRENT	0.42	0.32	1.3×	CASSÉ
F1_FEAR_TENSION	0.68	0.12	5.5×	Ratio maximal
F2 (Candidate)	0.55	0.14	4.0×	Candidat principal
F3_FEAR_HEDGED	0.48	0.19	2.5×	À évaluer
F4_BALANCED	0.51	0.17	3.0×	À évaluer
F5_SOFT_AROUSAL	0.46	0.21	2.2×	À évaluer
F6_SOFT_VETO	0.61	0.06	9.5×	Extrême

Résultats : La formule F0 (basée sur l’arousal) n’atteint que 1,3×, proche du hasard. La formule candidate F2 atteint 4,0×, dépassant l’objectif de 3,0×. L’inclusion de la composante *hs_surprise* est soutenue par Abdeldayem et al. (2026), qui documentent que la peur (AU 1+2+4) et la surprise (AU 1+2+5) ne diffèrent que par l’AU 4 (froncement) versus l’AU 5 (élévation de la paupière supérieure), entraînant une confusion systématique peur–surprise à travers les benchmarks FER.

Résultats VETO : À travers les 45 configurations de Phase B, aucune configuration VETO n’a amélioré le score F1 par rapport à la référence sans VETO. Le VETO de référence (V1) a supprimé 3 vrais positifs tout en capturant 0 faux positifs — un bilan net négatif.

1.2.2 Phase 3 : Évaluation Multi-Sujets Multi-Formules

La phase 3 a élargi l'évaluation de sept formules (F0–F6) à douze formules (F0–F11), introduisant des références d'ablation et des combinaisons non linéaires. L'évaluation a utilisé trois sessions enregistrées avec différents sujets sous différentes conditions d'éclairage, avec une vérité terrain annotée indépendamment (50 événements de peur au total ; voir Section 1.5). Un détecteur d'événements par fenêtre glissante a remplacé la métrique de ratio au niveau de la trame de la phase 2, produisant des scores de Précision, Rappel et F1 au niveau événementiel. Le Tableau 1.2 liste les douze formules.

Tableau 1.2: Douze formules composites candidates de peur (F0–F11)

ID	Label	Composition
F0	weighted	$0.5 \cdot hs_fear + 0.3 \cdot mp_tension + 0.2 \cdot hs_surprise$
F1	multiplicative	$hs_fear \times (1 + mp_tension)$
F2	equal-weight	$0.4 \cdot hs_fear + 0.4 \cdot mp_tension + 0.2 \cdot hs_surprise$
F3	fear-dominant	$0.6 \cdot hs_fear + 0.25 \cdot mp_tension + 0.15 \cdot hs_surprise$
F4	simple-sum	$hs_fear + mp_tension$
F5	no-surprise	$0.7 \cdot hs_fear + 0.3 \cdot mp_tension$
F6	surprise-blend	$0.5 \cdot (hs_fear + hs_surprise) + 0.3 \cdot mp_tension$
F7	hs-only	hs_fear
F8	mp-only	$mp_tension$
F9	max-fusion	$\max(hs_fear, mp_tension)$
F10	geometric-mean	$\sqrt{hs_fear \times mp_tension}$
F11	anger-suppress	$hs_fear - 0.6 \cdot hs_anger$

Le Tableau 1.3 présente les résultats combinés agrégés sur les trois sessions aux paramètres de détection optimisés individuellement pour chaque formule.

Tableau 1.3: Résultats de détection combinés sur trois sessions — meilleure configuration par formule

ID	Label	Précision	Rappel	F1
F0	weighted	50.00%	70.00%	0.5833
F1	multiplicative	82.50%	66.00%	0.7333
F2	equal-weight	84.62%	22.00%	0.3492
F3	fear-dominant	86.11%	62.00%	0.7209
F4	simple-sum	60.00%	66.00%	0.6286
F5	no-surprise	90.62%	58.00%	0.7073
F6	surprise-blend	85.71%	60.00%	0.7059
F7	hs-only	75.56%	68.00%	0.7158
F8	mp-only	7.02%	8.00%	0.0748
F9	max-fusion	75.56%	68.00%	0.7158
F10	geometric-mean	100.00%	18.00%	0.3051
F11	anger-suppress	74.47%	70.00%	0.7216

Résultats clés :

1. **F1 (multiplicative) est la candidate actuelle principale** avec le F1 combiné le plus élevé de 0,7333 à une Précision de 82,50 % et un Rappel de 66,00 %. Son design multiplicatif ($hs_fear \times (1 + mp_tension)$) utilise `mp_tension` comme amplificateur de signal : lorsque HSEmotion et MediaPipe s'accordent sur un moment lié à la peur, le score composite est amplifié ; lorsqu'un seul se déclenche, `hs_fear` seul pilote la détection sans fausse amplification.
2. **F2 (candidate de phase 2) a échoué** en fusion à poids égaux ($F1 = 0,3492$). Attribuer 40 % de poids à `mp_tension` fait dépendre la formule d'un signal qui s'active rarement (Section 1.3), effondrant le rappel à 22 %.
3. **F7 (hs_fear seul)** atteint un $F1 = 0,7158$ — compétitif mais systématiquement inférieur au 0,7333 de F1. Cet écart de 1,75 point de pourcentage, bien que modeste, est constant à travers les configurations de tension (Section 1.3).
4. **F8 (mp_tension seul)** atteint un $F1 = 0,0748$, confirmant que la tension MediaPipe n'est pas viable comme signal de peur autonome.
5. **F3 (fear-dominant)** atteint un $F1 = 0,7209$ avec la précision la plus élevée parmi les formules compétitives (86,11 %), ce qui en fait une candidate pour les applications où le coût des faux positifs est élevé.

Le Tableau 1.4 montre les résultats par session pour les trois formules clés à leurs paramètres optimaux combinés (seuil = 0,4, `min_frames` = 5, `fenêtre` = 15, `fill_ratio` = 65 %).

Lorsque chaque formule est évaluée à ses propres paramètres optimaux par session, `hs_fear` atteint des valeurs F1 absolues plus élevées : 0,8085 (S02, seuil = 0,55), 0,7407 (S08, seuil = 0,55) et 0,7200 (S06, seuil = 0,60). Cependant, les formules intégrant `mp_tension` surpassent systématiquement la référence HSEmotion seul à paramètres équivalents : le balayage de tension MediaPipe (Section 1.3) montre des gains de 12 à 19 points de pourcentage par session.

Tableau 1.4: Résultats de détection par session — F1, F7 et F8 aux paramètres optimaux combinés

Session	Éclairage	GT	F1 (mult.)	F7 (hs)	F8 (mp)
S02_Vid04	sombre	21	0.8372	0.6780	0.0000
S08_Vid18	mixte	13	0.6667	0.5946	0.1429
S06_Vid16	lumineux	16	0.6087	0.5600	0.0370
Combiné	—	50	0.7333	0.6281	0.0449

Statut de recommandation : $F1(hs_fear \times (1 + mp_tension))$ est la candidate actuelle principale. L’hypothèse que `mp_tension` fournit un apport constant comme modificateur multiplicatif nécessite une validation sur des sujets et conditions d’éclairage supplémentaires. L’espace de formules reste ouvert ; des formules additionnelles exploitant `mp_tension` dans des rôles de modificateur similaires sont planifiées.

1.3 ÉVALUATION DES BLENDSHAPES MEDIAPIPE

La phase 3 a mené une évaluation systématique de la tension des blendshapes MediaPipe comme signal de détection de peur, testant 81 configurations de tension (9 variantes de formule $\times$ 9 réglages de gain AGC) sur les trois sessions. Chaque configuration a été évaluée avec les douze formules, produisant $81 \times 12 \times 3 = 2916$ évaluations individuelles.

Performance autonome : La tension MediaPipe seule (F8) atteint un F1 combiné de 0,0748, avec des scores par session de 0,0000 (S02), 0,1429 (S08) et 0,0370 (S06). Même à sa meilleure configuration par session, le F1 le plus élevé atteint 0,2222 (S02, v4 s=2.2 noAGC) et 0,3810 (S08, v4 s=2.0 noAGC). Ces résultats confirment que `mp_tension` n’est pas viable comme signal de détection autonome.

Performance comme modificateur : En revanche, lorsque `mp_tension` est utilisé comme modificateur dans les formules combinées, il fournit une amélioration constante par rapport à HSEmotion seul. Le Tableau 1.5 montre les cinq meilleures configurations de tension du balayage combiné, classées par leur formule la plus performante.

Tableau 1.5: Top 5 des configurations de tension MediaPipe — balayage combiné sur 3 sessions

Config. tension	Gain	Meilleure formule	Meilleur F1	F7 (hs)
v4 (s=1.6, j=0.20)	noAGC	F1	0.7416	0.6281
v5c (s=1.8)	noAGC	F3	0.7312	0.6281
v5e (s=1.8)	noAGC	F3	0.7312	0.6281
v4 (s=1.4, j=0.20)	noAGC	F1	0.7273	0.6281
v4 (s=1.6, j=off)	noAGC	F1	0.7253	0.6281

Sur les 81 configurations, la meilleure formule intégrant `mp_tension` surpasse F7 (hs_fear seul, F1 = 0,6281) de 10 à 11 points de pourcentage. Les gains par session sont encore plus prononcés :

- S02 : meilleure formule incluant MP, F1 = 0,8571 vs. F7 = 0,6780 (**+17,9 pp**)
- S08 : meilleure formule incluant MP, F1 = 0,7200 vs. F7 = 0,5946 (**+12,5 pp**)
- S06 : meilleure formule incluant MP, F1 = 0,7500 vs. F7 = 0,5600 (**+19,0 pp**)

Causes profondes de l'échec autonome : L'analyse des blendshapes sur trois sujets révèle des limitations structurelles pour une utilisation autonome :

- **Plancher d'activation :** les blendshapes critiques pour la peur (*eyeWideLeft*, *eyeWideRight*) présentent des valeurs médianes de 0,001–0,004 selon les sujets, avec des valeurs au 95e percentile de 0,003–0,054 — bien en dessous du seuil de 0,30 requis pour la détection binaire.
- **Parcimonie temporelle :** même durant les événements de peur annotés, les activations des blendshapes sont brèves et intermittentes, produisant peu de trames consécutives au-dessus du seuil.
- **Morphologie au repos :** la géométrie faciale propre à chaque sujet crée des décalages de base dans certains blendshapes qui confondent la détection par seuil.

Conclusion : La tension des blendshapes MediaPipe n'est pas viable comme signal autonome de détection de peur mais fournit un apport constant et significatif lorsqu'elle est utilisée comme modificateur des scores HSEmotion. Cette découverte — que `mp_tension` fonctionne comme amplificateur plutôt que comme détecteur indépendant — n'avait pas été anticipée dans le design de phase 2, qui traitait MediaPipe et HSEmotion comme des signaux potentiellement interchangeables. L'évaluation de phase 3 a initialement conduit à une décision préliminaire de retirer entièrement `mp_tension` de la formule composite ; cependant, une évaluation ultérieure avec un outillage corrigé a inversé cette conclusion. L'hypothèse du modificateur nécessite une validation supplémentaire avec davantage de sujets et de variantes de formules, planifiée pour la phase finale d'évaluation.

1.4 RÉSULTATS RPPG

1.4.1 Phase 2 : Vérification de Faisabilité

Test préliminaire CHROM : L'algorithme CHROM autonome a été appliqué sur Video05_S02 (197 s). Un ROI frontal unique a été défini manuellement ; les valeurs RGB ont été extraites par moyenne spatiale des pixels de la région. Une fenêtre glissante (30 s) avec un chevauchement de 83 % et un pas de 5 s a été appliquée.

Résultat indicatif : **58,5 BPM**, avec les 34 fenêtres produisant des estimations dans la plage physiologiquement plausible (40–120 BPM). Ces valeurs n'ont pas été validées contre une référence cardiaque indépendante ; elles constituent une indication de plausibilité uniquement. Wang et al. (2017) comparent sept algorithmes rPPG sur 60 vidéos dans quatre conditions, classant POS au-dessus de CHROM en SNR global (5,16 dB contre 3,86 dB pour CHROM).

Test de fusion multi-algorithmes : Trois algorithmes exécutés simultanément sur Video05_S02 ont produit des estimations proches : CHROM 55,0, POS 58,0, GREEN 53,7 BPM — toutes dans la plage plausible, confirmant la faisabilité opérationnelle.

1.4.2 Phase 3 : Sessions Pilotes avec Vérité Terrain par Montre Connectée

La phase 3 a acquis une montre connectée Amazfit Active 2 pour fournir une vérité terrain cardiaque indépendante. Les données de rythme cardiaque sont exportées via l'application compagnon Zepp sous forme de fichiers TCX d'entraînement avec une résolution HR de 1 seconde. Deux sessions pilotes ont été menées en conditions contrôlées (éclairage ambiant, position assise, exercices de respiration inclus) :

- **Pilot 01** (session 20260502_162448) : 53 fenêtres de mesure, extraction faciale Haar et MediaPipe testées
- **Pilot 02** (session 20260502_200546) : 22 fenêtres de mesure, extraction MediaPipe

Le Tableau 1.6 présente la précision des algorithmes pour le Pilot 01 avec l'extracteur facial MediaPipe (53 fenêtres).

Tableau 1.6: Précision des algorithmes rPPG — Pilot 01 (extracteur MediaPipe, $n = 53$ fenêtres)

Algorithme	MAE (BPM)	RMSE	Pearson r	Biais
POS	22,75	28,95	+0,303	−22,06
ICA	27,30	33,34	−0,479	−25,80
GREEN	32,44	36,20	+0,586	−32,39
CONSENSUS	39,62	40,60	+0,448	−39,62
CHROM	47,18	48,34	−0,128	−47,18
WAVELET	50,14	51,75	+0,484	−50,14

POS atteint la MAE la plus faible (22,75 BPM) avec une corrélation positive modérée ($r = 0,303$), cohérent avec le classement de Wang et al.. Le Pilot 02 confirme POS comme meilleur algorithme (MAE = 22,20 BPM, $n = 22$). Le Pilot 01 a également été évalué avec l'extracteur par cascade de Haar : la MAE POS augmente à 27,18 BPM (taux de détection Haar 71,8 % vs. MediaPipe 99,9 %), démontrant que la qualité de détection faciale affecte la précision rPPG mais n'explique pas entièrement l'ampleur de l'erreur.

Verrouillage FFT demi-harmonique : Le résultat dominant des deux pilotes est la sous-estimation systématique du BPM. Tous les algorithmes présentent un biais négatif marqué (−22 à −50 BPM), cohérent avec la sélection FFT d'un pic sous-harmonique à approximativement la moitié de la fréquence fondamentale cardiaque ($\sim 0,75$ Hz au lieu de $\sim 1,5$ Hz). Ce verrouillage demi-harmonique est l'obstacle principal à l'intégration du rPPG dans le score composite de peur.

L'analyse de la cause racine indique un rapport signal-sur-bruit (SNR) insuffisant à la fréquence cardiaque : le spectre de puissance FFT contient un pic à la fondamentale cardiaque, mais un pic plus fort apparaît à approximativement la moitié de cette fréquence, probablement dû à la modulation respiratoire ou aux artefacts de mouvement. Les mitigations proposées — désambiguïsation par pic $2\times$, ajustement du plancher BPM de 42 à 60 BPM, et sessions de calibration au repos — ont été conçues mais pas encore implémentées (voir Chapitre 3).

Tests supplémentaires planifiés : Au-delà des sessions validées par montre connectée, le pipeline sera testé sur des vidéos continues de gameplay YouTubeur où aucune vérité terrain PPG n'existe. Dans cette configuration, la vérité terrain FER pour les moments de peur sera utilisée pour tester la corrélation cross-modale : si les changements du signal rPPG (élévation du rythme cardiaque) coïncident avec les événements de peur détectés par le FER. Cette approche de validation cross-modale complète l'évaluation directe de la précision cardiaque.

Architecture modulaire rPPG : La phase 3 a restructuré le code rPPG en six modules à responsabilité unique, remplaçant les scripts monolithiques de la phase 2 :




Figure 1.1: Architecture modulaire rPPG — six modules à responsabilité unique

1.5 MÉTHODOLOGIE D'ANNOTATION

L'annotation de vérité terrain a évolué à travers trois itérations avant d'atteindre la méthodologie utilisée en phase 3 :

1. **v1 (auto-déTECTÉE)** : Les événements étaient détectés par la formule F0 comme détecteur de pics, avec des fenêtres de 6 secondes autour des pics détectés. Cela introduisait une dépendance circulaire : le benchmark évaluait les formules contre une vérité terrain générée par l'une des formules candidates (F0), biaisant l'évaluation contre les formules détectant des événements manqués par F0.
2. **v2 (horodatages manuels)** : Un modèle ajoutait des colonnes manuelles `start_s/end_s` pour que l'annotateur enregistre les limites d'événements indépendamment de toute formule. Bien que cela élimine la dépendance circulaire, le modèle contenait encore des champs de métadonnées dérivés de formules risquant d'influencer le jugement de l'annotateur.
3. **v3 (XLSX avec métadonnées)** : Un modèle élargi avec 12 champs de métadonnées par événement. Bien que plus structuré, le processus de raffinement itératif a été abandonné lorsqu'il est apparu que la revue directe des vidéos sources produisait des limites d'événements plus fiables que toute approche guidée par modèle.

Méthodologie finale : Toutes les évaluations de phase 3 utilisent des tables de vérité terrain événementielles créées manuellement. L'annotateur a revu indépendamment chaque vidéo source sans accès aux sorties d'aucune formule, enregistrant les limites des événements de peur sur la seule base des expressions faciales visibles et des indices contextuels du contenu vidéo. Cette approche a éliminé à la fois la dépendance circulaire de v1 et les biais induits par les modèles v2/v3.

Un total de 50 événements de peur ont été annotés sur les trois sessions, avec 17 événements supplémentaires exclus du scoring (labels non-peur tels que `slight_fear`, `anger`, `disgust`, `laughter`, et segments `obscured/side_profile`). Les événements exclus sont conservés dans les fichiers d'annotation pour l'analyse mais ne contribuent pas aux calculs de Précision, Rappel ou F1.

Tableau 1.7: Événements de vérité terrain par session

Session	Éclairage	Événements peur	Exclus	Labels d'exclusion
S02_Vid04	sombre	21	11	slight_fear, anger, disgust, obscured
S08_Vid18	mixte	13	5	laughter, obscured
S06_Vid16	lumineux	16	1	slight_fear
Total	—	50	17	—

1.6 RÉSULTATS CLÉS ET IMPLICATIONS DE CONCEPTION

1.6.1 Évaluation des Formules de Peur

Le benchmark de phase 2 a établi que les formules basées sur l'arousal (F0) sont inadaptées à la détection de la peur en raison du chevauchement de l'arousal entre peur et colère dans le modèle circomplexe. La formule candidate F2 de phase 2 a atteint un ratio de discrimination peur/colère de 4,0×.

L'évaluation multi-sujets de phase 3 avec le scoring F1 au niveau événementiel a supplanté ce résultat. La fusion à poids égaux de F2 (40 % *mp_tension*) s'effondre sous l'évaluation inter-sujets (F1 combiné = 0,3492) car les activations de *mp_tension* sont trop éparses pour soutenir une part de 40 % du composite. La formule multiplicative F1 ($hs_fear \times (1 + mp_tension)$) atteint le meilleur F1 combiné de 0,7333 en utilisant *mp_tension* comme amplificateur plutôt que comme composante à poids égal. La composante *hs_surprise* de F2 n'est pas présente dans F1 ; la question de savoir si sa réintroduction sous forme multiplicative améliorerait la détection reste ouverte pour les futures formules.

1.6.2 Mécanisme VETO

Les approches VETO identifiées en phase 2 (suppresseur multiplicatif doux, VETO temporel conscient du contexte) n'ont pas été poursuivies en phase 3. Le passage de la fusion à poids égaux (F2) au modificateur multiplicatif (F1) a éliminé le conflit cross-modal que les VETOs devaient résoudre : dans F1, *mp_tension* ne peut qu'amplifier *hs_fear*, jamais le supplanter. Avec un seul signal primaire pilotant la détection, l'architecture VETO n'est plus nécessaire sous le design de formule actuel.

1.6.3 Faisabilité et Limitations du rPPG

La phase 2 a confirmé la faisabilité opérationnelle (58,5 BPM CHROM, toutes les fenêtres plausibles). Les sessions pilotes de phase 3 avec vérité terrain par montre connectée ont révélé que le meilleur algorithme (POS) atteint une MAE = 22,75 BPM — bien au-dessus du seuil de 5 BPM requis pour une détection d'affect cardiaque significative. Le verrouillage FFT demi-harmonique (sous-estimation systématique à GT/2) est la source d'erreur dominante. Le rPPG opère actuellement comme canal de validation indépendant en arrière-plan, préservant la voie architecturale vers la fusion directe si la précision s'améliore (voir chapitre Conception Conceptuelle, section intégration rPPG).

1.6.4 Méthodologie d'Annotation

L'évolution de la vérité terrain automatisée (v1) à la vérité terrain manuelle événementielle a éliminé la dépendance circulaire qui biaisait les résultats de phase 2. Le corpus de 50 événements sur trois sujets et conditions d'éclairage fournit une base pour l'évaluation inter-sujets, bien que des sujets supplémentaires soient nécessaires avant qu'une formule puisse être considérée comme validée pour le déploiement.

1.6.5 Architecture de Détection Hybride

L'approche hybride de détection faciale Haar + MediaPipe a amélioré la couverture faciale pour HSEmotion de 30,4 % (cascade de Haar seule) à 99,9 %. L'équivalence $r = 0,935$ entre les scores HSEmotion recadrés par Haar et par MediaPipe valide que le changement de backend de détection n'introduit pas d'artefacts de classification. La comparaison rPPG pilote (MAE POS : 27,18 BPM Haar vs. 22,75 BPM MediaPipe) confirme en outre que le taux de détection supérieur de MediaPipe bénéficie au traitement en aval.

1.7 STATUT DE L'IMPLÉMENTATION DU JEU UNITY

La phase 3 a produit un prototype fonctionnel de jeu d'horreur 3D à la première personne dans Unity 2022.3 LTS avec Universal Render Pipeline (URP), implémenté en 4 commits totalisant 177 fichiers et +20 157 lignes de code. Le développement du jeu a ensuite été reporté en raison d'une panne matérielle (voir Chapitre 3, Section 3.6) ; l'accent s'est déplacé vers les améliorations de précision des pipelines FER et rPPG.

Systèmes fondamentaux implémentés :

- **SocketManager** : client TCP sur localhost:5005 recevant l'état affectif du pipeline
- **AffectiveState** : charge utile structurée (composite_fear, valence, BPM, confiance)
- **AffectiveSmoothing** : moyenne mobile exponentielle avec calcul de delta et calibration de référence
- **SessionLogger** : journalisation CSV par trame à 26 colonnes avec file d'événements pour les événements de jeu
- **BenchmarkHUD** : superposition de débogage en temps réel pour les valeurs du pipeline durant le développement

Infrastructure expérimentale :

- **ParticipantFlowManager** : cycle de vie du participant en 7 états (Accueil → Consentement → Profil → Calibration → Sélection condition → Jeu → Fin)
- **CalibrationSystem** : collecte de référence déguisée en « Scan de sécurité » pour éviter de révéler l'objectif de la caméra
- **ConsentScreen / ConditionSelect** : interface du protocole expérimental avec support d'aveuglement du participant (symboles de cartes pour les conditions A/B)

IA Ennemie : La classe de base `EnemyStateMachine` implémente une machine à états finis à quatre états :




Figure 1.2: Machine à états finis ennemie à quatre états

La sous-classe `WandererEnemy` implémente le câblage Condition A (IA fixe) et Condition B (IA pilotée par biofeedback) : en Condition B, la sensibilité de transition `WANDER`→`ALERT` varie avec le `DeltaCompositeFear` de `AffectiveSmoothing`.

Intégration pipeline en direct : La latence de bout en bout a été vérifiée à ~ 53 ms (capture 33 ms + détection 9 ms + `HSEmotion` 10 ms + formule < 1 ms + socket 1 ms), bien dans le budget temps réel de 200 ms. TCP a été sélectionné plutôt qu'UDP pour une livraison fiable et ordonnée.

Statut actuel : Le développement du jeu est reporté. Le prototype valide l'intégration architecturale entre le pipeline affectif Python et Unity ; la conception complète des niveaux et le développement du gameplay sont reprogrammés en attente du remplacement matériel et de la validation de la précision du pipeline.

1.8 RÉSULTATS DE DÉTECTION FACIALE

La stratégie hybride de détection faciale Haar + MediaPipe a été validée sur les trois sessions de phase 3 :

- **Cascade de Haar seule** : 30,4 % de taux de détection faciale en conditions sombres (S02_Vid04) — insuffisant pour un traitement FER/rPPG continu.
- **Hybride Haar + MediaPipe** : 99,9 % de taux de détection faciale sur toutes les sessions, incluant éclairage sombre (S02), lumineux (S06) et mixte (S08).
- **Équivalence des scores HSEmotion** : $r = 0,935$ entre les scores HSEmotion recadrés par Haar et par MediaPipe à 10 % de marge, confirmant que le changement de backend de détection n'introduit pas d'artefacts de classification.
- **Latence** : 24–28 ms par trame pour le pipeline hybride, donnant un taux de traitement effectif de 27–30 FPS.

Les détections Haar+MediaPipe et MediaPipe seul seront comparées pour leur impact sur la précision de classification HSEmotion dans les évaluations futures. Les preuves actuelles ($r = 0,935$ d'équivalence) suggèrent que la différence est minimale, mais une comparaison formelle sur des sujets supplémentaires est planifiée.

2 ANALYSE DES RÉSULTATS, PREMIÈRES IMPRESSIONS ET VÉRIFICATION

Ce chapitre interprète les résultats de la phase 3 présentés au Chapitre 1, analyse pourquoi certaines approches ont réussi ou échoué, et vérifie l’architecture actualisée du pipeline par rapport aux conceptions présentées dans les chapitres précédents.

2.1 HSEMOTION VS MEDIAPIPE : ANALYSE COMPARATIVE

L’évaluation de phase 3 révèle une asymétrie nette entre les deux outils FER : HSEmotion fonctionne comme un détecteur de peur autonome fiable tandis que la tension MediaPipe ne fonctionne pas — pourtant la combinaison surpasse chacun pris isolément.

HSEmotion (EfficientNet-B0, entraîné sur AffectNet) fournit une classification neuronale holistique, produisant des probabilités softmax à 8 classes par trame. Il capture les schémas faciaux globaux sans nécessiter de seuils individuels d’Action Units, le rendant intrinsèquement robuste aux variations morphologiques inter-sujets. En tant que signal autonome (F7), `hs_fear` atteint un F1 combiné de 0,7158 sur trois sujets — une performance constante sans calibration par sujet.

MediaPipe (52 blendshapes faciaux) extrait les activations individuelles d’Action Units nécessitant des décisions binaires par seuil. En tant que signal autonome (F8), `mp_tension` n’atteint qu’un F1 combiné de 0,0748. Les causes sont structurelles : les blendshapes critiques pour la peur (*eyeWideLeft*, *eyeWideRight*) présentent des activations médianes de 0,001–0,004, avec des valeurs au 95e percentile de 0,003–0,054 — bien en dessous du seuil de 0,30 requis pour la détection. Ces planchers d’activation varient selon les sujets en raison de la morphologie faciale au repos, produisant des décalages de base dépendants du sujet.

Performance combinée : Malgré l'échec autonome de MediaPipe, les formules utilisant `mp_tension` comme modificateur multiplicatif pour HSEmotion surpassent systématiquement HSEmotion seul. La formule candidate F1 ($hs_fear \times (1 + mp_tension)$) atteint un F1 combiné de 0,7333 — une amélioration de 1,75 point de pourcentage par rapport à F7. Les gains par session de la meilleure formule incluant MP sont plus substantiels : +17,9 pp (S02), +12,5 pp (S08) et +19,0 pp (S06).

Interprétation : Le design multiplicatif explique ces résultats. Lorsque `hs_fear` est proche de zéro (aucune peur détectée par HSEmotion), toute valeur de `mp_tension` est multipliée par approximativement zéro, empêchant les faux positifs. Lorsque `hs_fear` est élevé (peur détectée), même un modeste apport de `mp_tension` amplifie le signal au-dessus du seuil de détection. En pratique, MediaPipe capture des informations complémentaires de micro-expressions — tension des sourcils, serrement de mâchoire — qui confirment et renforcent la classification de HSEmotion lorsque les deux outils s'accordent sur un moment lié à la peur. Ce rôle complémentaire n'avait pas été anticipé dans le design de phase 2, qui traitait les deux outils comme des signaux potentiellement interchangeables.

Statut : L'hypothèse du modificateur nécessite une validation supplémentaire. La décision initiale de phase 3 de supprimer entièrement `mp_tension` (D-113) était basée sur une évaluation autonome avec un outillage qui a depuis été remanié. Une évaluation ultérieure a inversé cette conclusion ; cependant, les preuves actuelles ne couvrent que trois sujets. L'Alignement de Distribution des Blendshapes (BDA) de Yang et al. (2026) reste un candidat pour les travaux futurs : si la calibration par sujet peut élever les niveaux d'activation des blendshapes plus près du seuil, l'effet modificateur pourrait devenir encore plus fort.

2.2 ANALYSE DU SIGNAL RPPG

Les deux sessions pilotes fournissent la première évaluation quantitative du rPPG avec une vérité terrain cardiaque indépendante. Les résultats révèlent à la fois le potentiel et les limitations actuelles de l’approche rPPG.

Cause racine demi-harmonique : Le schéma d’erreur dominant pour les six algorithmes est une sous-estimation systématique du BPM, avec des valeurs de biais allant de -22 à -50 BPM. L’analyse des spectres de puissance FFT révèle que la fréquence fondamentale cardiaque ($\sim 1,5$ Hz pour un rythme cardiaque au repos de ~ 90 BPM) est en compétition avec un pic sous-harmonique à approximativement la moitié de cette fréquence ($\sim 0,75$ Hz). Lorsque le SNR à la fréquence cardiaque est insuffisant, la FFT sélectionne le sous-harmonique comme pic dominant, produisant des estimations à approximativement $GT/2$.

Bonnes fenêtres : Environ 30 à 40 % des fenêtres de mesure produisent des estimations à ± 10 BPM de la vérité terrain, indiquant que le signal de pouls cardiaque *est* présent dans les données RGB mais est masqué par le bruit dans les fenêtres restantes. Cela suggère qu’un filtrage par qualité de signal — ne conservant que les fenêtres à haut SNR — pourrait améliorer substantiellement la précision pour la détection de tendances, même si la précision absolue par fenêtre reste limitée.

Confondant des exercices respiratoires : Les deux sessions pilotes incluaient des exercices de respiration, introduisant un mouvement périodique du thorax et du visage à $0,2$ – $0,3$ Hz. Cette bande de fréquences chevauche la région sous-harmonique, renforçant potentiellement le verrouillage demi-harmonique. Les futures sessions devraient séparer les segments de repos de base des exercices de respiration pour isoler le confondant.

Comparaison des extracteurs : La détection faciale par cascade de Haar (taux de détection de 71,8 %) produit une MAE POS de 27,18 BPM, tandis que MediaPipe (99,9 %) atteint 22,75 BPM. L'amélioration de ~ 5 BPM grâce à une meilleure détection faciale est réelle mais éclipsée par l'erreur demi-harmonique systématique de ~ 22 BPM, confirmant que l'obstacle principal est la sélection du pic FFT plutôt que la qualité de l'extraction faciale.

Anomalie de corrélation GREEN : L'algorithme GREEN présente une discordance notable entre la corrélation de Pearson ($r = 0,586$ avec MediaPipe, la plus élevée parmi tous les algorithmes) et la MAE (32,44 BPM, troisième meilleure). Une corrélation élevée avec une MAE importante indique que GREEN suit les *tendances* cardiaques (variations relatives dans le temps) tout en opérant avec un décalage de fréquence systématique. Cette propriété pourrait rendre GREEN précieux pour les applications basées sur les tendances (par ex. détecter une augmentation du rythme cardiaque lors d'événements de peur) même si la précision BPM absolue est faible.

Statut opérationnel actuel : Le rPPG opère au Tier 2a de la stratégie de dégradation gracieuse (chapitre Conception de Haut Niveau) : le pipeline FER fonctionne à pleine capacité tandis que le rPPG fournit des données indépendantes en arrière-plan. L'intégration dans le score de peur composite est reportée jusqu'à ce que la précision descende sous ~ 5 BPM MAE.

2.3 IMPRESSIONS SUR LE DESIGN EXPÉRIMENTAL

L'expérience de jeu en simple aveugle à 2 conditions conçue en phase 2 a été validée lors du playtest Unity. La caméra reste toujours active, éliminant le biais comportemental lié à la conscience de la présence de la caméra qui affectait le design original à 3 conditions. La Condition A (IA fixe, symbole pique) et la Condition B (IA pilotée par biofeedback, symbole carreau) sont différenciées par des symboles de cartes pour maintenir l'aveuglement du participant. Le cadrage « Scan de sécurité » du CalibrationSystem collecte avec succès les données physiologiques de base sans révéler la finalité de la caméra.

Toutefois, le développement du jeu a été reporté en raison d'une panne matérielle (Chapitre 3, Section 3.6). La validation expérimentale se tourne désormais vers un protocole d'évaluation par vidéo :

- **Pool de sujets** : 8 à 12 sujets différents issus de vidéos de réaction YouTube regardant du contenu d'horreur.
- **Procédure** : Pour chaque sujet, la vidéo source est traitée par le pipeline FER. Les événements de peur sont annotés manuellement par revue directe de la vidéo. Les détections du pipeline sont évaluées par rapport à la vérité terrain manuelle.
- **Justification** : (a) les contraintes matérielles empêchent les sessions de jeu en direct ; (b) l'évaluation par vidéo permet de tester sur des sujets plus diversifiés avant de s'engager dans l'intégration au jeu ; (c) les vidéos de réaction contrôlées fournissent une vérité terrain révisable qui peut être affinée itérativement.

L'expérience de jeu à 2 conditions reste l'objectif expérimental à long terme. L'évaluation par vidéo sert de prérequis nécessaire : valider que le pipeline FER se généralise à des sujets diversifiés avant de le déployer dans un contexte de jeu en direct où la vérité terrain est plus difficile à établir.

2.4 VÉRIFICATION : ARCHITECTURE DU PIPELINE

La Figure 2.1 présente l'architecture du pipeline de phase 3, reflétant les changements depuis le design de phase 2 (documenté au chapitre Conception Technique).




Figure 2.1: Architecture du pipeline phase 3 — `mp_tension` comme modificateur (pointillé), rPPG comme canal indépendant

Changements clés par rapport à la phase 2 :

- **HSEmotion** fournit le signal de détection principal (`hs_fear`), représenté par une flèche pleine vers la formule composite.
- **MediaPipe** alimente `mp_tension` comme modificateur multiplicatif (flèche pointillée), et non comme entrée à poids égal.
- **rPPG** opère comme canal indépendant en arrière-plan (bordure pointillée), enregistrant les estimations cardiaques sans contribuer au score de peur composite.
- **TCP** remplace l'évaluation TCP/UDP — TCP a été retenu pour la livraison fiable.
- **Formule composite** : $F1 (hs_fear \times (1 + mp_tension))$ remplace F2.

Latence de bout en bout : Vérifiée à ~ 53 ms (capture 33 ms + détection faciale 9 ms + HSEmotion 10 ms + formule < 1 ms + socket 1 ms), bien en dessous du budget temps réel de 200 ms établi au chapitre Analyse de Coûts.

3 PROBLÈMES RENCONTRÉS ET SOLUTIONS PROPOSÉES

Ce chapitre documente les principaux obstacles techniques et logistiques rencontrés durant la phase 3, les solutions adoptées ou proposées, et leur statut actuel.

3.1 GÉNÉRALISATION INTER-SUJETS DE MEDIAPIPE

Problème : Les activations de blendshapes MediaPipe pour les Action Units critiques de la peur sont structurellement éparées entre les sujets. Les valeurs au 95e percentile pour *eyeWideLeft* et *eyeWideRight* vont de 0,003 à 0,054 selon les trois sujets évalués, bien en dessous du seuil de 0,30 requis pour une détection binaire. La morphologie faciale au repos propre à chaque sujet crée des décalages de base dans certains blendshapes, et même durant les événements de peur annotés, les activations sont brèves et intermittentes.

Preuves : 81 configurations de tension $\times$ 12 formules $\times$ 3 sessions = 2 916 évaluations individuelles. La meilleure formule MediaPipe seule (F8) atteint un F1 combiné de 0,0748, comparé à HSEmotion seul (F7) à 0,7158.

Solution : La phase 3 a initialement conclu que *mp_tension* devait être retiré de la formule composite (décision préliminaire D-113). L'évaluation ultérieure avec un outillage corrigé a révélé que bien que la performance autonome soit quasi nulle, *mp_tension* fournit un gain constant comme modificateur multiplicatif : la formule F1 (*hs_fear* $\times$ ($1 + mp_tension$)) atteint un F1 = 0,7333, surpassant HSEmotion seul. L'hypothèse du modificateur nécessite une validation supplémentaire avec des sujets additionnels.

Travaux futurs : L'Alignement de Distribution des Blendshapes (BDA) (Yang et al., 2026) — une étape de calibration légère par sujet (<1 ms) mappant les plages individuelles de blendshapes vers un espace canonique — est un candidat pour traiter la variabilité d'activation inter-sujets dans les futures évaluations.

3.2 VERROUILLAGE FFT DEMI-HARMONIQUE DU RPPG

Problème : La sélection du pic FFT identifie systématiquement un pic sous-harmonique à approximativement la moitié de la fréquence fondamentale cardiaque ($\sim 0,75$ Hz au lieu de $\sim 1,5$ Hz), causant un regroupement des estimations BPM autour de $GT/2$. Les six algorithmes implémentés présentent un biais négatif marqué (-22 à -50 BPM), le meilleur algorithme (POS) atteignant une $MAE = 22,75$ BPM.

Cause racine : Un rapport signal-sur-bruit (SNR) insuffisant à la fréquence cardiaque. Le spectre de puissance FFT contient des pics à la fois à la fondamentale et à son sous-harmonique, le sous-harmonique étant souvent plus fort en raison de la modulation respiratoire et des artefacts de mouvement. Les exercices de respiration durant les sessions pilotes (mouvement périodique du thorax/visage à $0,2\text{--}0,3$ Hz) pourraient renforcer le pic sous-harmonique.

Solutions proposées :

1. **Désambiguïsation par pic $2\times$:** Lorsqu'un pic est détecté à la fréquence f , vérifier si un pic existe à $2f$ dans la plage cardiaque plausible ($60\text{--}180$ BPM). Si oui, préférer le pic de fréquence supérieure.
2. **Ajustement du plancher BPM :** Relever la fréquence minimale détectable de 42 BPM ($0,7$ Hz) à 60 BPM ($1,0$ Hz), excluant la bande sous-cardiaque où la plupart des faux pics apparaissent.
3. **Sessions de repos de base :** Établir la plage HR attendue durant un segment de repos avant l'expérience, fournissant un a priori pour la sélection du pic.

Statut : Conçu mais pas encore implémenté. Ces mitigations sont planifiées pour la phase finale d'évaluation.

3.3 DÉLAI DE MATÉRIEL DE VÉRITÉ TERRAIN RPPG

Problème : Aucune référence cardiaque indépendante n'était disponible jusqu'à fin avril 2026, bloquant l'évaluation quantitative du rPPG tout au long de la phase 2 et du début de la phase 3. Tous les résultats rPPG antérieurs étaient de simples vérifications de plausibilité.

Solution : Une montre connectée Amazfit Active 2 a été acquise. Les données de rythme cardiaque sont exportées via l'application compagnon Zepp sous forme de fichiers TCX d'entraînement avec une résolution HR de 1 seconde (~ 900 échantillons par session de 15 minutes). Deux sessions pilotes ont été menées et évaluées avec succès (Chapitre 1, Section 1.4.2).

Limitation résiduelle : L'appairage BLE est exclusif à l'application Zepp, empêchant l'accès SDK direct pour le streaming HR en temps réel. La collecte de vérité terrain nécessite de démarrer une session d'entraînement Zepp séparément de l'expérience, puis d'aligner temporellement l'export TCX avec l'enregistrement rPPG.

3.4 DÉPENDANCE CIRCULAIRE DANS L'ANNOTATION DE VÉRITÉ TERRAIN

Problème : La première itération d'annotation (v1) utilisait la formule F0 comme détecteur de pics, avec des fenêtres de 6 secondes autour des pics détectés. Cela introduisait une dépendance circulaire : le benchmark évaluait les formules contre une vérité terrain générée par l'une des formules candidates (F0), biaisant les résultats contre les formules détectant des événements manqués par F0.

Solution : Amélioration itérative via v2 (horodatages manuels `start_s/end_s`) et v3 (XLSX avec 12 champs de métadonnées), finalement remplacés par des tables de vérité terrain événementielles entièrement manuelles. Chaque vidéo source annotée indépendamment sans accès aux sorties d'aucune formule, enregistrant les limites des événements de peur sur la seule base des expressions faciales visibles et des indices contextuels.

Statut : Résolu. Toutes les évaluations de phase 3 (50 événements de peur sur 3 sessions) utilisent une vérité terrain indépendante exempte de biais dérivé des formules.

3.5 DÉTECTION FACIALE EN FAIBLE LUMINOSITÉ

Problème : La cascade de Haar n'atteint que 30,4 % de taux de détection faciale en conditions sombres (S02_Vid04), insuffisant pour un traitement FER ou rPPG continu.

Solution : Stratégie de repli hybride Haar + MediaPipe FaceLandmarker. Lorsque Haar échoue, le maillage facial à 478 points de MediaPipe fournit un cadre de détection alternatif. L'approche hybride atteint 99,9 % de détection faciale sur les trois sessions de phase 3 (éclairage sombre, lumineux et mixte). L'équivalence des scores HSEmotion ($r = 0,935$) entre les entrées recadrées par Haar et par MediaPipe valide que le changement de backend de détection n'introduit pas d'artefacts de classification.

Statut : Résolu et validé sur trois sessions avec différentes conditions d'éclairage.

3.6 PANNE MATÉRIELLE

Problème : La machine de développement principale est tombée en panne durant la phase 3 (après le 13 avril 2026), interrompant le développement du jeu Unity.

Impact : Les plans de construction du niveau 1 de phase 4 (design de niveau « The Annex » en 9 phases avec 14 espaces, 5 checkpoints obligatoires, textures procédurales et IA ennemie avancée) n'ont pas pu être exécutés. Certaines données de session non suivies ont été perdues, bien que la majorité du progrès ait été préservée dans git. La panne matérielle a également empêché la poursuite du protocole expérimental basé sur le jeu.

Décision : L'accent s'est déplacé vers les améliorations de précision des pipelines FER et rPPG, qui peuvent se poursuivre sur la machine de secours. Le protocole d'évaluation par vidéo (8 à 12 sujets YouTube) a remplacé l'expérience de jeu en direct comme approche de validation immédiate.

Statut : Les travaux se poursuivent sur la machine de secours avec des capacités réduites.

3.7 COMPLEXITÉ DU CODE SOURCE

Problème : À la fin de la phase 2, le pipeline consistait en 22 scripts non structurés avec un orchestrateur monolithique de 1 600 lignes (`test_fusion.py`), rendant l'évaluation systématique multi-sessions impraticable.

Solution : Une réorganisation en 9 phases (décision D-096) a découpé le monolithe en modules ciblés avec une séparation claire des responsabilités. Une documentation architecturale (`Pipeline/ARCHITECTURE.md`) a été créée, et le sous-système rPPG a été restructuré en six modules à responsabilité unique (Chapitre 1, Section 1.4.2).

Résultat : Le code modulaire supporte désormais l'évaluation systématique multi-sessions et multi-formules. La nouvelle infrastructure d'évaluation ($\sim 1\,700$ LOC : `compare_ground_truth.py`, `evaluate_all.py`) et le pipeline remanié ($\sim 3\,200$ LOC) ont permis le balayage de 2 916 évaluations MP tension qui était infaisable avec l'architecture d'origine.

Statut : Résolu.

4 MÉTRIQUES DE PERFORMANCE ET MÉTHODES D'ÉVALUATION

Ce chapitre formalise les métriques, les protocoles d'évaluation et l'infrastructure utilisés pour produire les résultats rapportés au Chapitre 1. Chaque métrique est définie avec son interprétation et ses limitations.

4.1 MÉTHODOLOGIE DE VÉRITÉ TERRAIN

L'annotation de vérité terrain a évolué à travers trois itérations avant d'atteindre la méthodologie utilisée pour toutes les évaluations de phase 3 :

1. **v1 (auto-détectée)** : Formule F0 comme détecteur de pics avec des fenêtres de 6 secondes. Introduisait une dépendance circulaire — le benchmark évaluait les formules contre une vérité terrain générée par l'un des candidats.
2. **v2 (horodatages manuels)** : Modèle avec colonnes manuelles `start_s/end_s`, éliminant la dépendance circulaire mais conservant des champs de métadonnées dérivés de formules.
3. **v3 (XLSX, 12 champs)** : Modèle élargi avec métadonnées structurées. Abandonné lorsque la revue directe de la vidéo s'est avérée plus fiable.
4. **Finale (manuelle événementielle)** : L'expérimentateur revoit indépendamment chaque vidéo source sans accès aux sorties des formules, enregistrant les limites des événements de peur sur la seule base des expressions faciales visibles et des indices contextuels.

Sessions annotées : S02_Vid04 (21 événements de peur, 11 exclus), S06_Vid16 (16 événements de peur, 1 exclu), S08_Vid18 (13 événements de peur, 5 exclus). Total : 50 événements de peur scorables, 17 événements exclus (étiquettes non-peur : slight_fear, anger, disgust, laughter, obscured, side_profile).

Convention de comptage : Plusieurs déclenchements du pipeline à l'intérieur du même cluster d'événements de vérité terrain comptent comme un seul vrai positif. Cette convention par événement (plutôt que par déclenchement) gonfle légèrement à la fois la précision et le rappel par rapport au comptage par déclenchement, mais est acceptée car l'adaptation affective du jeu répond aux états de peur soutenus, non aux comptes de déclenchements individuels.

4.2 MÉTRIQUES D'ÉVALUATION FER

Métriques primaires (Phase 3) : Précision, Rappel et score F1 au niveau événementiel.

- **Précision** = $VP / (VP + FP)$: proportion des détections déclenchées correspondant à de véritables événements de peur.
- **Rappel** = $VP / (VP + FN)$: proportion des événements de peur annotés détectés avec succès.
- **Score F1** = $2 \times \text{Précision} \times \text{Rappel} / (\text{Précision} + \text{Rappel})$: moyenne harmonique équilibrant les deux préoccupations.

Détecteur d'événements par fenêtre glissante : L'algorithme de détection utilise quatre paramètres configurables :

- **threshold** : valeur minimale du signal pour considérer une trame comme active (balayé : 0,40–0,70).
- **min_frames** : nombre minimal de trames actives consécutives pour ouvrir une fenêtre de détection (balayé : 5–15).
- **window_size** : trames à anticiper lors de la fusion d'activations proches (balayé : strict, 10, 15, 20).
- **fill_ratio** : pourcentage minimal de trames actives dans une fenêtre (fixé : 65 %).

Un rembourrage temporel ($\text{pad_start} = -0,5 \text{ s}$, $\text{pad_end} = +1,0 \text{ s}$) est appliqué autour des événements de vérité terrain pour l'appariement, tenant compte de l'incertitude des limites d'annotation.

Ratio de discrimination peur/colère (métrique de phase 2) : Ratio du score composite moyen durant les événements de peur versus les événements de colère. Cible : $>3,0\times$. Remplacé par le F1 en phase 3 car : (a) le F1 est une métrique standard permettant la comparaison avec la littérature, et (b) le ratio ne capture pas l'alignement temporel entre les événements prédits et réels.

Taux de faux positifs (FDR) : $\text{FP} / (\text{VP} + \text{FP})$, utilisé pour la comparaison inter-outils (par ex. $\text{FDR MediaPipe} = 97,1 \%$ vs. $\text{FDR HSEmotion} = 30,4 \%$ dans la comparaison multi-outils de phase 2).

Analyse de proximité des faux positifs : Les régions FP sont analysées pour leur proximité temporelle avec les événements GT (à 3 s) et avec les événements exclus, distinguant les véritables erreurs du modèle des désaccords de limites d'annotation ou des détections de catégories d'émotions non scorées.

4.3 MÉTRIQUES D'ÉVALUATION RPPG

- **MAE (Erreur Moyenne Absolue)** : Moyenne $|\text{estimé} - \text{GT}|$ BPM sur toutes les fenêtres de mesure. Métrique de précision principale.
- **RMSE (Racine de l'Erreur Quadratique Moyenne)** : $\sqrt{\text{moy}((\text{est} - \text{GT})^2)}$. Pénalise les erreurs importantes plus fortement que la MAE.
- **Corrélation de Pearson (r)** : Relation linéaire entre les séries de rythme cardiaque estimé et GT. Peut être positive même avec un décalage systématique important (par ex. GREEN : $r = 0,586$, $\text{MAE} = 32,44$ BPM — corrélation élevée à un décalage de fréquence).
- **Biais** : Erreur signée moyenne ($\text{estimé} - \text{GT}$). Un biais négatif indique une sous-estimation systématique, cohérente avec le verrouillage FFT demi-harmonique observé pour tous les algorithmes.

Chaque algorithme est évalué indépendamment par session pilote, avec des rapports séparés pour les extracteurs Haar et MediaPipe lorsque disponibles (le Pilot 01 fournit les deux). Le SNR par fenêtre de mesure est utilisé pour identifier les « bonnes fenêtres » où le suivi rPPG est fiable (± 10 BPM du GT), appuyant l'hypothèse qu'un filtrage par qualité de signal pourrait améliorer la précision agrégée.

4.4 MÉTRIQUES DE PERFORMANCE SYSTÈME

Décomposition de la latence de bout en bout :

Couverture de détection faciale : 99,9 % avec l'approche hybride Haar + MediaPipe sur les trois sessions de phase 3 (30,4 % avec Haar seul en conditions sombres).

FPS effectif : 27–30 FPS sous opération pipeline complète (FER + rPPG concurrent). La phase 2 atteignait 54,6 FPS sur Video05_S02 avec un périmètre pipeline réduit.

Tableau 4.1: Budget de latence du pipeline (valeurs mesurées en phase 3)

Étape	Latence	Notes
Capture caméra	~33 ms	Webcam 30 FPS
Détection faciale	~9 ms	Hybride Haar + MP
HSEmotion	~10 ms	EfficientNet-B0, CPU
Calcul formule	<1 ms	Arithmétique uniquement
Émission socket	~1 ms	TCP localhost
Total	~53 ms	Dans le budget de 200 ms

4.5 INFRASTRUCTURE D'ÉVALUATION

`compare_ground_truth.py` : Script d'évaluation principal avec deux modes de détection :

- **v1 (strict)** : Nécessite `min_frames` trames consécutives au-dessus du seuil pour enregistrer une détection.
- **v2 (fenêtre glissante)** : Utilise `window_size` et `fill_ratio` pour une détection flexible, tolérant de brèves trames sous le seuil dans une région par ailleurs active.

`evaluate_all.py` : Enveloppe multi-sessions produisant :

- La meilleure configuration de détection par formule (seuil, `min_frames`, balayage de fenêtres)
- Des rapports détaillés par session avec analyse des faux positifs
- Des résultats agrégés combinés sur toutes les sessions
- Le balayage de configuration de tension MediaPipe (81 configurations $\times$ 12 formules)

Étendue du balayage de paramètres : L'évaluation de phase 3 a couvert 12 formules sur plusieurs configurations de seuil et de fenêtre pour l'évaluation HSEmotion, et 81 configurations de tension $\times$ 12 formules $\times$ 3 sessions = 2 916 évaluations individuelles pour le balayage de tension MediaPipe.

Détecteur d'Événements Affectifs à Deux Portes : Conçu pour la validation prévue en session en direct :

- **Porte A (déclenchement) :** La dérivée de `composite_fear` dépasse un seuil, détectant le front montant d'un événement de peur.
- **Porte B (maintien) :** `composite_fear` reste au-dessus du seuil pendant une durée minimale, filtrant les pics transitoires.

Ce détecteur est conçu mais pas encore déployé dans le pipeline d'évaluation ; il est planifié pour l'évaluation par vidéo avec des sujets supplémentaires.

Bibliographie

- Abdeldayem, M. A., Hamed, H. F. A., & Nagy, A. M. (2026). Facial expression recognition: A survey of techniques, datasets, and real-world challenges. *Statistics, Optimization and Information Computing*, 15, 733–761.
- Wang, W., den Brinker, A. C., Stuijk, S., & de Haan, G. (2017). Algorithmic principles of remote PPG. *IEEE Transactions on Biomedical Engineering*, 64(7), 1479–1491.
- Yang, S., Yoon, B., Kang, S., Song, H., & Woo, W. (2026). OFERA: Blendshape-driven 3D gaussian control for occluded facial expression to realistic avatars in VR. *arXiv preprint arXiv:2602.01748*.