

T.C GALATASARAY ÜNİVERSİTESİ
MÜHENDİSLİK VE TEKNOLOJİ FAKÜLTESİ

DUYUŞSAL OYUN TASARIMINDA UYARLAMALI DÜŞMAN
YAPAY ZEKASI İÇİN GERÇEK ZAMANLI DUYGU ANALİZİ

**(La Façade Fissurée : Analyse des Émotions en Temps Réel
pour l'IA Adaptative dans la Conception de Jeux Affectifs)**

RAPPORT FINAL

Ali Burak SARAÇ

Bölüm : BİLGİSAYAR MÜHENDİSLİĞİ

Danışman : Dr. Öğr. Üyesi Reis Burak Arslan

MAİ 2026

Préface

Ce rapport présente le projet de fin d'études *La Façade Fissurée*, réalisé au cours du semestre de printemps 2026 au sein du département d'Ingénierie Informatique de l'Université Galatasaray.

Je tiens à exprimer ma sincère gratitude à mon directeur de projet, Dr. Öğr. Üyesi Reis Burak Arslan, pour ses conseils, ses retours constructifs et son soutien continu tout au long de ce projet. Ses observations et ses encouragements ont été déterminants dans l'orientation technique et la forme finale de ce travail.

Je souhaite également exprimer ma reconnaissance envers mon ami Kaan Çolakoğlu, qui a généreusement partagé son deuxième ordinateur lorsque le mien est tombé en panne pendant la période critique du projet, me permettant de poursuivre mon travail sans retard significatif.

22 mai 2026

Ali Burak Saraç

Table des Matières

Préface	i
Table des Matières	ii
Liste des Figures	vii
Liste des Tableaux	viii
Liste des Notations	x
Résumé	xi
Özet	xvi
1. INTRODUCTION	1
1.1. Sujet du projet	1
1.2. Buts et objectifs	2
1.3. Valeur unique du projet	3
1.4. Contribution sociale	4
2. REVUE DE LA LITTÉRATURE	6
2.1. Reconnaissance des émotions faciales (FER)	6
2.2. Photopléthysmographie à distance et détection en faible luminosité	8
2.3. Fusion multimodale	9
2.4. Biofeedback et adaptation affective	10
2.5. Confidentialité en informatique affective	11

3.	DÉFINITION DU PROBLÈME	12
3.1.	Lacunes identifiées	12
3.1.1.	Robustesse FER en faible éclairage	12
3.1.2.	Le paradoxe rPPG sous stress	12
3.1.3.	Fusion de modalités à résolutions temporelles différentes	12
3.1.4.	Biofeedback à signal unique	13
3.2.	Énoncé du problème	13
3.3.	Analyse SWOT	14
4.	MÉTHODOLOGIES ET MODÈLES	15
4.1.	Environnement de développement et contraintes	15
4.2.	Outils de reconnaissance des émotions faciales	17
4.3.	Photopléthysmographie à distance (rPPG)	19
4.4.	Stratégie de fusion et mécanisme d'adaptation	19
4.5.	Conception expérimentale	20
4.6.	Cadre d'évaluation	21
4.6.1.	Méthodologie de vérité terrain	21
4.6.2.	Métriques FER	21
4.6.3.	Métriques rPPG	22
4.6.4.	Métriques de performance système	23

5.	CONCEPTION ET IMPLÉMENTATION DU SYSTÈME	24
5.1.	Architecture du pipeline	24
5.2.	Prétraitement d'image : CLAHE	25
5.3.	Détection faciale hybride	26
5.4.	Traitement du signal rPPG	27
5.4.1.	Algorithme POS	27
5.4.2.	Stratégie ROI	28
5.5.	Formule composite de peur	29
5.5.1.	Architecture de la formule	29
5.5.2.	Score de tension MediaPipe	30
5.6.	Formule d'augmentation rPPG	31
5.7.	Stratégie de détection par couches	32
5.7.1.	Pipeline à quatre couches	32
5.7.2.	Détecteur d'événements à double porte	32
5.8.	Implémentation du jeu Unity	33
5.8.1.	Concept du jeu	33
5.8.2.	Prototype v1 (validé)	34
5.8.3.	Refonte v2.0 (en développement)	35
5.9.	Analyse des coûts	36

6.	RÉSULTATS	37
6.1.	Phase 1 : Développement du pipeline	37
6.2.	Phase 2 : Pilote sur sujet unique (S02)	38
6.2.1.	Comparaison des outils FER	38
6.2.2.	Benchmark initial des formules (F0–F6)	38
6.3.	Phase 3 : Évaluation sur trois sujets	40
6.3.1.	L’effondrement de F2	40
6.3.2.	L’intuition multiplicative	41
6.3.3.	Résultats de la détection faciale hybride	42
6.4.	Phase 4 : Évaluation finale sur six sujets	42
6.4.1.	De F13 à F12 : le canal d’arousal	43
6.4.2.	Performance par session	44
6.4.3.	Registre des formules	45
6.5.	La découverte rPPG	46
6.5.1.	Faisabilité et validation par montre connectée	46
6.5.2.	Le résultat nul (CONSENSUS)	47
6.5.3.	Le balayage de 48 configurations	47
6.5.4.	Correction pour tests multiples	48
6.5.5.	Augmentation rPPG de la détection FER	49
6.6.	Résumé des résultats clés	50
7.	ANALYSE ET DISCUSSION	51
7.1.	HSEmotion vs. MediaPipe : une asymétrie inattendue	51
7.2.	Le résultat nul rPPG : anatomie d’un artefact méthodologique	52
7.3.	La mécanique de terreur soutenue	53
7.4.	Précision plutôt que rappel : un principe de conception en pratique	54
7.5.	La panne matérielle et le pivot du projet	55
7.6.	Vérification de l’architecture	56

8.	CONCLUSIONS ET PERSPECTIVES	57
8.1.	Réponses aux questions de recherche	57
8.2.	Résumé des contributions	58
8.3.	Limitations	59
8.4.	Travaux futurs	60
8.5.	Conclusion	60
A.	GLOSSAIRE TECHNIQUE	61
1.1.	Traitement du signal et rPPG	61
1.1.1.	Algorithmes rPPG	63
1.1.2.	Variabilité de la fréquence cardiaque	64
1.2.	Reconnaissance des émotions faciales	65
1.3.	Métriques d'évaluation	70
1.3.1.	Tests statistiques	72
1.4.	Architecture du système	73
B.	GLOSSAIRE SIMPLIFIÉ	77
2.1.	Mesure de la fréquence cardiaque par vidéo	77
2.1.1.	Algorithmes rPPG	79
2.1.2.	Variabilité de la fréquence cardiaque	80
2.2.	Reconnaissance des émotions faciales	80
2.3.	Comment nous mesurons les performances du système	85
2.3.1.	Tests statistiques	87
2.4.	Architecture du système	88
	Bibliographie	90

Liste des Figures

5.1	Architecture finale du pipeline — les flèches pleines indiquent les signaux principaux ; les flèches en pointillés indiquent les canaux modificateur et d’augmentation	24
5.2	Organigramme de la détection faciale hybride	26
5.3	Machine à états finie ennemie à quatre états (prototype v1)	34
5.4	Cycle de vie à 7 états du ParticipantFlowManager	34

Liste des Tableaux

3.1	Analyse SWOT du projet (annotations rétrospectives en <i>italique</i>)	14
4.1	Spécifications matérielles de développement	15
4.2	Outils FER candidats	17
4.3	Latence d'inférence FER — benchmark contrôlé (Acer Predator, éclairage intérieur standard). Les valeurs en régime permanent excluent le préchauffage du modèle à la première image. FPS = 1000/latence moyenne.	18
5.1	Budget de latence du pipeline	36
6.1	Résultats du benchmark des formules de peur (Video05_S02, discrimination peur/colère). Vérité terrain basée sur la synchronisation auto-détectée v1 ; voir texte pour la mise en garde méthodologique.	39
6.2	Événements de vérité terrain par session	42
6.3	Résultats de détection combinés sur six sessions — meilleure configuration par formule	43
6.4	Résultats de détection F12 par session aux paramètres verrouillés	44
6.5	Registre de composition des formules (F0–F15)	45
6.6	Précision des algorithmes rPPG — Pilote 01 (extracteur MediaPipe, $n = 53$ fenêtres)	46
6.7	Réponse cardiaque de peur rPPG — POS@10s/5s sur quatre sessions	48
6.8	Meilleures configurations d'augmentation rPPG. La ligne de base F12 (F1 = 0.7191, P = 91.4 %, R = 59.3 %) est évaluée sur les quatre mêmes sessions avec données rPPG (54 événements), pas le corpus complet de six sessions (88 événements, F1 = 0.6971).	49

Liste des Équations

4.1 Décomposition de la latence de bout en bout	23
5.1 POS — Signal de pouls rPPG Plane-Orthogonal-to-Skin	27
5.2 F12 — Formule composite de détection de peur (hybrid_amp)	29
5.3 F15 — Formule de détection de peur augmentée par rPPG (rppg_amp)	31

Liste des Notations

POS	Algorithme rPPG Plane-Orthogonal-to-Skin
CHROM	Algorithme rPPG basé sur la chrominance
CLAHE	Égalisation adaptative d'histogramme à contraste limité
CONSENSUS	Fusion BPM multi-algorithme pondérée par le SNR (abandonnée en production)
AGC	Contrôle automatique de gain (normalisation des blendshapes)
P	Précision : $TP/(TP + FP)$
R	Rappel : $TP/(TP + FN)$
F1	Moyenne harmonique de la précision et du rappel : $2PR/(P + R)$
d	Taille d'effet d de Cohen
SNR	Rapport signal sur bruit
MAE	Erreur absolue moyenne
RMSE	Erreur quadratique moyenne
RMSSD	Racine de la moyenne des carrés des différences successives (métrique VFC)
BPM	Battements par minute
FPS	Images par seconde
TCP	Protocole de contrôle de transmission
FER	Reconnaissance des émotions faciales
rPPG	Photopléthysmographie à distance
HRV	Variabilité de la fréquence cardiaque

Résumé

Ce projet étudie si une webcam grand public standard peut servir de capteur biométrique unique pour le gameplay adaptatif d'un jeu d'horreur, remplaçant ainsi les équipements spécialisés et intrusifs. Un pipeline d'informatique affective multimodale en temps réel a été conçu et évalué, combinant la reconnaissance des émotions faciales (FER) via HSE-motion et MediaPipe avec l'estimation sans contact de la fréquence cardiaque par photopléthysmographie à distance (rPPG) utilisant l'algorithme POS.

Le problème central abordé est la détection et la quantification de la peur du joueur sous l'éclairage faible et dynamique typique des jeux d'horreur — une condition largement inexplorée dans la littérature FER. Une stratégie hybride de détection faciale combinant cascade de Haar et MediaPipe a été développée pour surmonter la dégradation sévère des détecteurs traditionnels en conditions de faible luminosité. La formule composite de peur F12 fusionne la classification neuronale avec la tension faciale géométrique dans une architecture multiplicative, atteignant un F1 au niveau événementiel de 0.70 sur six sujets et 88 événements de peur annotés sous éclairage mixte. L'augmentation multiplicative par rPPG (F15) améliore la détection à un F1 de 0.77 tout en maintenant une précision de 90%.

Le système fonctionne entièrement sur la machine locale du joueur avec une latence de bout en bout d'environ 53 ms, répondant aux préoccupations de confidentialité inhérentes au traitement biométrique facial. Aucune donnée vidéo ne quitte l'appareil. L'architecture du pipeline est conçue pour l'intégration dans un prototype de jeu d'horreur Unity 3D implémentant une mécanique « Relax-to-Win », où l'agressivité de l'ennemi répond à l'état émotionnel détecté du joueur, encourageant l'autorégulation émotionnelle — un paradigme avec des applications potentielles en gestion du stress et en thérapie d'exposition.

L'expérience en jeu en direct et la calibration inter-sujets demeurent les principales orientations pour les travaux futurs.

Özet

PROJENİN TANITIMI, KAPSAMI VE ARAŞTIRMA PROBLEMİ

Bugüne kadar geliştirilen biyogeribildirimli (biofeedback) oyunlar, oyuncunun fizyolojik durumunu ve duygusal tepkilerini algılayabilmek için elektroensefalografi (EEG) başlıkları, göğüs bantları, kulak klipsi nabız sensörleri veya akıllı saatler gibi özel donanımlara ihtiyaç duymuştur. Bu cihazlar işlevsel olmakla birlikte, getirdikleri yüksek maliyet ve kurulum zahmeti, biyogeribildirimli oyun tasarımını son kullanıcı için yaygın bir pratik olmaktan çıkarıp araştırma odaklı bir niş düzeyinde tutmaktadır. Bu projenin temel araştırma problemi, oyuncunun duygu durumunu ve fizyolojik tepkilerini ölçmek için her dizüstü bilgisayarda ve monitörde standart olarak bulunan web kamerasının, söz konusu kısıtlayıcı ve pahalı donanımların yerini alıp alamayacağıdır.

Projenin kapsamı, oyuncunun hem yüz ifadelerinin (FER - Facial Emotion Recognition) hem de fotopletismografi (rPPG - remote Photoplethysmography) yöntemiyle elde edilen kalp atış hızının eş zamanlı olarak analiz edilerek oyun içi zorluk seviyesine entegre edilmesini içermektedir. Çalışmanın sınırları ise, yöntemin özellikle loş ve dinamik aydınlatma koşullarının hakim olduğu bir korku oyunu senaryosunda, sadece web kamerası kullanılarak sınanmasıyla belirlenmiştir. Yüksek işlem kapasiteli sunuculara veya bulut bilişime dayanmak yerine, tüm sürecin oyuncunun kendi bilgisayarında gerçek zamanlı ve yerel (offline) olarak çalıştırılması projenin temel kısıtlamalarından ve sınırlarından biridir.

ÇALIŞMANIN AMACI

Bu çalışmanın ana amacı, oyuncunun korku ve stres seviyesini standart bir web kamerası üzerinden gerçek zamanlı olarak ölçebilen, çok modlu (multimodal) bir duyuşsal bilişim (affective computing) işlem hattı geliştirmek ve bu altyapıyı "Kazanmak için Rahatla" (Relax-to-Win) mekaniğine sahip üç boyutlu bir korku oyunu prototipine entegre etmektir. Projenin sonunda ulaşılmak istenen hedef, oyuncunun sadece yüz ifadelerindeki anlık irk-ilmelere değil, aynı zamanda görünmez kardiyak tepkilerine ve süregelen uyarılmışlığına da duyarlı olan, tamamen cihaz üzerinde çalışan düşük gecikmeli bir biyogeribildirim sistemi kurmaktır.

Çalışmanın amacına ulaşp ulaşmadığı spesifik ölçütlerle değerlendirilmiştir. Yüz tespiti ve duygu analizinin başarısı, farklı aydınlatma koşullarında etiketlenmiş korku olayları üzerinde kayan pencere (sliding window) bir değerlendirme kullanılarak olay bazlı hassasiyet (precision), duyarlılık (recall) ve F1-skoru ile ölçülmüştür. Kardiyak kanalın başarısı ise, rPPG tahminlerinin referans değerlere kıyasla korku anlarındaki kalp atış hızı artışını tespit edip edemediği üzerinden; Welch t-testi, Cohen's d etki boyutu ve aile bazlı hata oranı (FWER) permütasyon düzeltmeleri gibi istatistiksel metriklerle doğrulanmıştır.

PROJENİN ÖZGÜN DEĞERİ VE ÖNEMİ

Projenin özgün değeri, literatürdeki birbirini kuvvetlendiren dört temel eksikliği eş zamanlı olarak gidermesinden kaynaklanmaktadır. Birincisi, literatürdeki duygu tanıma çalışmaları büyük ölçüde kontrollü ve aydınlık stüdyo ortamlarında test edilmektedir; bir korku oyununun gerektirdiği loş ve renkli aydınlatma altındaki performans büyük bir boşluktur. Bu proje, söz konusu zorlu aydınlatma koşullarında kararlı çalışabilen hibrit bir yüz tespiti ve duygu çıkarım stratejisi sunarak bu soruna doğrudan çözüm getirmektedir.

İkincisi, yüz videosundan kalp atış hızını çıkarma tekniği olan rPPG, denek hareket ettiğinde veya kalp atış hızı aniden yükseldiğinde doğruluk kaybetme eğilimindedir. Oysa biyogeribildirimli bir oyunda ölçümün en kritik olduğu an tam da bu hareketli ve stresli anlardır. Üçüncüsü, hızlı bir modalite (saniyede 30 kare ile güncellenen yüz ifadeleri) ile yavaş bir modaliteyi (birkaç saniyede bir güncellenen kalp atış hızı) oyun bağlamında birleştiren, asimetrik güvenilirliklere sahip bu sinyalleri dengeleyen hiçbir birleştirme (fusion) stratejisi daha önce doğrulanmamıştır. Dördüncüsü, mevcut biyogeribildirim oyunlarının tamamı tek bir adanmış fizyolojik sensör kullanırken, bu proje hiçbir temas sensörü olmadan duygu ve fizyolojiyi tek bir kameradan birleştiren öncü bir yaklaşımdır.

Bu konunun seçiliş sebebi ve önemi, donanım bağımlılığını ortadan kaldırarak adaptif oyun tasarımlarını herkes için erişilebilir kılmaktır. Ayrıca, geliştirilen mekanizma sayesinde oyuncunun korkusunu bastırarak düşmanı yatıştırdığı bir yapı kurgulanmıştır. Bu yaklaşım, kontrollü maruz bırakma ve öz-düzenleme eğitiminin temel alındığı fobiler ve anksiyete yönetimine yönelik terapötik maruz bırakma uygulamaları için değerli bir oyunlaştırma potansiyeli taşımaktadır.

YÖNTEM, ARAŞTIRMA TEKNİKLERİ VE KAYNAK ANALIZI

Projede derin öğrenme, bilgisayarlı görü ve sinyal işleme tekniklerini bir araya getiren hibrit ve çok modlu bir yöntem tasarlanmıştır.

Yüz duygu tanıma için AffectNet veri seti üzerinde eğitilmiş, EfficientNet-B0 mimarisine dayanan HSEmotion modeli kullanılmıştır. Bu modelin seçilme sebebi, kare başına yaklaşık 10 milisaniye gibi son derece düşük bir sürede duygu olasılığı ve arousal değerleri üretebilen bir yapıya sahip olmasıdır. Eş zamanlı olarak, oyuncunun yüzündeki kas aktivasyonlarını ve gerginlikleri (örneğin göz açma veya kaş kaldırma gibi blendshape değerleri) tespit etmek için Google MediaPipe FaceLandmarker tercih edilmiştir. Kalp atış hızı tahmini için ise alın bölgesindeki piksel altı renk dalgalanmalarını işleyen POS (Plane-Orthogonal-to-Skin) algoritması kullanılmıştır. POS algoritmasının seçilme nedeni, aydınlatma değişikliklerine ve kafa hareketlerine karşı diğer yöntemlere (örneğin ICA veya CHROM) kıyasla matematiksel olarak daha dirençli olmasıdır.

Projede uygulanan en önemli araştırma tekniği, sinyallerin "çarpımsal birleştirme" (multiplicative fusion) mimarisi ile entegre edilmesidir. Bir korku oyununda yanlış pozitif tespiti (oyuncunun sakın olduğu halde korktuğunun sanılıp oyunun aniden zorlaşması) oyuncunun deneyimini tamamen bozarken, yanlış negatif (bir anlık korkunun kaçırılması) daha tolere edilebilir bir durumdur. Bu asimetrik risk nedeniyle, tespit kanalları birbirlerine doğrusal olarak eklenmek yerine çarpımsal bir düzenleyici olarak kurgulanmıştır. Zayıf ancak tamamlayıcı sinyaller olan MediaPipe yüz gerginliği ve rPPG kalp artışı, ancak ana HSEmotion modeli bir korku olasılığı tespit etmişse skoru yükseltecek şekilde tasarlanmıştır; böylece yanlış alarmların önüne geçilmiştir.

Kaynak analizi açısından proje; Python tabanlı bir işlem hattı, TCP soket haberleşmesi ve Unity 3D motoru ile geliştirilmiş bir ön yüz gerektirmiştir. Veri kaynağı olarak değerlendirme sürecinde kamuya açık korku reaksiyon videoları kullanılarak 88 olay manuel olarak etiketlenmiş ve zengin bir referans veri seti oluşturulmuştur. İşlem hattının donanım gereksinimi tamamen tüketici seviyesindeki bir dizüstü bilgisayar donanımına ve standart bir web kamerasına indirgenmiş, bulut tabanlı bir API veya harici bir grafik işlem birimi ihtiyacı ortadan kaldırılmıştır.

SONUÇLARIN GENEL DEĞERLENDİRMESİ

Proje sonucunda elde edilen veriler, geliştirilen sistemin amaçlarına başarıyla ulaştığını ve literatürdeki boşlukları etkili bir şekilde doldurduğunu göstermektedir.

İlk olarak, düşük aydınlatmadaki yüz tespiti sorunu, klasik Haar cascade ile modern MediaPipe ağının hibrit kullanımıyla çözülmüş ve karanlık ortamlardaki yüz tespit oranı %30,4'ten %99,9'a çıkarılarak kesintisiz bir veri akışı elde edilmiştir.

Sinyal birleştirme stratejisi incelendiğinde, HSEmotion çıktısı ile MediaPipe yüz gerginliğinin çarpımsal olarak birleştirildiği ana tespit formülü, karışık aydınlatma altındaki altı denek ve 88 olay üzerinde 0,70 gibi rekabetçi bir olay bazlı F1-skoru sağlamıştır. rPPG kanalının sisteme entegrasyonu projenin en çarpıcı bulgularından birini sunmuştur. Başlangıçta hareket ve aydınlatma nedeniyle çalışmadığı sanılan kardiyak kanal üzerinde yapılan 48 konfigürasyonluk kapsamlı tarama, doğru pencere boyutu ve algoritma (POS) eşleşmesiyle istatistiksel olarak oldukça anlamlı bir tepki (korku olaylarında +8,6 BPM artış, $p = 0.029$, $d = 0.70$) yakalamıştır. Bu kardiyak tepkinin tespit formülüne eklenmesiyle sistemin entegre F1-skoru 0,77 seviyesine yükselirken, hassasiyeti (precision) %90 seviyesinde korunmuştur.

Mimari değerlendirmeler, sistemin ortalama 53 milisaniyelik uçtan uca gecikmeyle, saniyede 100 milisaniye olan eş zamanlılık sınırının çok altında, tamamen oyuncunun kendi cihazında çalıştığını doğrulamıştır. Bu durum, hiçbir video verisinin cihazı terk etmemesini sağlayarak biometrik verilerin işlenmesindeki gizlilik endişelerini ortadan kaldırmıştır. Yüz kanalının anlık ırkılmayı, kalp atış hızı kanalının ise fizyolojik olarak süregelen uyarılmışlığı yakaladığı bu tamamlayıcı yaklaşım; oyuncu sakinleştiğinde düşmanın geri çekildiği "Kazanmak için Rahatla" mekanizması ile mükemmel bir uyum sergilemektedir.

Sonuç olarak bu proje, herhangi bir ek donanım olmaksızın sadece standart bir web kamerası ve tüketici düzeyinde bilgisayar kullanılarak yüksek doğruluklu, düşük gecikmeli ve gizliliğe saygılı bir duyuşsal oyun işlem hattının geliştirilebileceğini somut verilerle kanıtlamıştır. Biyogeribildirimli oyunların önündeki teknik donanım engeli aşılmış olup, gelecekteki çalışmalar canlı denek deneyleri ile bu sistemin oyuncu deneyimi üzerindeki psikolojik etkilerini araştırmaya yönlendirilecektir.

1. INTRODUCTION

1.1. SUJET DU PROJET

Des jeux tels que *Until Dawn* ont démontré que les capteurs biométriques physiques peuvent renforcer l’immersion, mais le coût et le caractère intrusif des capteurs dédiés limitent leur adoption. Ce projet étudie si une webcam grand public standard — un appareil que chaque joueur possède déjà — peut remplacer les équipements biométriques spécialisés et servir de capteur unique pour un gameplay adaptatif.

Un pipeline d’informatique affective multimodale en temps réel a été conçu, évalué et préparé pour l’intégration dans un jeu d’horreur 3D à la première personne. Le système capture les expressions faciales via webcam et estime la fréquence cardiaque par photopléthysmographie à distance (rPPG), avec pour objectif d’adapter dynamiquement le comportement de l’IA ennemie à travers une mécanique « Relax-to-Win » : lorsque le joueur a peur, les ennemis deviennent agressifs ; lorsque le joueur retrouve son calme, les ennemis se désengagent. Le jeu récompense l’autorégulation émotionnelle plutôt que de punir l’échec — une inversion de la conception conventionnelle des jeux d’horreur.

La portée du projet englobe trois axes :

- (a) la détection et la quantification des émotions du joueur (peur, stress, surprise) dans les conditions de faible éclairage typiques d’un jeu d’horreur ;
- (b) la fusion au niveau décisionnel des signaux d’expression faciale et physiologiques à partir d’une seule webcam ;
- (c) l’adaptation en boucle fermée du comportement de l’IA ennemie en fonction de l’état affectif détecté.

Le pipeline a été évalué sur six sujets et 88 événements de peur annotés sous des conditions d’éclairage mixtes. Un prototype de jeu Unity implémentant la mécanique Relax-to-Win a été développé. Les résultats détaillés et leur interprétation sont présentés aux Chapitres 6 et 7.

La question de recherche principale est : *Un pipeline d'informatique affective multi-modale — combinant la reconnaissance des émotions faciales et la détection physiologique à distance via une webcam grand public — peut-il être utilisé pour construire un jeu d'horreur adaptatif qui répond de manière significative à l'état émotionnel du joueur ?*

Cette question se décompose en trois sous-questions :

- **RQ1** : Un système de reconnaissance des émotions faciales (FER) peut-il maintenir une précision suffisante dans les conditions de faible éclairage d'un jeu d'horreur ?
- **RQ2** : La fusion au niveau décisionnel des signaux FER et rPPG améliore-t-elle la fiabilité de la détection dans des conditions de jeu réalistes ?
- **RQ3** : Un mécanisme d'adaptation affective « Relax-to-Win » — où le comportement de l'ennemi réagit à l'état émotionnel détecté du joueur — améliore-t-il l'expérience du joueur dans un jeu d'horreur ?

1.2. BUTS ET OBJECTIFS

L'objectif principal est de développer une boucle de biofeedback complète reliant l'état émotionnel du joueur au comportement de l'IA ennemie en temps réel. Les objectifs spécifiques sont :

1. **Construire un pipeline de reconnaissance des émotions faciales (FER)** capable de fonctionner en temps réel (<100 ms de latence de bout en bout) avec une webcam grand public, en utilisant des outils open-source.
2. **Implémenter et évaluer un module rPPG** pour l'estimation sans contact de la fréquence cardiaque à partir du flux vidéo de la webcam, en évaluant la précision et la robustesse dans des conditions de jeu.

3. **Évaluer la robustesse** des deux modalités dans des conditions de faible éclairage — une contrainte réaliste pour un jeu d’horreur.
4. **Concevoir une stratégie de fusion au niveau décisionnel** entre les signaux faciaux et physiologiques, avec gestion des conflits entre modalités.
5. **Implémenter un mécanisme d’adaptation affective « Relax-to-Win »** où le calme du joueur est récompensé et le stress élevé déclenche une réactivité accrue de l’ennemi.

Le seuil de latence de 100 ms est choisi en référence aux seuils de réactivité perceptuelle en interaction homme-machine : en dessous de ce délai, la réponse d’un système est perçue comme instantanée.

Un principe de conception gouverne l’ensemble du système : **la précision importe plus que le rappel**. Un faux positif — le système détectant de la peur chez un joueur calme — déclenche une poursuite ennemie injustifiée, brisant l’immersion et désorientant le joueur. Un faux négatif — manquer un véritable moment de peur — signifie que le jeu continue sans adaptation, ce qui ressemble à un gameplay normal. L’asymétrie est fondamentale : les fausses alarmes perturbent ; les détections manquées sont invisibles. Ce principe a guidé chaque décision de conception, de la sélection des formules au réglage des seuils de détection.

1.3. VALEUR UNIQUE DU PROJET

Ce projet se distingue des travaux existants de plusieurs manières :

1. **Fusion multimodale dans un contexte de jeu** : Les systèmes de biofeedback existants dans les jeux reposent sur un signal physiologique unique, typiquement la fréquence cardiaque (Moschovitis & Denisova, 2022). Ce projet propose une approche multimodale combinant FER et rPPG à partir d’une seule webcam.

2. **Conditions d'éclairage dégradées :** La majorité des benchmarks FER sont réalisés sous éclairage contrôlé (Kopalidis et al., 2024). Ce projet cible spécifiquement les environnements sombres des jeux d'horreur où le moniteur est la seule source de lumière.
3. **Détection hybride catégorielle-continue :** Le système combine la classification catégorielle des émotions (probabilité softmax de peur à 8 classes de HSEmotion) avec des signaux continus (scores valence-arousal et activations géométriques des blendshapes), capturant à la fois les catégories d'émotions discrètes et les variations physiologiques subtiles qu'aucune approche seule ne détecterait (Li et al., 2025).
4. **Traitement local et confidentialité :** Tout le traitement est effectué localement sur la machine du joueur. Aucune donnée vidéo n'est transmise à un serveur externe, conformément aux principes de confidentialité dès la conception (Gutiérrez et al., 2025).
5. **Évolution technologique :** Ce projet poursuit une progression naturelle dans les systèmes de biofeedback pour les jeux : des équipements de laboratoire coûteux (Nexus-10) à un capteur de pouls à pince auriculaire à faible coût (Moschovitis & Denisova, 2022), puis une montre connectée grand public (Hossan et al., 2025), et enfin une webcam standard.

1.4. CONTRIBUTION SOCIALE

Contribution scientifique et technologique : Le pipeline fournit une architecture reproductible pour l'intégration de l'informatique affective dans les systèmes interactifs en temps réel. L'évaluation comparative des outils FER en conditions de faible éclairage et l'étude systématique de la détection de la peur basée sur le rPPG contribuent à des domaines encore peu explorés dans la littérature.

Perspectives pour la santé et le bien-être : Le mécanisme « Relax-to-Win » encourage le joueur à réguler son stress plutôt que de paniquer davantage. Comme le notent Moschovitis & Denisova (2022), ce paradigme suscite un intérêt croissant pour la gestion du stress et pourrait inspirer de futures applications thérapeutiques.

Considérations éthiques : Le projet aborde la confidentialité dans les systèmes biométriques à travers une architecture de traitement entièrement locale. Aucune image faciale ne quitte la machine du joueur.

Accessibilité : L'utilisation d'une webcam grand public plutôt que de capteurs spécialisés (EEG, capteur de fréquence cardiaque dédié) rend le système accessible sans matériel supplémentaire, réduisant les barrières tant pour les développeurs que pour les joueurs.

La suite de ce rapport est organisée comme suit :

- Le Chapitre 2 passe en revue la littérature pertinente.
- Le Chapitre 3 formule le problème et identifie les lacunes que ce projet vise à combler.
- Le Chapitre 4 présente les choix méthodologiques, les sélections d'outils et le cadre d'évaluation — y compris les définitions de métriques dont le lecteur aura besoin avant de rencontrer les résultats.
- Le Chapitre 5 détaille l'architecture du système, l'implémentation technique et l'analyse des coûts.
- Le Chapitre 6 présente les résultats expérimentaux sous forme de récit de découverte progressive.
- Le Chapitre 7 interprète ces résultats, analyse pourquoi certaines approches ont réussi ou échoué, et examine les moments pivots du projet.
- Le Chapitre 8 répond aux questions de recherche et propose des orientations pour les travaux futurs.

2. REVUE DE LA LITTÉRATURE

La revue de la littérature est structurée selon la logique du pipeline envisagé : reconnaissance des émotions faciales, photopléthysmographie à distance, fusion multimodale, adaptation par biofeedback, et confidentialité.

2.1. RECONNAISSANCE DES ÉMOTIONS FACIALES (FER)

Cheong et al. (2023) présentent **Py-Feat**, une boîte à outils modulaire pour la détection des émotions faciales utilisant HOG+SVM pour les unités d'action et ResMaskNet pour la classification des émotions. Les auteurs rapportent un F1 moyen de 0.55 sur les benchmarks standards, avec une dégradation notable en conditions de faible éclairage et une confusion fréquente entre peur et surprise. Ce résultat a souligné la nécessité de privilégier des architectures beaucoup plus légères pour respecter un budget strict de 100,ms en temps réel. La confusion peur-surprise rapportée a été confirmée dans nos données et a directement motivé l'approche par formule composite (Chapitre 5).

Kopalidis et al. (2024) fournissent une revue systématique de 60 méthodes FER, des approches traditionnelles aux transformers. Leur conclusion principale est que l'apprentissage profond surpasse les méthodes classiques, et que l'éclairage constitue le défi majeur pour la robustesse des systèmes FER. Ce constat a motivé la recherche de stratégies de détection hybrides ou de secours pour assurer une couverture robuste dans les environnements de jeu sombres. (Chapitre 6, Section 6.3.3).

Li et al. (2025) réalisent une comparaison équitable de 12 algorithmes FER sur les jeux de données AffectNet, FER2013 et RAF-DB. Le meilleur modèle (Poster) atteint 75.98 % de précision, tandis que HOG-SVM est limité à 50.12 %, confirmant la nécessité des approches d'apprentissage profond. Le backbone EfficientNet-B0 de HSEmotion a été sélectionné en conséquence, atteignant une inférence en temps réel adaptée à la détection de la peur dans des conditions de jeu (Chapitre 6).

Savchenko (2025) présentent l'entrée HSEmotion à la compétition ABAW-8, démontrant que le backbone EmotiEffNet-B0 atteint une reconnaissance d'expressions compétitive en conditions réelles sur le jeu de données Aff-Wild2. Pour traiter l'instabilité image par image, les auteurs démontrent qu'une technique de *lissage temporel* (noyau à fenêtre glissante sur les prédictions) produit des améliorations consistantes (+3.93 % F1 pour une taille de fenêtre $\delta = 25\text{--}100$ images). Cette approche a été directement adoptée dans ce projet : une moyenne glissante sur 50 images (~ 1.67 s) est appliquée sur le score composite de peur, s'inspirant de ce résultat. Le filtrage par confiance a été évalué mais non adopté, car le détecteur d'événements à double porte (Chapitre 5) traite déjà l'instabilité au niveau des images.

Abdeldayem et al. (2026) passent en revue l'évolution des architectures FER des CNN aux réseaux d'attention et aux transformers. Un résultat systématique à travers les benchmarks est la précision de reconnaissance la plus faible pour la *peur* comparée à toutes les autres catégories. Les auteurs attribuent cela au chevauchement entre la peur (AU 1+2+4 : élévation du sourcil interne + froncement) et la surprise (AU 1+2+5 : élévation du sourcil interne + élévation de la paupière supérieure), qui ne diffèrent que par l'activation de AU 4 ou AU 5. Cette confusion peur–surprise documentée a des implications directes pour la stratégie de détection adoptée dans ce projet. La confusion a été confirmée empiriquement : HSEmotion attribue fréquemment un arousal élevé mais une probabilité de peur sous le seuil lors d'événements de peur véritables. Cette observation a directement influencé la stratégie du projet d'intégrer des métriques d'arousal pour récupérer ces événements mal classifiés (Chapitre 6).

2.2. PHOTOPLETHYSMOGRAPHIE À DISTANCE ET DÉTECTION EN FAIBLE LUMINOSITÉ

Acharya et al. (2025) évaluent 8 méthodes rPPG sur 45 participants dans 4 conditions d'éclairage et d'activité. La méthode POS atteint une erreur absolue moyenne de 1.1 BPM, surpassant les approches d'apprentissage profond. Un paradoxe important est identifié : la précision se dégrade lorsque la fréquence cardiaque est élevée — précisément quand la mesure est la plus critique pour un système adaptatif. Cette découverte a établi POS comme le candidat principal pour le pipeline rPPG du projet, qui a ensuite été soumis à des tests d'optimisation exhaustifs (Section 6.5.1). Le paradoxe rPPG a été atténué par la normalisation z-score, qui capture les changements relatifs de BPM plutôt que les valeurs absolues.

Wang et al. (2017) fournissent une analyse complète des familles d'algorithmes rPPG utilisant le modèle de réflexion cutanée dichromatique. Un benchmark sur 60 vidéos établit une hiérarchie de performance : $G < PCA < ICA < CHROM \approx PBV < 2SR < POS$, avec POS atteignant le SNR global le plus élevé (5.16 dB contre 3.86 dB pour CHROM). Une distinction clé est que CHROM utilise un a priori fixe de teinte cutanée, le rendant vulnérable à l'éclairage non blanc, tandis que POS élimine les variations d'intensité par projection orthogonale sans hypothèse de teinte cutanée — une propriété pertinente pour l'éclairage coloré émis par un moniteur de jeu. Cette hiérarchie algorithmique a mis en évidence les risques du moyennage naïf multi-algorithmes et a justifié l'isolation de méthodes de projection robustes comme POS pour les environnements de jeu (Section 6.5).

Moghimi & Grailu (2024) identifient la région rPPG optimale indépendante du sujet en utilisant la décomposition en superpixels sur un jeu de données enregistré avec une webcam Logitech HD C270 à 640×480 et 25 FPS. Leur analyse converge vers le **milieu du front, englobant le passage de la veine supratrochléaire**, comme ROI optimal, atteignant $>98\%$ de précision de fréquence cardiaque. Ils documentent en outre que les régions avec des signaux pulsatiles forts produisent des estimations peu fiables lorsque des mouvements faciaux non rigides corrompent le signal, et concluent que le bas du visage doit être exclu dans les contextes d'expression intense. Cette découverte a guidé le projet vers la priorisation du haut du visage pour l'extraction rPPG et l'exclusion rigoureuse du bas du visage dans notre contexte horrifique à forte expression.

2.3. FUSION MULTIMODALE

Yan et al. (2024) présentent une méthode de fusion multimodale (SLSMKCCA) combinant visage, voix et geste, démontrant la supériorité de l'approche trimodale sur l'unimodale. Le résultat central — que chaque modalité supplémentaire produit des gains de précision consistants — soutient l'approche de fusion au niveau décisionnel adoptée dans ce projet.

Karani & Desai (2022) passent en revue les stratégies de fusion (au niveau des caractéristiques, au niveau décisionnel, hybride) et concluent que la fusion hybride atteint la meilleure précision (66.67 %), mais que **la fusion au niveau décisionnel est plus robuste lorsque les modalités ont des résolutions temporelles différentes** — ce qui correspond au cas d'usage ici (FER à 30+ fps, rPPG à ~ 0.33 Hz). La formule d'augmentation multiplicative F15 (Chapitre 5) implémente ce principe de niveau décisionnel, fusionnant les scores FER avec la normalisation BPM dérivée du rPPG à leurs taux respectifs.

2.4. BIOFEEDBACK ET ADAPTATION AFFECTIVE

Hossan et al. (2025) étudient l’adaptation affective basée sur la fréquence cardiaque dans un jeu Flappy Bird adapté avec 25 participants équipés d’une Pixel Watch. Leurs résultats montrent une augmentation de l’affect positif au niveau d’adaptation le plus élevé, validant l’approche « objectif + adaptatif ». L’avancée clé de ce projet par rapport à leur travail est le remplacement de la montre connectée dédiée par un rPPG par webcam uniquement et l’ajout de l’expression faciale comme seconde modalité pour une estimation plus riche de l’état émotionnel.

Moschovitis & Denisova (2022) proposent **Caroline**, un jeu d’horreur à la première personne utilisant un capteur auriculaire Arduino pour mesurer la fréquence cardiaque et implémenter un mécanisme « Relax-to-Win ». Avec 42 participants, ils démontrent une motivation intrinsèque accrue grâce au biofeedback. Notamment, les deux systèmes reposent sur un signal physiologique unique (fréquence cardiaque) mesuré par un capteur dédié — aucun travail recensé ne combine plusieurs modalités biométriques au sein d’un jeu. Combler cette lacune est la contribution centrale du présent projet : un pipeline multimodal (FER + rPPG) à partir d’une seule webcam grand public, remplaçant les capteurs dédiés par une estimation sans contact.

Yang et al. (2026) traitent le décalage des coefficients de blendshape entre les sujets individuels et le modèle d’activation faciale standardisé dans un contexte VR. Ils proposent le Blendshape Distribution Alignment (BDA), une étape de calibration légère (<1 ms) utilisant la régression linéaire pour mapper la plage d’activation des blendshapes d’un individu vers un espace d’entrée canonique. Cette technique est directement pertinente pour la variabilité inter-sujets des blendshapes — un défi devenu prééminent dans ce projet. F8 (mp_tension seul) a atteint un $F1 = 0.065$ à travers les sujets en raison des différences de morphologie au repos, confirmant le besoin de calibration. La calibration de type BDA reste le candidat principal pour les améliorations futures (Chapitre 8).

Shao et al. (2025) traitent la précision rPPG dans des scénarios d'éclairage variable en utilisant le découplage d'interférence de fond : une ROI de référence non cutanée capture le bruit environnemental commun au visage et à son environnement, qui est ensuite soustrait du signal rPPG facial. Cette approche est pertinente pour les contextes de jeu où les flashes du moniteur constituent une source de bruit partagée corrompant les valeurs RGB faciales. L'infrastructure de ROI de fond a été construite dans ce projet (canaux RGB de fond capturés dans le pipeline d'extraction rPPG) mais la soustraction n'a pas été appliquée, car POS a atteint un $MAE = 2.96$ BPM sans elle. Le découplage d'interférence de fond reste disponible comme amélioration future.

2.5. CONFIDENTIALITÉ EN INFORMATIQUE AFFECTIVE

Gutiérrez et al. (2025) démontrent la faisabilité de l'apprentissage fédéré avec chiffrement AES-256 pour la reconnaissance des émotions, atteignant 87 % de précision tout en préservant la confidentialité. Leur travail démontre que des garanties de confidentialité fortes et une précision de reconnaissance compétitive ne sont pas mutuellement exclusives — validant la décision de conception de traiter toutes les données localement.

Les lacunes et défis ouverts identifiés dans cette revue sont synthétisés dans le chapitre suivant, qui formule le problème spécifique abordé par ce projet.

3. DÉFINITION DU PROBLÈME

3.1. LACUNES IDENTIFIÉES

La revue de la littérature révèle quatre lacunes cumulatives dans le domaine de l'informatique affective appliquée aux jeux vidéo.

3.1.1. Robustesse FER en faible éclairage

La majorité des benchmarks FER sont réalisés sous éclairage contrôlé (Kopalidis et al., 2024). Les meilleurs modèles atteignent 75.98 % de précision en conditions standard (Li et al., 2025), mais leur fiabilité sous l'éclairage faible et dynamiquement changeant d'un jeu d'horreur — où le moniteur est la seule source de lumière — n'est pas documentée.

3.1.2. Le paradoxe rPPG sous stress

La précision rPPG se dégrade lorsque la fréquence cardiaque est élevée (Acharya et al., 2025), précisément quand la mesure est la plus critique dans un jeu d'horreur. Ce paradoxe n'a pas été étudié dans un contexte de jeu, où les pics de stress sont les moments les plus informatifs pour un système adaptatif.

3.1.3. Fusion de modalités à résolutions temporelles différentes

La fusion au niveau décisionnel entre des modalités opérant à des résolutions temporelles fondamentalement différentes (FER à 30+ fps, rPPG à ~ 0.33 Hz) n'a pas été validée dans un contexte de jeu (Karani & Desai, 2022). La question de comment combiner un signal d'expression faciale instantané avec un signal physiologique à évolution lente reste ouverte.

3.1.4. Biofeedback à signal unique

Les systèmes de biofeedback existants dans les jeux reposent sur un signal physiologique unique, typiquement la fréquence cardiaque par contact (Moschovitis & Denisova, 2022; Hossan et al., 2025). Aucun travail recensé ne combine la reconnaissance des émotions faciales et la photopléthysmographie à distance au sein d'un jeu, et aucun travail recensé n'utilise la webcam comme capteur biométrique unique.

Résultat : Un pipeline multimodal entièrement fonctionnel a été construit à partir d'une seule webcam grand public, et un prototype de jeu d'horreur Unity 3D implémentant la mécanique Relax-to-Win a été développé. Une panne matérielle a empêché l'expérience prévue avec des participants ; l'évaluation a été réalisée à travers un protocole basé sur vidéo à la place (Chapitre 7).

3.2. ÉNONCÉ DU PROBLÈME

Ces lacunes ne sont pas indépendantes — elles se cumulent. Le FER et le rPPG ont chacun été étudiés isolément, mais aucun travail ne les combine en un pipeline unique pour les applications de jeu en temps réel. Cette lacune est amplifiée par trois défis non résolus : la précision FER se dégrade sous le faible éclairage typique des jeux d'horreur, la précision rPPG chute précisément quand les pics de fréquence cardiaque sont les plus informatifs, et aucune stratégie de fusion n'a été validée pour des modalités opérant à des résolutions temporelles différentes dans un contexte de jeu.

3.3. ANALYSE SWOT

Le Tableau 3.1 présente l'analyse SWOT telle qu'évaluée au départ, annotée avec les résultats rétrospectifs en *italique*.

Tableau 3.1 : Analyse SWOT du projet (annotations rétrospectives en *italique*)

Forces	Faiblesses
• Pipeline indépendant : testable en isolation • Architecture modulaire avec repli progressif • Traitement local (confidentialité) • Outils open-source matures (MediaPipe, OpenCV) • Très faible latence MediaPipe (~ 6 ms)	• Dépendance à une seule caméra — pas de capteur de secours • Taille d'échantillon attendue faible limite la puissance statistique • Contrôle limité de l'éclairage du visage du joueur
Opportunités	Menaces
• Adoption industrielle croissante de la biométrie par webcam (Affectiva, iMotions) • Architecture réutilisable pour des applications thérapeutiques • Les scores continus valence-arousal complètent les catégories discrètes • Les blendshapes MediaPipe permettent des métriques personnalisées	• Le rPPG peut manquer de sensibilité pour capturer les changements cardiaques induits par la peur • La dégradation FER en faible lumière peut dépasser les seuils acceptables • Difficulté de recrutement des participants • Risque de dépasser le budget de latence de 100 ms

La panne matérielle a forcé un pivot de l'expérience contrôlée prévue vers un protocole d'évaluation basé sur vidéo, qui a finalement produit un groupe de sujets plus diversifié. La manière dont chaque menace a été résolue (ou non) est documentée au Chapitre 7.

Le Chapitre 4 présente les choix méthodologiques effectués pour combler ces lacunes.

4. MÉTHODOLOGIES ET MODÈLES

Ce chapitre présente les outils, algorithmes, contraintes et protocoles d'évaluation sélectionnés pour combler les lacunes identifiées au Chapitre 3. Les sections suivent le flux de données du pipeline, puis présentent la conception expérimentale et le cadre d'évaluation — y compris toutes les définitions de métriques dont le lecteur aura besoin avant de rencontrer les résultats.

4.1. ENVIRONNEMENT DE DÉVELOPPEMENT ET CONTRAINTES

Le Tableau 4.1 détaille les spécifications matérielles de développement. Après la panne de la machine principale mi-avril 2026 (Chapitre 7, Section 7.5), le développement s'est poursuivi sur la machine secondaire. Les deux machines utilisent des webcams 720p à 30 FPS ; les benchmarks de latence dans ce chapitre ont été réalisés sur le matériel Acer principal sauf indication contraire.

Tableau 4.1 : Spécifications matérielles de développement

Composant	Machine principale	Machine secondaire
Modèle	Acer Predator Helios Neo 18	Monster Abra A7 V11.2
CPU	Intel Core i9-14900HX @ 2.20 GHz / 5.80 GHz	Intel Core i7-10750H @ 2.60 GHz / 5.0 GHz
GPU	NVIDIA RTX 4070 8 Go GDDR6	NVIDIA GTX 1650 4 Go GDDR6
RAM	16 Go (8×2) DDR5-5600	16 Go (8×2) DDR4-2933
OS	Windows 11	Ubuntu 24.04 LTS

Le pipeline de détection est développé en Python 3.12 dans un environnement Conda isolé. Le prototype de jeu est développé sous Unity 2022.3 LTS avec le Universal Render Pipeline (URP) en 3D à la première personne.

Le projet impose des contraintes explicites qui ont guidé chaque décision de conception :

Économique : Le système doit fonctionner avec une webcam grand public (720p, 30 FPS) comme seul capteur requis. Aucun matériel biométrique dédié n'est nécessaire. Tous les composants logiciels sont open-source et gratuits : Python 3.12, MediaPipe (Apache 2.0), HSEmotion (MIT), NumPy, SciPy, OpenCV. Unity Personal (licence gratuite) est utilisé pour le jeu.

Éthique : Tout le traitement vidéo est effectué localement. Les images sont traitées en RAM et immédiatement supprimées ; aucune vidéo faciale n'est persistée sur disque. Les journaux CSV ne contiennent que des valeurs numériques anonymisées (scores d'émotions, estimations BPM, métriques de latence), identifiées par des codes participants (S01, S02, etc.). Le protocole d'évaluation basé sur vidéo (Design v3, Section 4.5) utilise des vidéos de réaction horripilante YouTube publiquement disponibles ; ces sujets n'ont pas été contactés ni notifiés de leur inclusion dans cette étude, car leur contenu est déjà public. En revanche, les participants locaux qui ont effectué les tests de validation FER et rPPG ont fourni un consentement verbal éclairé pour que leurs enregistrements vidéo et les métriques dérivées soient utilisés dans cette étude.

Environnemental : Les sessions de jeu se déroulent sous éclairage dynamique de moniteur uniquement ($\sim 50\text{--}100$ lux, variable). Les changements de couleur de l'écran pendant les moments de haute intensité affectent directement les valeurs RGB utilisées par les algorithmes rPPG. Le mouvement naturel du joueur (hochements de tête, penchements, expressions réactives) est préservé dans le protocole pour refléter les conditions d'utilisation réelles.

4.2. OUTILS DE RECONNAISSANCE DES ÉMOTIONS FACIALES

Plusieurs outils FER ont été évalués comme candidats pour le module de détection. Le Tableau 4.2 liste les candidats et leurs types de sortie.

Tableau 4.2 : Outils FER candidats

Outil	Sortie	Notes
MediaPipe	52 blendshapes	Activations musculaires faciales brutes
HSEmotion	V-A + 8 émotions	Backbone EfficientNet-B0
DeepFace	7 émotions catégorielles	Multi-backend (VGG-Face, ArcFace)
Py-Feat	AUs + émotions + landmarks	Boîte à outils orientée recherche

Les mesures préliminaires de latence (Tableau 4.3) ont déterminé la sélection des outils.

Le modèle AU XGBoost n’a pas de voie d’accélération GPU, et l’API exige des entrées par chemin de fichier, forçant une écriture/lecture JPEG temporaire par image. Même avec l’accélération GPU (RTX 4070), la latence n’a diminué que de 27 % (1143 ms → 863 ms) car les étapes liées au CPU dominent. Py-Feat est architecturalement conçu pour l’analyse FACS par lots hors ligne, pas pour l’inférence en direct, et est catégoriquement inadapté au budget temps réel de < 100 ms.

DeepFace utilise un seul passage direct CNN de bout en bout sans extraction AU intermédiaire ni E/S fichier, le rendant $20\times$ plus rapide que Py-Feat. Cependant, à 41.8 ms (23.9 FPS) il est $4.4\times$ plus lent que HSEmotion (9.6 ms) car DeepFace encapsule des backends de reconnaissance faciale lourds (VGG-Face) non optimisés pour l’inférence légère d’émotions. Il ne fournit également que 7 émotions catégorielles sans scores continus valence-arousal, limitant son utilité pour la détection graduelle de la peur requise dans ce projet.

Tableau 4.3 : Latence d’inférence FER — benchmark contrôlé (Acer Predator, éclairage intérieur standard). Les valeurs en régime permanent excluent le préchauffage du modèle à la première image. FPS = 1000 / latence moyenne.

Outil	Moy. (ms)	Méd. (ms)	P95 (ms)	FPS eff.
MediaPipe	6.7	6.2	10.4	149.3
HSEmotion	9.6	9.3	11.4	104.2
DeepFace	41.8	40.9	48.9	23.9
Py-Feat (GPU)	863	—	—	1.2

La paire principale sélectionnée est **MediaPipe + HSEmotion**, fonctionnant simultanément dans une boucle d’images partagée. La formule de détection de peur en production **F12** (*hybrid_amp*, définie au Chapitre 5 et au Chapitre A) fusionne la classification HSEmotion avec les blendshapes MediaPipe à travers une architecture multiplicative. Cette approche hybride capture les changements émotionnels graduels que les étiquettes purement catégorielles manqueraient : les blendshapes distinguent le stress (mâchoire serrée) de la tristesse (bouche relâchée) — une distinction impossible avec une étiquette catégorielle seule. La variante augmentée par rPPG **F15** (*rppg_amp*) étend F12 avec des données cardiaques (Chapitre 5).

L’évaluation prévue de YOLOv7 (Alqahtani et al., 2025) comme détecteur facial de repli en basse lumière a été remplacée par une approche **hybride Haar + MediaPipe Face-Landmarker**. MediaPipe FaceLandmarker — déjà présent pour l’extraction des blendshapes — gère les scénarios de faible luminosité et de faible contraste, sans ajouter de nouvelle dépendance. Le déploiement d’un checkpoint YOLOv7 parallèlement au pipeline existant augmenterait la pression mémoire GPU sans bénéfice mesurable par rapport à un outil déjà en cours d’exécution dans le même processus.

4.3. PHOTOPLÉTHYSMOGRAPHIE À DISTANCE (RPPG)

Pour estimer la fréquence cardiaque sans capteur dédié, le système utilise le rPPG à partir du flux vidéo de la webcam. Les méthodes de traitement du signal ont été privilégiées pour le pipeline en direct : elles opèrent sur des fenêtres glissantes avec un calcul quasi temps réel, tandis que les méthodes d'apprentissage profond nécessitent 100–400 ms par segment sur GPU.

La stratégie rPPG initiale utilisait une approche CONSENSUS : une moyenne pondérée par le SNR de cinq algorithmes (CHROM, POS, GREEN, ICA, WAVELET). La logique était que la combinaison de plusieurs algorithmes moyennait les faiblesses individuelles. Cependant, les algorithmes avec de grandes erreurs absolues (GREEN, WAVELET) peuvent encore franchir le seuil de vote $\text{SNR} \geq 2.0$, diluant l'estimation supérieure de POS. Cette limitation a produit une réponse cardiaque de peur quasi nulle sous CONSENSUS ($d = 0.042$) comparée à un effet moyen à large sous POS seul ($d = 0.696$), motivant le passage à l'extraction POS uniquement dans le pipeline de production (Chapitre 6). Les définitions formelles des algorithmes figurent dans le glossaire technique (Chapitre A).

4.4. STRATÉGIE DE FUSION ET MÉCANISME D'ADAPTATION

La stratégie de fusion combine les sorties FER par fusion au niveau décisionnel (Karani & Desai, 2022), produisant le score composite de peur **F12** (*hybrid_amp*) transmis au jeu via TCP. Lorsque les données rPPG sont disponibles, la variante augmentée **F15** (*rppg_amp*) applique un amplificateur cardiaque multiplicatif à F12. Les deux formules sont formellement définies au Chapitre 5. Avant la détection d'événements, le signal composite est lissé sur une fenêtre glissante de 50 images (≈ 1.67 s à 30 fps) pour supprimer le bruit de classification image par image — une pratique standard motivée par l'instabilité temporelle identifiée par Savchenko (2025).

La communication entre le pipeline Python et Unity utilise TCP sur localhost:5005. TCP a été sélectionné plutôt qu'UDP car la livraison fiable et ordonnée est préférable pour la transmission d'état affectif où les paquets perdus causeraient un comportement d'adaptation discontinu.

Le jeu implémente un mécanisme d'adaptation « Relax-to-Win » (Moschovitis & Denisova, 2022; Hossan et al., 2025) : les réactions de l'IA ennemie changent en réponse à l'état émotionnel détecté du joueur, tandis que le level design et le placement des ennemis restent statiques. Le joueur navigue dans le jeu sans être détecté ; quand le pipeline détecte une peur élevée, les IA ennemies prennent conscience et initient la poursuite. Contrairement à l'ajustement traditionnel de difficulté qui modifie les paramètres structurels du jeu, l'adaptation opère exclusivement au niveau comportemental.

4.5. CONCEPTION EXPÉRIMENTALE

La conception expérimentale a évolué à travers trois itérations, chacune motivée par une limitation découverte dans la version précédente.

Design v1 (3 conditions, intra-sujets) : Trois conditions — caméra éteinte (ligne de base), caméra allumée avec IA fixe, caméra allumée avec IA active.

Design v2 (2 conditions, simple aveugle) : La caméra reste toujours active, éliminant le facteur de confusion lié à la présence de la caméra.

Design v3 (évaluation basée sur vidéo) : La panne matérielle a interrompu le développement du jeu (Chapitre 7, Section 7.5). La validation utilise un protocole basé sur vidéo : 6 à 12 sujets issus de vidéos YouTube de réactions horribles sont traités par le pipeline. Les événements de peur sont annotés manuellement par revue directe de la vidéo. Les détections du pipeline sont évaluées contre la vérité terrain manuelle en utilisant la précision, le rappel et le F1-score au niveau événementiel. Cette approche fournit des sujets diversifiés, une vérité terrain révisable et des conditions contrôlées pour comparer les variantes de formules.

L'expérience de jeu à 2 conditions (Design v2) reste l'objectif à long terme. L'évaluation basée sur vidéo valide que le pipeline se généralise à travers les sujets avant de le déployer dans un contexte de jeu en direct où la vérité terrain est plus difficile à établir.

4.6. CADRE D'ÉVALUATION

Cette section définit toutes les métriques utilisées dans les évaluations rapportées au Chapitre 6. Ces définitions fournissent le contexte méthodologique nécessaire pour interpréter les résultats expérimentaux qui suivent. Les définitions mathématiques formelles figurent dans le glossaire technique (Chapitre A) ; les explications en langage courant figurent dans le glossaire simplifié (Chapitre B).

4.6.1. Méthodologie de vérité terrain

La vérité terrain est produite par annotation purement manuelle et événementielle : l'annotateur examine indépendamment chaque vidéo source sans accès aux sorties des formules, enregistrant les limites des événements de peur sur la seule base des expressions faciales visibles et des indices contextuels. Cette méthodologie était l'itération finale après que deux approches antérieures — l'auto-détection dérivée de formules (qui introduisait une dépendance circulaire) et les horodatages guidés par modèle (qui introduisaient un biais de modèle) — ont été identifiées et abandonnées.

Convention de comptage : Plusieurs déclenchements du pipeline à l'intérieur du même événement de vérité terrain comptent comme un seul vrai positif. Cette convention par événement (plutôt que par déclenchement) est adoptée car l'adaptation affective du jeu répond à des états de peur soutenus, pas aux comptages individuels de déclenchements.

4.6.2. Métriques FER

Métriques principales : Précision, rappel et F1-score au niveau événementiel (formellement définis dans le glossaire technique, Chapitre A). Une haute précision (peu de fausses alarmes) est prioritaire pour le contexte de jeu, où les fausses détections brisent l'immersion.

Détecteur d'événements à fenêtre glissante : L'algorithme de détection utilise quatre paramètres configurables :

- `threshold` : valeur minimale du signal pour considérer une image comme active.
- `min_frames` : nombre minimal d'images actives consécutives pour ouvrir une fenêtre de détection.
- `window_size` : images à examiner en avant lors de la fusion d'activations proches.
- `fill_ratio` : pourcentage minimal d'images actives dans une fenêtre.

Un remplissage temporel (`pad_start` = -0.5 s, `pad_end` = $+1.0$ s) est appliqué autour des événements de vérité terrain pour l'appariement, tenant compte de l'incertitude aux limites d'annotation.

Ratio de discrimination peur/colère (Phase 2 uniquement) : Ratio du score composite moyen pendant les événements de peur versus les événements de colère, utilisé comme métrique précoce avant l'adoption du F1 au niveau événementiel.

4.6.3. Métriques rPPG

La précision rPPG est évaluée en utilisant la MAE et le RMSE contre la vérité terrain de la montre connectée, complétés par la corrélation de Pearson et le biais signé. La réponse cardiaque de peur est quantifiée par le d de Cohen (différence moyenne standardisée entre le BPM des événements de peur et hors peur). Les définitions formelles figurent dans le glossaire technique (Chapitre A).

Méthodologie d'évaluation cross-modale : L'analyse de corrélation $\text{rPPG} \times \text{FER}$ a balayé plusieurs configurations d'algorithme, de taille de fenêtre et de pas, avec les tests multiples contrôlés par permutation familiale (FWER) : les étiquettes peur/non-peur ont été mélangées 10 000 fois par test, enregistrant la meilleure valeur p à travers toutes les configurations par mélange. La valeur p corrigée est la fraction des permutations dont le meilleur p était $\leq$ au meilleur p observé.

4.6.4. Métriques de performance système

La latence de bout en bout est décomposée comme suit :

$$L_{\text{total}} = L_{\text{caméra}} + L_{\text{détection}} + L_{\text{analyse}} + L_{\text{formule}} + L_{\text{socket}} \quad (4.1)$$

Le budget de 100 ms (Section 1.2) correspond à un minimum de 10 mises à jour affectives par seconde. La boucle de rendu du jeu et le pipeline d’analyse Python sont découplés : Unity rend à 30+ FPS pour un gameplay fluide, tandis que le pipeline Python produit des mises à jour d’état affectif à 10–20 FPS selon la charge d’inférence (~ 50 ms par image pour MediaPipe + HSEmotion combinés). Les mises à jour arrivent de manière asynchrone via TCP ; le composant `AffectiveSmoothing` du jeu interpole entre elles en utilisant un lissage exponentiel, de sorte que le comportement adaptatif (IA ennemie, audio) apparait continu au joueur malgré le taux d’analyse plus faible. Si une mise à jour du pipeline arrive en retard ou est perdue, le jeu continue avec le dernier état affectif connu — la boucle de rendu ne se bloque jamais en attendant la sortie d’analyse.

La couverture de détection faciale est mesurée comme le pourcentage d’images vidéo où un visage est détecté avec succès et disponible pour le traitement FER et rPPG en aval.

Le Chapitre 5 traduit ces choix méthodologiques en une architecture système concrète.

5. CONCEPTION ET IMPLÉMENTATION DU SYSTÈME

Ce chapitre traduit les choix méthodologiques du Chapitre 4 en un système concret. Il définit chaque formule, algorithme et élément architectural une seule fois et de manière définitive. Les chapitres suivants font référence à ces définitions par étiquette plutôt que de les reformuler.

5.1. ARCHITECTURE DU PIPELINE

Le système est structuré en quatre modules. La Figure 5.1 présente l'architecture finale.




Figure 5.1 : Architecture finale du pipeline — les flèches pleines indiquent les signaux principaux ; les flèches en pointillés indiquent les canaux modificateur et d'augmentation

Module 1 — Acquisition : Capture vidéo via webcam grand public, prétraitement (conversion RGB, normalisation).

Module 2 — Détection : Trois branches d'analyse parallèles : HSEmotion (softmax à 8 classes → probabilités de peur et de 7 autres émotions, plus scores continus valence-arousal), MediaPipe (52 blendshapes → score de tension continu), et rPPG (algorithme POS → estimation BPM).

Module 3 — Fusion : Application de la formule composite de peur (Section 5.5), produisant un score de peur unique par image.

Module 4 — Adaptation (Unity) : L'IA ennemie reçoit le score de peur via TCP et ajuste son comportement.

L'architecture implémente une stratégie de dégradation progressive :

- **Tier 1** : FER + rPPG + Fusion → Expérience complète
- **Tier 2a** : FER uniquement → Si le signal rPPG est trop bruité
- **Tier 2b** : rPPG uniquement → Si la confiance FER est trop faible
- **Tier 3** : Saut d'images → Traitement d'une image sur N
- **Tier 4** : Comportement fixe par défaut → Pipeline désactivé ; l'IA ennemie revient à une patrouille fixe

Le Tier 1 est le mode de production : l'approche rPPG CONSENSUS initiale a dilué les performances de POS (Section 6.5.3), mais l'isolation de POS a restauré un canal cardiaque utilisable, permettant la fusion complète. F15 (POS@30s/3s, $c=0.5$) à $\theta=0.80$ atteint un $F1=0.7660$ (+4.69 pp par rapport à la base F12) tout en préservant 90 % de précision (Section 6.5.5). Le Tier 2a (FER uniquement via F12, $\theta=0.70$) sert de repli lorsque la qualité du signal rPPG est insuffisante. Le Tier 4 correspond à la Condition A dans la conception expérimentale.

5.2. PRÉTRAITEMENT D'IMAGE : CLAHE

Avant la classification des émotions, chaque découpe faciale détectée subit une égalisation adaptative d'histogramme à contraste limité (CLAHE) sur le canal de luminosité. L'image est convertie de BGR vers l'espace colorimétrique CIELAB ; CLAHE est appliqué au canal L ($\text{clipLimit} = 2.0$, $\text{tileGridSize} = 4 \times 4$), puis l'image est reconvertie. Cela améliore localement le contraste sans amplifier le bruit du capteur, compensant l'éclairage faible et inégal typique d'une configuration de jeu où le moniteur est la source de lumière dominante — et parfois unique. CLAHE est appliqué après le recadrage facial pour cibler spécifiquement le contraste cutané, et non les régions d'arrière-plan. Il est activé par défaut et peut être désactivé via un drapeau `--no-clahe` pour l'ablation.

5.3. DÉTECTION FACIALE HYBRIDE

Chaque image passe par une étape de détection faciale hybride avant l'analyse émotionnelle. La cascade de Haar (OpenCV) tente la détection primaire ; en cas d'échec, MediaPipe FaceLandmarker fournit un maillage facial à 478 points à partir duquel une boîte englobante est dérivée. Un remplissage de 15 % est appliqué au recadrage pour inclure le contexte environnant pour HSEmotion. La stratégie hybride atteint une couverture de détection faciale quasi complète dans toutes les conditions d'éclairage, surmontant la dégradation sévère de Haar sous éclairage faible de moniteur uniquement (Section 6.3.3). L'organigramme est présenté dans la Figure 5.2.




Figure 5.2 : Organigramme de la détection faciale hybride

5.4. TRAITEMENT DU SIGNAL RPPG

5.4.1. Algorithme POS

L'algorithme Plane-Orthogonal-to-Skin (POS) (Wang et al., 2017) construit un signal de pouls S à partir des moyennes RGB temporellement normalisées $(\hat{R}, \hat{G}, \hat{B})$:

$$S = (\hat{G} - \hat{B}) + \alpha (\hat{G} + \hat{B} - 2\hat{R}) \quad (5.1)$$

avec $\alpha = \sigma_{H_1} / \sigma_{H_2}$ adaptatif, où $H_1 = \hat{G} - \hat{B}$ et $H_2 = \hat{G} + \hat{B} - 2\hat{R}$. POS élimine les variations d'intensité par projection orthogonale sans hypothèse de teinte cutanée, le rendant robuste à l'éclairage coloré émis par un moniteur de jeu — contrairement à CHROM, qui repose sur un a priori de teinte cutanée fixe.

Le signal S est filtré passe-bande (Butterworth d'ordre 4, 1.0–3.0 Hz = 60–180 BPM), puis analysé par FFT sur une fenêtre glissante configurable. La fréquence dominante est affinée par interpolation parabolique du pic FFT. Parmi les cinq algorithmes rPPG évalués (POS, CHROM, GREEN, ICA, WAVELET), POS a atteint le SNR le plus élevé et la MAE la plus faible contre la vérité terrain de la montre connectée (Section 6.5.1), motivant sa sélection comme seul algorithme de production (voir Annexe A pour les comparaisons d'algorithmes).

5.4.2. Stratégie ROI

Suivant Moghimi & Grailu (2024), le `MultiROIExtractor` définit trois ROI faciales via les landmarks MediaPipe Face Mesh : *front* (principal, au-dessus de la veine supra-trochléaire), *glabell*e (entre les sourcils), et *malaire* (pommettes supérieures). Chaque ROI est masquée par polygone et vérifiée indépendamment pour la peau ($\geq 60\%$ de pixels cutanés dans l'espace colorimétrique HSV). Le signal principal suit une chaîne de repli front-d'abord : *front* $\rightarrow$ *glabell*e $\rightarrow$ *malaire*, assurant une extraction rPPG continue même lorsque le front est occlus — comme lorsque les joueurs se couvrent le visage pendant les réactions de frayeur, précisément les moments les plus pertinents pour la détection de la peur.

Une ROI de fond (50×50 px en haut à gauche) est capturée et écrite dans le CSV pour un éventuel découplage d'interférence (Shao et al., 2025), mais l'étape de soustraction n'est pas appliquée en production.

5.5. FORMULE COMPOSITE DE PEUR

5.5.1. Architecture de la formule

La formule de production, désignée **F12** (*hybrid_amp*), est :

$$F12 = (0.7 \times \text{hs_fear} + 0.3 \times \text{hs_arousal}) \times (1 + \text{mp_tension}) \quad (5.2)$$

Cette conception combine deux canaux HSEmotion : *hs_fear* comme signal de détection principal (70 %) et *hs_arousal* comme canal secondaire (30 %) qui capture les événements où l'arousal est élevé mais la probabilité de peur reste sous le seuil — un schéma cohérent avec la confusion peur-surprise documentée par Abdeldayem et al. (2026). Le modificateur multiplicatif *mp_tension* amplifie les détections quand les deux modèles s'accordent sur un moment pertinent pour la peur. Quand seul HSEmotion se déclenche, la détection procède au niveau de base ; quand seul MediaPipe se déclenche, le score reste proche de zéro car les canaux HSEmotion dirigent le produit.

La formule a atteint cette forme à travers une évaluation multi-phases sur six sujets et 88 événements de vérité terrain. Aux paramètres d'évaluation verrouillés ($\theta=0.70$, *min_frames*=5, *window*=10, *fill*=65 %), F12 atteint un F1 combiné de 0.6971, avec cinq des six sessions regroupées dans la plage $F1=0.67\text{--}0.78$ (Section 6.4.2). L'évolution depuis les candidats précédents et le raisonnement derrière chaque décision de conception sont documentés au Chapitre 6.

5.5.2. Score de tension MediaPipe

L'entrée `mp_tension` de F12 est calculée à partir des 52 blendshapes faciaux de MediaPipe via la formule **v5e**. Les activations brutes des blendshapes sont regroupées en trois catégories fonctionnelles :

- **Groupe stress** (pression buccale, froncement nasal, élévation de la lèvre supérieure, gonflement des joues) — somme pondérée capturant le serrement de mâchoire et la tension nasale.
- **Groupe contexte** (sourcils baissés, yeux plissés, bouche tombante) — modulé par un multiplicateur de contexte qui atténue le signal pendant la concentration ($\times 0.2$), la joie ($\times 0.25$), ou la tristesse ($\times 0.5$) pour réduire les faux positifs liés à une tension faciale non liée à la peur.
- **Groupe peur** (sourcil interne levé, yeux écarquillés G/D, bouche ouverte) — conditionné par un facteur d'atténuation du sourire qui supprime l'activation lorsque des expressions faciales positives sont détectées, empêchant le rire d'être mal classifié comme de la peur.

Les trois scores de groupe sont mélangés avec une moyenne pondérée par rang ($0.50 \times \text{max} + 0.30 \times \text{moyen} + 0.20 \times \text{min}$), mis à l'échelle par un facteur de gain global de 1.8, et écrêtés à $[0, 1]$.

Contrôle automatique de gain (AGC) : Sous éclairage faible de moniteur uniquement, les amplitudes des blendshapes sont globalement supprimées, comprimant la tension brute dans une bande étroite (0.09–0.22) indépendamment du contenu émotionnel. Le module TensionAGC normalise la tension brute par rapport à une ligne de base ambiante adaptative à la session en utilisant une moyenne mobile exponentielle (décroissance = 0.9990, demi-vie ≈ 23 s à 30 FPS). Les 60 premières images avec visage détecté servent de période de rodage pendant laquelle la ligne de base ambiante converge avant toute production de sortie. Cela rend le score de tension indépendant de l'éclairage sans calibration manuelle. La variante v5e avec AGC a été sélectionnée à travers un balayage systématique de 81 configurations (9 variantes de formule $\times$ 9 paramètres de gain) ; en tant que modificateur multiplicatif, `mp_tension` fournit des gains de F1 par session de +12.5 à +19.0 pp (Section 6.3.2 ; explication simplifiée en Annexe B).

5.6. FORMULE D'AUGMENTATION RPPG

La formule augmentée, désignée **F15** (*rppg_amp*), applique une augmentation rPPG multiplicative au score composite basé sur le FER :

$$F15 = F12 \times (1 + c \cdot \text{bpm_norm}) \quad (5.3)$$

où $\text{bpm_norm} = \text{clip}((\text{BPM} - \text{baseline}) / \text{baseline}, 0, 1)$ avec une ligne de base en médiane glissante de 60 s, et c est le coefficient d'augmentation. La configuration de production utilise POS@30s/3s (fenêtre FFT de 30 s, pas de 3 s) avec $c = 0.5$. La configuration rPPG par défaut (fusion multi-algorithme CONSENSUS) diluait le signal précis de POS, produisant une réponse cardiaque de peur quasi nulle ($d=0.042$). Ce n'est qu'après l'isolation de POS et l'optimisation de la configuration de fenêtre qu'un effet significatif a émergé ($d=0.696$, p corrigé FWER=0.029 ; Section 6.5.3). Ce constat guide la stratégie de dégradation progressive : le Tier 2a (FER uniquement via F12) est le mode par défaut, avec

l'augmentation rPPG via F15 appliquée uniquement lorsque la qualité du signal POS est confirmée (Section 6.5.5).

5.7. STRATÉGIE DE DÉTECTION PAR COUCHES

5.7.1. Pipeline à quatre couches

Chaque image est traitée à travers quatre couches temporellement chaînées :

1. **Couche 1** (MediaPipe, ~ 6 ms) : extraction de 52 blendshapes faciaux $\rightarrow$ score continu `mp_tension`.
2. **Couche 2** (HSEmotion, ~ 10 ms) : classification softmax $\rightarrow$ `hs_fear`, `hs_arousal`, et 6 probabilités d'émotions supplémentaires.
3. **Couche 3** (formule, < 1 ms) : application de F12 (Éq. 5.2) $\rightarrow$ score `composite_fear`, lissé sur une fenêtre glissante de 50 images.
4. **Couche 4** (rPPG, thread en arrière-plan) : accumulation multi-ROI $\rightarrow$ estimation BPM mise à jour toutes les 3 s $\rightarrow$ augmentation multiplicative via F15 (Éq. 5.3).

5.7.2. Détecteur d'événements à double porte

Le signal composite lissé est traité par une machine à états à double porte qui convertit le score de peur continu en événements affectifs discrets :

- **Porte A (déclenchement)** : Un déclencheur basé sur la dérivée. La pente du signal lissé est calculée sur un tampon circulaire de 10 images (~ 0.33 s à 30 FPS). Quand la pente dépasse `onset_threshold`, un événement candidat commence (IDLE $\rightarrow$ ONSET).
- **Porte B (confirmation)** : Une porte de confirmation à fenêtre glissante. Le candidat doit accumuler au moins `min_frames = 5` images qualifiantes (`signal  $\geq$  threshold = 0.70`) dans une fenêtre glissante de `window_size = 10` images, avec un `fill_ratio = 65 %`.

Si la condition est remplie, le candidat est confirmé comme événement (ONSET $\rightarrow$ EVENT_CONFIRMED). Si le signal chute avant que la Porte B ne soit satisfaite, le candidat est annulé (ONSET $\rightarrow$ IDLE).

Un événement confirmé persiste jusqu'à ce que le signal descende sous un seuil de sortie (hystérésis), après quoi une période de refroidissement de 30 images (~ 1 s) empêche le redéclenchement sur la même décroissance de stimulus. La conception à double porte filtre les brefs pics de signal (la Porte A rejette les dérives lentes ; la Porte B rejette les pics transitoires), assurant que seuls les épisodes de peur soutenus sont enregistrés.

Le détecteur à double porte est un composant central du pipeline partagé entre les scripts d'analyse (`test_mp_hs.py`) et le jeu Unity. Les deux consommateurs reçoivent les mêmes sorties via TCP : l'état d'événement discret (IDLE/ONSET/EVENT_CONFIRMED) pour déclencher les événements de jeu tels que l'escalade comportementale de l'ennemi et les effets sonores, et le score F15 continu lissé ($\theta=0.80$) pour le comportement adaptatif instantané tel que la modulation de vitesse de l'ennemi et l'intensité du post-traitement.

5.8. IMPLÉMENTATION DU JEU UNITY

5.8.1. Concept du jeu

La Façade Fissurée est un jeu d'horreur 3D à la première personne où le joueur navigue dans un bâtiment abandonné faiblement éclairé tout en évitant la détection par les IA ennemies. La perspective à la première personne a été choisie plutôt que la conception 2D tilemap initialement prévue car elle maximise la proximité faciale avec la webcam et produit une immersion horrifique plus forte.

La mécanique de gameplay centrale est **Relax-to-Win** : l'IA ennemie devient plus agressive quand le joueur montre de la peur, créant une boucle de rétroaction positive que le joueur doit briser en se calmant activement. Quand le pipeline détecte une peur soutenue (via F12/F15 dépassant le seuil de détection), l'ennemi passe de WANDER à ALERT puis éventuellement CHASE. La seule défense du joueur est l'autorégulation émotionnelle — supprimer la peur visible pour désescalader l'ennemi. Cela inverse le paradigme conven-

tionnel du jeu d’horreur où la peur est une expérience passive : ici, l’état physiologique du joueur est une entrée de jeu active. La mécanique a une pertinence directe pour la thérapie d’exposition aux angoisses et phobies (Moschovitis & Denisova, 2022), où l’exposition contrôlée avec entraînement à l’autorégulation est une technique thérapeutique centrale.

5.8.2. Prototype v1 (validé)

Un prototype fonctionnel a été développé avec un niveau graybox de 4 salles, une IA ennemie basée sur NavMesh, et des déclencheurs de salle sûre. L’EnemyStateMachine implémente une machine à états finie à quatre états (Figure 5.3) :




Figure 5.3 : Machine à états finie ennemie à quatre états (prototype v1)

En Condition B (IA pilotée par biofeedback), la sensibilité de la transition WANDER→ALERT s’adapte au delta composite de peur reçu du pipeline. La sous-classe WandererEnemy implémente le câblage Condition A (IA fixe) et Condition B.

L’infrastructure expérimentale comprend : un SocketManager pour la communication TCP, un AffectiveSmoothing avec calibration de la ligne de base, un SessionLogger avec CSV de 26 colonnes par image, un ParticipantFlowManager avec un cycle de vie à 7 états (Figure 5.4), et un CalibrationSystem déguisé en « Scan de sécurité ». Ce prototype a servi de base pour l’évaluation du pipeline sur six sujets rapportée au Chapitre 6.




Figure 5.4 : Cycle de vie à 7 états du ParticipantFlowManager

5.8.3. Refonte v2.0 (en développement)

La disposition linéaire de 4 salles du prototype v1 offrait une prise de décision spatiale limitée : avec un seul chemin du début à la fin, le joueur n'avait pas d'options d'évasion significatives une fois que l'ennemi entrait en CHASE. La refonte v2.0 étend le niveau à 17 salles + 6 couloirs + 4 zones de jardin dans une emprise de bâtiment de 50×70 m (environ 3.5× la superficie utilisable d'origine), introduisant des boucles, des culs-de-sac et des passages étroits via une conception de bâtiment enveloppé dans un jardin. La durée cible de session est de 20 minutes.

Wanderer v2.0 étend la FSM v1 à cinq états (ajoutant POUNCE entre CHASE et COOLDOWN) et remplace le déclencheur unique par seuil de peur par trois canaux de détection indépendants : (1) un *cône de mouvement* (90° vers l'avant, 12 m de portée, occlusion par raycast) qui ne se déclenche que sur le mouvement du joueur — rester immobile rend le joueur invisible même à l'intérieur du cône ; (2) une *bulle d'audition de sprint* (360°, rayon de 7 m, occlusion par murs) qui détecte le sprint mais pas la marche ; et (3) un *ping de peur* (global, >15 m uniquement) qui lit `SmoothedCompositeFear` depuis le pipeline et navigue l'ennemi vers la position du joueur quand le score dépasse `fearThreshold`. Le ping de peur est le canal de biofeedback direct : il assure qu'une peur élevée attire l'ennemi quelle que soit la distance physique, tandis que les deux autres canaux gouvernent les rencontres à courte distance.

Watcher (nouvel ennemi) est une entité basée sur la proximité qui apparaît à 5–9 m du joueur, toujours en dehors du frustum de la caméra. Une fois apparu, une matrice de décision 2×2 de (le joueur le voit, le joueur a peur) détermine son comportement : le contact visuel direct gèle le Watcher quel que soit l'état de peur ; regarder ailleurs en étant calme le fait disparaître ; regarder ailleurs en ayant peur déclenche un STRIKE — une téléportation du côté opposé à la moitié de la distance, avec ≤ 4 m résultant en une séquence de game-over. La fréquence d'apparition se resserre par clé collectée à travers sept paliers (de ~ 17 min d'intervalle moyen à 0 clé à ~ 2 min à 6 clés), créant une tension croissante à mesure que le joueur progresse.

La conception v2.0 supprime la division Condition A/B : le biofeedback est toujours actif (équivalent à l'ancienne Condition B). Un système de collecte de six clés remplace la séquence de quatre objectifs v1 ; 6 clés sont tirées parmi 25 positions d'ancrage par session, et la collecte de clés pilote l'escalade du taux d'apparition du Watcher. La machinerie expérimentale v1 est préservée sous un drapeau de compilation (`#if EXPERIMENT_V1_LEGACY`) pour une éventuelle réactivation. Au moment de la rédaction, la géométrie du niveau et la FSM Wanderer v2.0 sont partiellement implémentées ; l'ennemi Watcher est partiellement implémenté.

5.9. ANALYSE DES COÛTS

Le Tableau 5.1 présente le budget de latence de bout en bout, mesuré dans des conditions contrôlées sur Video05_S02 (197 s, 30 FPS nominal).

Tableau 5.1 : Budget de latence du pipeline

Composant	Latence	Notes
Capture caméra	33 ms	Période d'image à 30 FPS
Détection Haar+MP	9 ms	Détection faciale hybride
Analyse HSEmotion	10 ms	EfficientNet-B0, mode CPU
Application de la formule	<1 ms	Arithmétique uniquement
Émission socket	1 ms	TCP localhost
Total	~53 ms	~19 FPS effectifs

La latence totale de ~53 ms est bien dans le budget de 100 ms établi à la Section 1.2. Le chiffre de 53 ms inclut la période d'image de la caméra (33 ms) ; quand la capture d'image chevauche l'inférence dans une architecture pipelinée, le débit effectif atteint 27–30 FPS.

L'utilisation CPU est asymétrique : MediaPipe utilise un runtime C++ optimisé à 4 % CPU, tandis que HSEmotion en mode CPU (PyTorch, pas de CUDA sous Windows) atteint en moyenne 67.5 % pendant le traitement hors ligne. Le pipeline rPPG s'exécute dans un thread en arrière-plan non bloquant : extraction ROI ≈ 1 ms par image, FFT toutes les 3 s (≈ 50 –100 ms, non bloquant).

6. RÉSULTATS

Ce chapitre présente les résultats expérimentaux sous forme de récit progressif à travers quatre phases du projet. La Phase 1 (développement du pipeline) a établi la chaîne d'outils et identifié la première limitation des seuils de blendshape de MediaPipe. La Phase 2 a conçu sept formules candidates (F0–F6) et sélectionné F2 à partir d'un benchmark préliminaire sur un seul sujet. La Phase 3 s'est étendue à trois sujets, a révélé l'effondrement de la fusion à poids égaux et a découvert l'architecture multiplicative. La Phase 4 a étendu l'évaluation à six sujets et 88 événements, a introduit le canal d'arousal qui a produit la formule de production verrouillée F12, et a validé l'augmentation rPPG sous la forme F15.

6.1. PHASE 1 : DÉVELOPPEMENT DU PIPELINE

La Phase 1 s'est concentrée sur la sélection des outils et l'architecture du pipeline. Quatre outils FER candidats ont été évalués : DeepFace, Py-Feat, HSEmotion et MediaPipe. MediaPipe (52 blendshapes faciaux, ~ 6 ms par image sur CPU) et HSEmotion (EfficientNet-B0, entraîné sur AffectNet, ~ 10 ms par image) ont été sélectionnés comme signaux principaux sur la base de forces complémentaires (Chapitre 5). Un test de calibration contrôlé sur le participant S01 a révélé que les seuils de blendshape de MediaPipe ne se généralisent pas aux sujets individuels : les plages d'activation brutes variaient de 3 à $5\times$ entre les sujets pour les mêmes expressions. Ce constat a motivé la stratégie de détection faciale hybride (cascade de Haar + MediaPipe) conçue pour maintenir la couverture sous des éclairages variables. Quatre algorithmes rPPG candidats (POS, CHROM, GREEN, PhysNet) ont été identifiés pour l'extraction du signal cardiaque ; l'implémentation a été reportée à la Phase 2. L'objectif de latence de bout en bout a été fixé à 200 ms (resserré ultérieurement à 100 ms en Phase 3). Aucune formule composite de peur n'a été créée en Phase 1 ; la conception conceptuelle d'une « formule de tension » combinant les signaux MediaPipe et HSEmotion a été planifiée pour la Phase 2.

6.2. PHASE 2 : PILOTE SUR SUJET UNIQUE (S02)

6.2.1. Comparaison des outils FER

Les trois outils FER candidats ont été évalués sur Video05_S02 (197 s). Les latences par composant sont rapportées au Chapitre 5, Tableau 5.1. Lorsque MediaPipe et HSEmotion sont fusionnés dans une boucle partagée avec détection faciale hybride unifiée, le pipeline à deux outils atteint 54.6 FPS avec 99.9 % de couverture de détection faciale sur cet enregistrement.

La limitation des seuils MediaPipe identifiée en Phase 1 (Section 6.1) a motivé la stratégie de détection hybride utilisée ici. L'approche hybride a atteint 99.9 % de couverture de détection faciale dans toutes les conditions d'éclairage, contre 30.4 % pour la cascade de Haar seule en faible luminosité (S02).

6.2.2. Benchmark initial des formules (F0–F6)

Trois formules candidates initiales (F0–F2) ont été évaluées contre 9 événements de peur et 5 événements de contrôle d'erreur (colère/confusion) sur Video05_S02. Ces événements ont été identifiés en utilisant la synchronisation auto-détectée v1, où la formule F0 servait de détecteur de pics avec des fenêtres de 6 s autour des pics détectés. Cela a introduit une dépendance circulaire : le benchmark évaluait les formules candidates contre une vérité terrain générée par l'un de ces candidats (Section 4.6.1). Les résultats de Phase 2 sont donc préliminaires ; la limitation méthodologique a été corrigée dans les phases suivantes. Le Tableau 6.1 résume les résultats de discrimination peur/colère.

Tableau 6.1 : Résultats du benchmark des formules de peur (Video05_S02, discrimination peur/colère). Vérité terrain basée sur la synchronisation auto-détectée v1 ; voir texte pour la mise en garde méthodologique.

Formule	Moy. peur	Moy. colère	Ratio	Statut
F0 (arousal-tension)	0.42	0.32	1.3×	Rejeté — quasi aléatoire
F1 (fear-tension)	0.68	0.12	5.5×	Ratio le plus élevé
F2 (equal-weight)	0.55	0.14	4.0×	Candidat Phase 2

F0 — qui reposait sur l’arousal brut — n’a atteint qu’une discrimination de 1.3×, essentiellement aléatoire. Ce fut le premier résultat important : l’arousal seul ne peut pas distinguer la peur de la colère, puisque les deux émotions occupent le même quadrant de haut arousal dans le modèle circomplexe. F2, qui utilisait la probabilité de peur directe à la place, a atteint 4.0×, dépassant l’objectif de 3.0×. L’inclusion de `hs_surprise` a été motivée par la documentation de Abdeldayem et al. (2026) que la peur et la surprise ne diffèrent que par une seule unité d’action.

Un mécanisme VETO (suppression post-score basée sur des seuils contextuels) a également été évalué : sur 45 configurations, aucun VETO n’a amélioré la ligne de base. Le mécanisme a été abandonné.

F2 a été sélectionné comme candidat de Phase 2 : $F2 = 0.40 \cdot \text{hs_fear} + 0.20 \cdot \text{hs_surprise} + 0.40 \cdot \text{mp_tension}$.

6.3. PHASE 3 : ÉVALUATION SUR TROIS SUJETS

La Phase 3 s’est étendue à trois sujets sous différentes conditions d’éclairage : S02 (faible, moniteur uniquement), S06 (lumineux, ambiant), S08 (mixte). La vérité terrain comprenait 50 événements de peur annotés via la méthodologie événementielle finale (Section 4.6.1) : l’annotateur a examiné indépendamment chaque vidéo sans accès aux sorties des formules. Chronologiquement, le nombre de formules est passé de 2 à 7, puis à 12. Initialement, F0–F2 de la Phase 2 ont été mises à jour en F0–F6. Puis, les nouvelles formules F7–F11 et F13 (autrefois nommée formule composite, rendant F12 vacant) ont été créées pour tester les performances de HSEmotion et MediaPipe afin de déterminer comment ils peuvent être utilisés. Un détecteur d’événements à fenêtre glissante a remplacé la métrique de ratio au niveau image, produisant des scores de précision, rappel et F1 au niveau événementiel.

6.3.1. L’effondrement de F2

Le candidat de Phase 2 F2, qui avait bien performé sur un seul sujet, s’est effondré sous l’évaluation inter-sujets : F1 combiné = 0.3492 avec un rappel de seulement 22 %. La cause racine a été identifiée : F2 attribue 40 % du poids à `mp_tension`, un signal qui, comme l’analyse des blendshapes l’a révélé, s’active rarement au-dessus du seuil de détection à travers les sujets.

Les lignes de base d’ablation ont quantifié le problème. F8 (`mp_tension` seul) a atteint un F1 = 0.0748 — proche de zéro. Les blendshapes critiques pour la peur (*eyeWideLeft*, *eyeWideRight*) ont montré des activations au 95e percentile de seulement 0.003–0.054 à travers les sujets, bien en dessous du 0.30 requis pour la détection binaire. Même pendant les événements de peur annotés, les activations étaient brèves et intermittentes. La morphologie faciale au repos spécifique à chaque sujet créait des décalages de base qui confondaient la détection par seuil.

En revanche, F7 (`hs_fear` seul) a atteint un F1 = 0.7158. La classification neuronale holistique de HSEmotion, entraînée sur AffectNet, capturait les motifs du visage entier sans nécessiter de seuils individuels par unité d’action.

6.3.2. L'intuition multiplicative

La question est devenue : `mp_tension` devrait-il être entièrement abandonné ? La réponse est venue d'un balayage systématique de 81 configurations de tension (9 variantes de formule $\times$ 9 paramètres de gain AGC, 2916 évaluations au total). Le balayage a révélé que lorsque `mp_tension` est utilisé non pas comme entrée à poids égal mais comme *modificateur multiplicatif*, il fournit une amélioration constante. Les gains par session étaient frappants : +17.9 pp F1 pour S02, +12.5 pp pour S08, +19.0 pp pour S06.

Cela a produit la formule F13 : $F13 = hs_fear \times (1 + mp_tension)$. La conception multiplicative assure que `mp_tension` peut amplifier les détections de peur mais ne peut pas les déclencher indépendamment ; la logique architecturale est analysée au Chapitre 7, Section 7.1.

F13 a atteint le F1 combiné le plus élevé de Phase 3 de 0.7333 (Précision = 82.50 %, Rappel = 66.00 %).

6.3.3. Résultats de la détection faciale hybride

La stratégie de détection faciale hybride Haar + MediaPipe a été validée sur les trois sessions. La cascade de Haar seule n’a atteint que 30.4 % de détection faciale en conditions faibles (S02) — insuffisant pour un traitement continu. L’approche hybride a atteint 99.9 % de couverture sur toutes les sessions. L’équivalence des scores HSEmotion entre les entrées recadrées par Haar et par MediaPipe ($r = 0.935$ avec 10 % de remplissage) a confirmé que le changement de backend de détection n’introduit pas d’artefacts de classification.

6.4. PHASE 4 : ÉVALUATION FINALE SUR SIX SUJETS

La Phase 4 a étendu l’évaluation à six sujets avec 88 événements de peur de vérité terrain (Tableau 6.2) et a introduit 3 nouvelles formules optimisées : F12 (*hybrid_amp*, Éq. 5.2), F14 (une variante 60/40 des poids peur/arousal de F12), et enfin avec rPPG, F15 comme formule finale. La vidéo pilote Video05_S02 a été remplacée par S02_Vid04 pour la session S02 : Video05_S02 ne conservait que les annotations auto-détectées v1 de la Phase 2 (Section 6.2.2), et aucune ré-annotation manuelle indépendante n’avait été complétée. S02_Vid04, un enregistrement plus long du même sujet dans des conditions équivalentes, a été annoté en utilisant la méthodologie événementielle finale (Section 4.6.1). Les six sessions du Tableau 6.2 utilisent cette méthodologie.

Tableau 6.2 : Événements de vérité terrain par session

Session	Éclairage	Événements de peur
S02_Vid04	faible	21
S04_Vid09	lumineux	21
S05_Vid10	lumineux	8
S06_Vid16	lumineux	16
S08_Vid18	mixte	13
S10_Vid13	faible	9
Total	—	88

6.4.1. De F13 à F12 : le canal d'arousal

La comparaison de F13 ($hs_fear \times (1 + mp_tension)$) avec F7 (hs_fear seul) et F3 (dominance peur avec 20 % arousal) sur les six sujets a révélé que l'ajout d'une composante arousal récupère les événements perdus par la confusion peur-surprise (Abdel-dayem et al., 2026) ; le mécanisme est analysé au Chapitre 7, Section 7.1. Le poids d'arousal de 30 % récupère 15 vrais positifs supplémentaires par rapport à F7 au coût de seulement 7 faux positifs supplémentaires — un ratio de gain de 2.14:1.

Le Tableau 6.3 présente les résultats combinés sur les six sessions.

Tableau 6.3 : Résultats de détection combinés sur six sessions — meilleure configuration par formule

ID	Étiquette	Préc.	Rap.	F1	Paramètres
F12	hybrid_amp	70.1%	69.3%	0.6971	$\theta=0.7$, mf=5, w=10
F3	legacy	73.7%	63.6%	0.6829	$\theta=0.5$, mf=5, w=10
F7	hs_only	63.0%	71.6%	0.6702	$\theta=0.5$, mf=5, w=20
F13	multiplicative	62.0%	70.5%	0.6596	$\theta=0.6$, mf=5, w=15
F8	mp_only	7.6%	5.7%	0.0649	$\theta=0.4$, mf=12, w=10

Note : F7 atteint $F1 = 0.6702$ sur six sujets, contre 0.7158 dans l'évaluation Phase 3 à trois sujets (Section 6.3.2). La diminution reflète le pool de sujets élargi et plus diversifié.

6.4.2. Performance par session

Le Tableau 6.4 montre les résultats F12 par session aux paramètres verrouillés ($\theta=0.7$, min_frames=5, window=10, fill=65 %).

Tableau 6.4 : Résultats de détection F12 par session aux paramètres verrouillés

Session	Éclairage	VT	VP	FP	Préc.	Rap.	F1
S10_Vid13	faible	9	7	2	77.8%	77.8%	0.7778
S02_Vid04	faible	21	17	6	73.9%	81.0%	0.7727
S06_Vid16	lumineux	16	10	1	90.9%	62.5%	0.7407
S05_Vid10	lumineux	8	5	1	83.3%	62.5%	0.7143
S08_Vid18	mixte	13	7	1	87.5%	53.9%	0.6667
S04_Vid09	lumineux	21	15	15	50.0%	71.4%	0.5882
Combiné	—	88	61	26	70.1 %	69.3 %	0.6971

Trois observations émergent. Premièrement, **le faible éclairage est robuste** : les deux sessions en faible luminosité — S10 (F1=0.7778) et S02 (F1=0.7727, rappel le plus élevé à 81.0 %) — se classent première et deuxième, validant que la détection basée sur HSEmotion fonctionne de manière fiable sous les conditions d'éclairage d'un jeu d'horreur. S10 est notable car HSEmotion classe le visage au repos neutre de ce sujet comme fortement en colère ; malgré cette mauvaise classification de base, F12 atteint tout de même le F1 par session le plus élevé. Deuxièmement, **la variance inter-sujets est bornée** : cinq des six sessions se regroupent dans la plage F1 = 0.67–0.78 (étendue = 0.11) ; S04 est la seule valeur aberrante (F1 = 0.5882, 15 FP) en raison d'un sujet très expressif dont la ligne de base neutre déclenche des faux positifs fréquents — un problème de calibration adressable par le réglage du seuil par sujet, pas un problème de formule. Troisièmement, **les valeurs F1 optimales par session sont 5–10 % plus élevées** que les valeurs optimales combinées (par ex., S02 atteint F1 = 0.83 avec un réglage par session), indiquant que la calibration par sujet est une amélioration future à fort impact.

Note méthodologique importante : Ces résultats utilisent une évaluation au niveau événementiel avec fenêtres temporelles et remplissage, pas une classification au niveau image. Les résultats ne sont donc pas directement comparables aux benchmarks FER publiés au niveau image (AffectNet, FER2013).

6.4.3. Registre des formules

Le Tableau 6.5 résume le registre complet des formules. Les formules héritées sont conservées pour l’analyse d’ablation ; seuls F12 et F15 sont utilisés dans le pipeline de production.

Tableau 6.5 : Registre de composition des formules (F0–F15)

ID	Étiquette	Composition
F0	arousal-tension	$0.60 \cdot \text{arousal} + 0.40 \cdot \text{tension}$
F1	fear-tension	$0.60 \cdot \text{fear} + 0.40 \cdot \text{tension}$
F2	equal-weight	$0.40 \cdot \text{fear} + 0.20 \cdot \text{surprise} + 0.40 \cdot \text{tension}$
F3	legacy	$0.50 \cdot \text{fear} + 0.20 \cdot \text{arousal} + 0.30 \cdot \text{tension}$
F4	anger-gated	$F0 \times \mathbb{I}[\text{anger} \leq \text{fear}]$
F5	startle	$0.50 \cdot \text{fear} + 0.30 \cdot \text{tension} + 0.20 \cdot \text{startle}$
F6	anger-penalty	$(0.60 \cdot \text{fear} + 0.40 \cdot \text{tension}) \times (1 - \text{anger})$
F7	hs_only	fear
F8	mp_only	tension
F9	max	$\max(\text{fear}, \text{tension})$
F10	geometric	$\sqrt{\text{fear} \times \text{tension}}$
F11	anger-subtract	$\text{fear} - 0.6 \cdot \text{anger}$
F12	hybrid_amp	$(0.7 \cdot \text{fear} + 0.3 \cdot \text{arousal}) \times (1 + \text{tension})$
F13	multiplicative	$\text{fear} \times (1 + \text{tension})$
F14	hybrid_amp_60	$(0.6 \cdot \text{fear} + 0.4 \cdot \text{arousal}) \times (1 + \text{tension})$
F15	rppg_amp	F12 $\times (1 + 0.5 \cdot \text{bpm_norm})$

6.5. LA DÉCOUVERTE RPPG

6.5.1. Faisabilité et validation par montre connectée

Une montre connectée Amazfit Active 2 a été acquise fin avril 2026 pour fournir une vérité terrain cardiaque indépendante. La montre exporte les données de fréquence cardiaque sous forme de fichiers TCX avec une résolution de 1 seconde. La validation a été réalisée en alignant temporellement les horodatages de fréquence cardiaque de la montre avec les estimations BPM du pipeline rPPG : les deux horloges ont été synchronisées au début de la session, et les fenêtres BPM rPPG ont été appariées aux lectures correspondantes de la montre par jointure au plus proche horodatage. Aucune référence cardiaque n'avait été disponible avant ce point ; toutes les évaluations rPPG antérieures n'étaient que des vérifications de plausibilité. Deux sessions pilotes en conditions contrôlées ont produit la comparaison de précision des algorithmes dans le Tableau 6.6.

Tableau 6.6 : Précision des algorithmes rPPG — Pilote 01 (extracteur MediaPipe, $n = 53$ fenêtres)

Algorithme	MAE (BPM)	RMSE	Pearson r	Biais
POS	22.75	28.95	+0.303	−22.06
ICA	27.30	33.34	−0.479	−25.80
GREEN	32.44	36.20	+0.586	−32.39
CONSENSUS	39.62	40.60	+0.448	−39.62
CHROM	47.18	48.34	−0.128	−47.18
WAVELET	50.14	51.75	+0.484	−50.14

POS a atteint la MAE la plus faible (22.75 BPM), conformément au classement de benchmark de Wang et al.. Tous les algorithmes présentaient un biais négatif systématique (-22 à -50 BPM), indiquant une sélection de pic FFT sous-harmonique : la FFT s'est verrouillée sur un pic à environ la moitié de la fondamentale cardiaque (~ 0.75 Hz au lieu de ~ 1.5 Hz), probablement en raison de la modulation respiratoire de la forme d'onde du pouls. La désambiguïsation harmonique — vérifier si un pic candidat à $2f$ porte une puissance suffisante ($\geq 60\%$ de la puissance à f) et corriger en conséquence — a résolu cet artefact (voir Annexe A). Contre la vérité terrain de la montre connectée dans les sessions de gameplay avec désambiguïsation harmonique appliquée, la précision POS s'est améliorée à $MAE = 2.96$ BPM.

6.5.2. Le résultat nul (CONSENSUS)

L'évaluation cross-modale initiale a utilisé l'algorithme CONSENSUS (moyenne pondérée par le SNR de cinq algorithmes) avec des fenêtres de 15 s et des pas de 3 s. Cinq méthodes statistiques complémentaires ont été testées : comparaison de BPM moyen (test t de Welch), test t à un échantillon sur le delta BPM, corrélations temporelles de Pearson/Spearman, résolution multi-fenêtre, et normalisation z -score par sujet.

Le résultat était sans ambiguïté : aucune relation statistique entre la fréquence cardiaque estimée par rPPG et les événements de peur annotés ($p = 0.77$, $d = 0.042$). Le canal cardiaque semblait ne rien apporter, et l'intégration rPPG a été dépriorisée en faveur du développement de formules FER uniquement. Le balayage de 48 configurations ultérieur (Section 6.5.3) a renversé cette conclusion.

6.5.3. Le balayage de 48 configurations

Plutôt que d'accepter le résultat nul, un balayage systématique a été mené : 3 filtres d'algorithme (POS uniquement, POS+CHROM, CONSENSUS) $\times$ 16 combinaisons fenêtre/pas (fenêtres : 30 s, 15 s, 10 s, 5 s ; pas : 5 s, 3 s, 2 s, 1 s), chacune évaluée avec 3 méthodes statistiques = 144 tests de corrélation.

Le balayage a identifié POS@10s/5s comme la configuration optimale pour l'analyse de corrélation :

Tableau 6.7 : Réponse cardiaque de peur rPPG — POS@10s/5s sur quatre sessions

Session	n_{peur}	BPM peur	BPM non-peur	ΔBPM	d de Cohen
S04_Vid09	19	93.3	85.8	+7.5	0.589
S05_Vid10	6	94.5	85.3	+9.2	0.721
S06_Vid16	14	95.4	84.8	+10.5	0.862
S10_Vid13	9	100.2	90.9	+9.3	0.516
Combiné	48	95.3	86.7	+8.6	0.696

Les quatre sessions montrent des deltas BPM positifs avec des tailles d'effet moyennes à grandes ($d = 0.52\text{--}0.86$). L'effet combiné ($d = 0.696$) est moyen à grand. La validation croisée leave- k -out a confirmé la robustesse : le delta BPM est resté positif dans 14/14 plis à travers les partitions leave-1-out ($\bar{\Delta} = 8.72 \pm 0.74$), leave-2-out ($\bar{\Delta} = 8.89 \pm 1.11$), et leave-3-out ($\bar{\Delta} = 9.14 \pm 1.26$). Cependant, ces résultats reposent sur seulement quatre sessions (54 événements de peur) de spectateurs passifs de vidéo. Bien que la direction consistante à travers toutes les sessions et tous les plis de validation croisée soit encourageante, la petite taille d'échantillon limite la généralisabilité de ces résultats ; une validation avec un pool de participants plus large et plus diversifié — en particulier dans des conditions de gameplay en temps réel — est requise avant que la réponse cardiaque de peur puisse être considérée comme établie.

6.5.4. Correction pour tests multiples

Tester 48 configurations gonfle le taux d'erreur par famille. Une correction FWER basée sur les permutations a été appliquée : les étiquettes peur/non-peur ont été mélangées 10 000 fois, enregistrant la meilleure valeur p à travers les 48 configurations par permutation. Sur 10 000 permutations, 286 ont produit un meilleur- $p \leq 0.000283$ (le meilleur observé). La valeur p corrigée par famille est de **0.0287** — significative à $\alpha = 0.05$. Le résultat POS@10s/5s survit à la correction pour les 48 configurations testées.

6.5.5. Augmentation rPPG de la détection FER

Étant donné la réponse cardiaque de peur significative, l'augmentation rPPG multiplicative (F15, Éq. 5.3) a été évaluée. Un balayage de 48 configurations $\text{BPM} \times 4$ coefficients ($c \in \{0.3, 0.5, 0.8, 1.0\}$) a été mené.

Tableau 6.8 : Meilleures configurations d'augmentation rPPG. La ligne de base F12 ($F1 = 0.7191$, $P = 91.4\%$, $R = 59.3\%$) est évaluée sur les quatre mêmes sessions avec données rPPG (54 événements), pas le corpus complet de six sessions (88 événements, $F1 = 0.6971$).

Config	c	P (%)	R (%)	F1	$\Delta F1$
POS@30s/3s	0.5	90.0	66.7	0.7660	+0.0469
POS@10s/2s	1.0	81.2	72.2	0.7647	+0.0456
POS@10s/5s	0.8	~85	~63	0.7400	+0.0209

POS@30s/3s avec $c = 0.5$ est sélectionné comme configuration de production candidate : il atteint le F1 le plus élevé (+4.69 pp) tout en préservant 90 % de précision (−1.4 pp par rapport à la ligne de base), gagnant +7.4 pp de rappel. L'alternative POS@10s/2s avec $c = 1.0$ atteint un F1 comparable mais échange −10.2 pp de précision contre +12.9 pp de rappel — inadapté pour un jeu où les fausses alarmes dégradent l'expérience du joueur. Comme pour les résultats de corrélation, l'évaluation de l'augmentation est limitée à quatre sessions ; ces gains sont suggestifs mais nécessitent confirmation avec un plus grand pool de participants avant que le canal rPPG puisse être considéré comme un composant de production fiable.

La différence de taille de fenêtre optimale entre l'analyse de corrélation (POS@10s) et l'augmentation (POS@30s) reflète des exigences temporelles différentes ; le mécanisme sous-jacent est discuté au Chapitre 7, Section 7.3.

6.6. RÉSUMÉ DES RÉSULTATS CLÉS

L'évaluation progressive a produit cinq résultats principaux :

1. **L'échec de F2 et l'architecture multiplicative** : La fusion à poids égaux de HSE-motion et MediaPipe échoue sous l'évaluation inter-sujets car les activations de tension MediaPipe sont structurellement trop clairsemées. La conception du modificateur multiplicatif — où la tension peut amplifier les détections de peur mais ne peut pas les déclencher seule — résout ce problème.
2. **Le canal d'arousal** : L'ajout de 30 % de `hs_arousal` au signal de peur récupère les événements perdus par la confusion peur-surprise, produisant F12 ($F1 = 0.6971$).
3. **Le résultat nul rPPG était un artefact méthodologique** : L'algorithme CONSENSUS a dilué le signal précis de POS avec le bruit d'algorithmes plus faibles. Une fois POS isolé et la taille de fenêtre ajustée à la durée des événements de peur, une réponse cardiaque de peur moyenne à grande a émergé ($d = 0.696$, FWER $p = 0.029$). Ce résultat, basé sur quatre sessions, est prometteur mais préliminaire ; une validation à plus grande échelle est nécessaire.
4. **L'augmentation rPPG est prometteuse** : F15 améliore le F1 à 0.7660 tout en préservant 90 % de précision sur les quatre sessions disponibles. Le signal rPPG est en retard sur le FER de $\sim 8-18$ s, créant une dynamique temporelle complémentaire analysée au Chapitre 7. La confirmation avec davantage de participants est un objectif principal des travaux futurs.
5. **La robustesse en faible lumière est confirmée** : $F1 = 0.77$ sous éclairage de moniteur uniquement, avec 99.9 % de couverture de détection faciale via l'approche hybride.

La formule de production verrouillée est F15 (Éq. 5.3) avec F12 (Éq. 5.2) comme base FER. La vérification de l'architecture par rapport à la conception originale est présentée au Chapitre 7, Section 7.6.

7. ANALYSE ET DISCUSSION

Ce chapitre interprète les résultats du Chapitre 6, analyse pourquoi certaines approches ont réussi ou échoué, examine comment le plan du projet a divergé de la réalité, et vérifie l'architecture finale par rapport à la conception d'origine.

7.1. HSEMOTION VS. MEDIAPIPE : UNE ASYMÉTRIE INATTENDUE

L'évaluation sur six sujets révèle une asymétrie nette entre les deux outils FER qui n'avait pas été anticipée dans la conception initiale.

HSEmotion (EfficientNet-B0, entraîné sur AffectNet) fournit une classification neuronale holistique, produisant des probabilités softmax à 8 classes par image. Il capture les patterns faciaux globaux sans nécessiter de seuils individuels par Action Unit, ce qui le rend intrinsèquement robuste aux variations morphologiques inter-sujets. En tant que signal autonome (F7), `hs_fear` atteint un $F1 = 0.6702$ (Tableau 6.3) — des performances constantes sans calibration par sujet.

MediaPipe (52 blendshapes faciaux) extrait les activations individuelles des Action Units nécessitant des décisions binaires basées sur des seuils. En tant que signal autonome (F8), `mp_tension` atteint un $F1 = 0.0649$ (Tableau 6.3). Les causes profondes sont structurelles : les blendshapes critiques pour la peur présentent des activations médianes de 0.001–0.004, avec des valeurs au 95^e percentile qui n'approchent jamais les seuils requis pour la détection. Ces planchers d'activation varient selon les sujets en raison de la morphologie faciale au repos.

La conception initiale traitait ces deux outils comme des signaux potentiellement interchangeables pouvant être fusionnés avec des poids égaux. Les données ont montré le contraire : la relation est asymétrique. HSEmotion est le détecteur ; MediaPipe est l’amplificateur. La formule multiplicative F12 (Éq. 5.2) encode cette asymétrie : lorsque `hs_fear` est proche de zéro, toute valeur de `mp_tension` est multipliée par approximativement zéro, empêchant les faux positifs. Lorsque `hs_fear` est élevé, même un modeste boost de `mp_tension` amplifie le signal au-dessus du seuil de détection. MediaPipe capture des informations complémentaires de micro-expressions — tension des sourcils, crispation de la mâchoire — qui confirment et renforcent la classification de HSEmotion lorsque les deux outils concordent.

L’approche Blendshape Distribution Alignment (BDA) de Yang et al. (2026) reste une piste pour les travaux futurs. Les valeurs F1 optimales par session sont 5–10 % supérieures aux valeurs optimales combinées (par ex., S02 atteint un $F1 = 0.83$ avec un réglage par session ; Section 6.4.2), suggérant que même une simple adaptation des seuils pourrait substantiellement améliorer la contribution de MediaPipe.

7.2. LE RÉSULTAT NUL RPPG : ANATOMIE D’UN ARTEFACT MÉTHODOLOGIQUE

L’évaluation rPPG a produit l’un des épisodes les plus instructifs du projet : un résultat nul qui semblait clore une direction de recherche, mais qui s’est avéré être un artefact de la méthodologie d’évaluation plutôt qu’une absence de signal.

Cause profonde 1 — Dilution algorithmique : L’algorithme CONSENSUS calcule une moyenne pondérée par le SNR de cinq algorithmes d’extraction. Bien que théoriquement fondée, la validation par montre connectée a révélé des disparités extrêmes de précision (Tableau 6.6) : POS a atteint une $MAE = 2.96$ BPM, tandis que GREEN et WAVELET ont contribué des MAE dépassant 13 BPM. Même avec la pondération SNR, ces algorithmes faibles ont dilué le signal précis de POS. Les mêmes données qui montraient $d = 0.042$ (aucun effet) avec CONSENSUS ont produit $d = 0.696$ (effet moyen à large) avec POS isolé.

Cause profonde 2 — Inadéquation de la taille de fenêtre : La fenêtre BPM initiale de 15 s moyennait les événements de peur durant 3–10 s, lissant les transitoires cardiaques d'intérêt. La fenêtre de 10 s capture ces réponses transitoires tout en conservant une résolution fréquentielle FFT suffisante. Les 11 configurations ayant atteint la significativité ($p < 0.05$) utilisaient des fenêtres de 10 s ou 5 s ; aucune configuration à 15 s ou 30 s n'a atteint la significativité pour la corrélation moyenne du BPM.

La leçon est méthodologique : lors de la combinaison de multiples estimateurs bruités, la qualité de l'estimateur le plus faible peut dominer l'ensemble plutôt que d'être moyennée. L'hypothèse selon laquelle « plus d'algorithmes = plus de robustesse » était erronée pour cette combinaison spécifique.

7.3. LA MÉCANIQUE DE TERREUR SOUTENUE

L'augmentation rPPG introduit une latence d'environ 8–18 s par rapport au signal FER. Ce retard comporte trois composantes : (1) la latence de la réponse autonome (5–15 s pour que le système nerveux sympathique élève la fréquence cardiaque après un stimulus de frayeur) ; (2) la fenêtre BPM de 30 s, qui moyenne les changements cardiaques aigus avec les données de base antérieures ; et (3) l'intervalle de pas de 3 s entre les mises à jour du BPM.

Plutôt qu'une limitation, cette séparation temporelle crée un pattern de réponse complémentaire en deux phases. Le score FER de F12 (~53 ms de latence) capture la réaction de sursaut facial immédiate et déclenche les réponses initiales de l'IA ennemie. L'augmentation rPPG maintient l'agressivité élevée de l'ennemi lorsque la fréquence cardiaque du joueur reste élevée après une frayeur. Cette séparation temporelle entre la détection faciale immédiate et la confirmation cardiaque retardée produit ce que l'on peut décrire comme une mécanique de « terreur soutenue », où la peur physiologique persistante intensifie l'expérience de jeu au-delà du sursaut initial.

Cette mécanique est architecturalement cohérente avec le paradigme Relax-to-Win : le jeu ne répond pas seulement à ce que vous montrez sur votre visage, mais à ce que votre corps ressent encore.

7.4. PRÉCISION PLUTÔT QUE RAPPEL : UN PRINCIPE DE CONCEPTION EN PRATIQUE

Le principe énoncé au Chapitre 1 — selon lequel les faux positifs sont plus dommageables que les faux négatifs — a façonné la formule finale et la sélection des paramètres de manière concrète.

Lorsque le pipeline détecte incorrectement de la peur chez un joueur calme (faux positif), l'IA ennemie passe en mode poursuite. Le joueur, qui explorait calmement, est soudainement poursuivi sans raison apparente. La boucle de biofeedback est censée rendre le jeu réactif ; au lieu de cela, il paraît aléatoire. Le joueur ne peut pas comprendre pourquoi l'ennemi a attaqué, ce qui sape la mécanique centrale et brise l'immersion.

Lorsque le pipeline manque un moment de peur authentique (faux négatif), rien ne se passe. L'ennemi continue sa patrouille. Le joueur, qui a été effrayé par l'environnement du jeu, ne reçoit pas de pression supplémentaire de l'IA. Du point de vue du joueur, c'est simplement un moment où le jeu n'était pas à son intensité maximale — indistinguable d'un gameplay normal.

Cette asymétrie a motivé trois décisions spécifiques :

1. POS@30s/3s a été sélectionné plutôt que POS@10s/2s pour l'augmentation rPPG malgré des scores F1 comparables, car la fenêtre plus longue préserve la précision (90 % vs. 81.2 %).
2. Le seuil de détection de base de F12 a été fixé à $\theta = 0.70$; lorsque l'augmentation rPPG est active (F15), le seuil est relevé à $\theta = 0.80$ pour compenser le boost multiplicatif, privilégiant davantage la précision.
3. La composante arousal de F12 a été fixée à 30 % plutôt qu'un poids plus élevé : à 40 %, la perte de précision dépassait le gain de rappel.

7.5. LA PANNE MATÉRIELLE ET LE PIVOT DU PROJET

La machine de développement principale est tombée en panne après le 13 avril 2026. Le plan original (Figure ??) projetait une progression linéaire : développement du pipeline (Phase 1–2) → intégration au jeu (Phase 3) → expérience avec participants (Phase 4). Le prototype de jeu — 177 fichiers, +20 157 lignes de code Unity — représentait le point de convergence où le pipeline devait rencontrer le joueur. La panne matérielle a rompu cette connexion. Le prototype Unity ne pouvait pas s'exécuter sur la machine de secours pendant un certain temps. Certaines données de session non suivies ont été perdues, bien que la majorité du code du pipeline et des scripts d'évaluation aient été préservés dans git.

Le plan du projet n'a pas dérivé progressivement ; il a bifurqué. Le pipeline a continué à se développer sur la machine de secours, mais le jeu est resté figé. Au lieu d'un système intégré unique, le projet est devenu deux voies parallèles : un pipeline capable de détecter la peur dans des flux vidéo, et un prototype de jeu qui existait mais ne pouvait pas évoluer.

La décision de pivoter vers une évaluation basée sur vidéo n'était pas un simple palliatif — elle a changé le caractère de l'évaluation. Le plan original aurait testé le pipeline sur des participants jouant au jeu, produisant peut-être 8–12 sujets d'une seule institution. Le protocole basé sur vidéo, utilisant des vidéos de réaction d'horreur YouTube, a produit six sujets diversifiés avec 88 événements de peur annotés dans trois conditions d'éclairage et une annotation manuelle indépendante.

Cependant, ce pivot impliquait un compromis significatif. Valider la précision de détection sur des spectateurs passifs omet intrinsèquement les dynamiques en boucle fermée d'un système de biofeedback, où la sortie du pipeline influence activement l'état du jeu en temps réel. Par conséquent, QR3 (« Le Relax-to-Win améliore-t-il l'expérience du joueur ? ») reste formellement sans réponse. Malgré cela, des discussions informelles avec des participants potentiels ont confirmé un fort intérêt pour le concept Relax-to-Win, consolidant l'expérience planifiée à deux conditions en simple aveugle comme objectif principal des travaux futurs.

7.6. VÉRIFICATION DE L'ARCHITECTURE

Le système final (Figure 5.1) a été vérifié par rapport à la conception d'origine du Chapitre 5 :

- **HSEmotion** fournit le signal de détection principal via des flèches pleines dans l'architecture — validé par l'évaluation sur six sujets.
- **MediaPipe** alimente `mp_tension` en tant que modificateur multiplicatif (flèche en pointillés) — validé par l'intuition multiplicative (Section 6.3.2).
- **rPPG** (POS@30s/3s) fournit l'augmentation via `bpm_norm` (flèche en pointillés) — validé par la corrélation corrigée FWER (Section 6.5.4) et l'évaluation de l'augmentation (Section 6.5.5).
- **TCP** a été sélectionné plutôt qu'UDP pour une livraison fiable — confirmé en Phase 3.
- La **latence de bout en bout** est dans le budget de 100 ms (Tableau 5.1).
- Le système opère au **Tier 1** (fusion complète) — la stratégie de dégradation progressive n'a pas été nécessaire, car les deux canaux FER et rPPG ont produit des signaux exploitables.

La formule de production finale est F15 (Éq. 5.3) :

$$F15 = \underbrace{(0.7 \cdot \text{hs_fear} + 0.3 \cdot \text{hs_arousal})}_{F12 \text{ (Éq. 5.2)}} \times (1 + \text{mp_tension}) \times (1 + 0.5 \cdot \text{bpm_norm})$$

Les métriques de performance pour F12 et F15 sont rapportées dans les Tableaux 6.3 et 6.8 (Section 6.5.5).

8. CONCLUSIONS ET PERSPECTIVES

8.1. RÉPONSES AUX QUESTIONS DE RECHERCHE

QR1 : Un système FER peut-il maintenir une précision suffisante dans les conditions de faible éclairage d'un jeu d'horreur ?

Oui. La formule de base F12 (Éq. 5.2) atteint un F1 au niveau événementiel de 0.6971 sur six sujets et 88 événements de peur annotés dans des conditions d'éclairage mixtes. La stratégie de détection hybride Haar + MediaPipe a élevé la couverture de 30.4 % à 99.9 % en conditions de faible éclairage sans introduire d'artefacts de classification ($r = 0.935$ d'équivalence des scores). Le pipeline opère à une latence de bout en bout d'environ 53 ms, bien en deçà du seuil temps réel de 100 ms.

QR2 : La fusion au niveau décisionnel des signaux FER et rPPG améliore-t-elle la fiabilité de détection ?

Oui partiellement. L'évaluation initiale avec l'algorithme CONSENSUS a produit un résultat nul ($p = 0.77$, $d = 0.042$). Un balayage exhaustif de 48 configurations a identifié ce résultat nul comme un artefact méthodologique : la dilution algorithmique et l'inadéquation de la taille de fenêtre masquaient une réponse cardiaque de peur d'amplitude moyenne à large (POS@10s/5s, $d = 0.70$, FWER $p = 0.029$, cohérente sur les quatre sessions). L'augmentation multiplicative rPPG (F15, Éq. 5.3) améliore le F1 de +4.69 pp à 0.7660 tout en préservant 90 % de précision. La fusion est bénéfique lorsque la configuration d'extraction rPPG est correctement adaptée à la tâche.

QR3 : Un mécanisme « Relax-to-Win » améliore-t-il l'expérience du joueur ?

Cette question reste sans réponse. Un prototype de jeu Unity (v1) implémentant la mécanique Relax-to-Win a été développé et validé lors de sessions de test, et une refonte v2.0 avec une géométrie de niveau étendue, deux types d'ennemis et une intégration de biofeedback affinée est en cours (Chapitre 5, Section 5.8.3). L'expérience de jeu en direct reste l'objectif principal des travaux futurs.

8.2. RÉSUMÉ DES CONTRIBUTIONS

1. **Formule composite de peur F12 (*hybrid_amp*)** : Une fonction de scoring multimodale (Éq. 5.2) combinant la classification par réseau de neurones (HSEmotion) avec l'analyse géométrique faciale (blendshapes MediaPipe) dans une architecture multiplicative. La conception garantit que la tension MediaPipe amplifie les détections de peur authentiques sans générer de faux positifs lorsque le signal principal est absent. Évaluée sur six sujets et 88 événements de vérité terrain avec un $F1 = 0.6971$.
2. **Réponse cardiaque de peur par rPPG** : La première preuve empirique que les événements de peur dans un jeu d'horreur produisent une réponse cardiaque détectable via le rPPG par webcam ($d = 0.70$, FWER $p = 0.029$). La découverte que le résultat nul initial était causé par la dilution algorithmique comble une lacune méthodologique où le rPPG est proposé pour le jeu affectif sans optimisation systématique de la configuration.
3. **Détection faciale hybride pour le FER en faible éclairage** : Une stratégie de repli Haar + MediaPipe qui élève la couverture de 30.4 % à 99.9 % en éclairage faible sans artefacts de classification.
4. **Pipeline temps réel open-source** : Un pipeline Python complet (FER + rPPG + socket TCP) opérant à une latence d'environ 53 ms, adapté à l'intégration dans n'importe quel moteur de jeu.
5. **Méthodologie d'évaluation au niveau événementiel** : Un cadre de détection par fenêtre glissante avec des paramètres configurables, un rembourrage temporel et une analyse de proximité des faux positifs, conçu spécifiquement pour la granularité temporelle du jeu affectif.

8.3. LIMITATIONS

1. **Taille de l'échantillon** : Six sujets avec un seul annotateur pour la vérité terrain. Bien que les 88 événements de peur couvrent des éclairages et morphologies faciales diversifiés, l'échantillon est insuffisant pour une généralisabilité au niveau populationnel. La concordance inter-annotateurs n'a pas été évaluée.
2. **Validité écologique** : Les sujets de l'évaluation sont des YouTubeurs jouant à des jeux d'horreur pour leur audience — une population écologiquement pertinente. Cependant, le pipeline a traité leurs vidéos hors ligne, et non en temps réel pendant le gameplay. Cela valide la précision de détection mais ne teste pas les dynamiques en boucle fermée d'un système de biofeedback.
3. **Absence d'expérience de gameplay** : La panne matérielle a empêché l'expérience planifiée à 2 conditions. QR3 reste sans réponse.
4. **Variabilité inter-sujets de MediaPipe** : Les activations des blendshapes restent structurellement clairsemées, limitant MediaPipe à un rôle de modificateur multiplicatif. Aucune calibration par sujet n'a été implémentée.
5. **Dépendance à une seule caméra** : Les occlusions faciales momentanées (mains couvrant le visage lors d'une frayeur) causent une perte de signal sans repli au niveau du capteur.
6. **Configuration rPPG post-hoc** : La fenêtre POS@10s/5s a été découverte par balayage plutôt que pré-enregistrée. Bien que le résultat survive à la correction FWER, une réplication indépendante est nécessaire.

8.4. TRAVAUX FUTURS

Les travaux futurs se concentreront sur trois axes principaux :

- **Expérience de jeu en direct** : Acheter le prototype v2.0 et exécuter l'expérience en boucle fermée pour répondre à QR3, tout en validant la découverte rPPG (POS@10s/5s) sur un échantillon plus large.
- **Calibration inter-sujets** : Implémenter le Blendshape Distribution Alignment (BDA) (Yang et al., 2026) pour normaliser les plages d'activation de MediaPipe par sujet.
- **Vérité terrain cardiaque** : Compléter l'extraction par webcam avec un capteur PPG par contact pour capturer des métriques de variabilité de la fréquence cardiaque (VFC) haute résolution.

8.5. CONCLUSION

Une webcam standard, deux modèles open-source et une formule composite s'exécutant en 53 ms sur un ordinateur portable grand public — la barrière technique au jeu affectif n'est plus le matériel. C'est la méthodologie d'évaluation, la calibration inter-sujets et la validation en boucle fermée qu'une expérience de jeu en direct fournira.

A. GLOSSAIRE TECHNIQUE

Ce glossaire fournit des définitions techniques précises des termes utilisés dans ce rapport, organisées par domaine.

Pour des explications simplifiées de ces termes, voir l'Annexe B.

1.1. TRAITEMENT DU SIGNAL ET RPPG

BPM (*Beats Per Minute*) — Nombre de contractions cardiaques par minute. La fréquence cardiaque normale au repos chez l'adulte se situe entre 60 et 100 BPM. L'activation du système nerveux sympathique (par ex., lors de la peur) augmente le BPM par la libération d'adrénaline.

PPG (*Photopléthysmographie*) — Technique optique mesurant les variations du volume sanguin dans les tissus périphériques. Les capteurs PPG par contact (par ex., les oxymètres de pouls) détectent l'atténuation de la lumière transmise ou réfléchiée par la peau, modulée par le flux sanguin artériel pulsatile.

rPPG (*Photopléthysmographie à distance*) — Extension sans contact de la PPG utilisant une caméra vidéo RGB standard pour détecter les variations chromatiques sous-pixelles de la peau du visage causées par le flux sanguin pulsatile. Le signal est extrait de séquences d'images vidéo en analysant les fluctuations temporelles des valeurs moyennes des pixels de régions cutanées sélectionnées (ROI). Le signal résultant contient une composante périodique à la fréquence cardiaque, à partir de laquelle le BPM est estimé.

FFT (*Fast Fourier Transform*) — Un algorithme en $O(n \log n)$ pour calculer la transformée de Fourier discrète, décomposant un signal temporel de n échantillons en ses composantes fréquentielles. Chaque bin du spectre résultant représente l'amplitude et la phase à une fréquence spécifique. Dans notre pipeline rPPG, la FFT est appliquée à des segments fenêtrés du signal rPPG pour identifier le pic de fréquence dominant dans la bande cardiaque (1.0–3.0 Hz).

SNR (*Signal-to-Noise Ratio*) — Rapport de la puissance du pic FFT à la fréquence cardiaque détectée sur la puissance spectrale médiane du plancher de bruit, les ± 2 bins fréquentiels autour du pic étant exclus de l'estimation du bruit. Calculé comme $SNR = P_{\text{pic}}/P_{\text{médiane_bruit}}$. Dans notre évaluation, POS a atteint un SNR par fenêtre typiquement entre 3 et 6, confirmé par la validation par montre connectée (MAE = 2.96 BPM). Un $SNR \geq 2.0$ était le seuil pour le vote de l'algorithme historique CONSENSUS (désormais remplacé par l'extraction POS uniquement). Le SNR mesure la qualité de l'extraction du signal, pas le contenu émotionnel — un SNR élevé signifie que la fréquence cardiaque peut être mesurée précisément, non que la peur est présente.

Filtre passe-bande — Un filtre dans le domaine fréquentiel qui atténue toutes les composantes fréquentielles en dehors d'une bande passante spécifiée. Notre pipeline rPPG utilise un filtre passe-bande de Butterworth d'ordre 4 avec des fréquences de coupure de 1.0 Hz et 3.0 Hz (correspondant à 60–180 BPM) pour isoler la bande de fréquence cardiaque et rejeter la dérive DC, les artefacts respiratoires (~ 0.2 – 0.4 Hz) et le bruit haute fréquence.

Filtre de Butterworth — Un type de filtre à réponse impulsionnelle infinie (RII) caractérisé par une réponse en amplitude maximale plate dans la bande passante. Cela signifie qu'il introduit une distorsion d'amplitude minimale dans la bande passante au prix d'une atténuation progressive aux bords de bande, ce qui le rend adapté au traitement des signaux physiologiques où la préservation de la forme du signal est importante.

Désambiguïsation harmonique — Une étape de post-traitement qui détecte et corrige les erreurs sous-harmoniques dans l'estimation du BPM basée sur la FFT. Lorsque le pic détecté est à la fréquence f , l'algorithme vérifie si un pic à $2f$ existe avec une puissance $\geq 60\%$ de la puissance à f . Si oui, le pic dominant est probablement un sous-harmonique (par ex., un artefact respiratoire à ~ 15 – 20 respirations/min) et la vraie fréquence cardiaque est $2f$. Cela corrige un artefact courant où la modulation respiratoire du signal rPPG produit un pic fort à la moitié de la fréquence cardiaque, particulièrement dans les fenêtres d'analyse courtes (≤ 10 s) où la résolution fréquentielle est limitée.

1.1.1. Algorithmes rPPG

Cinq algorithmes rPPG ont été implémentés et évalués par rapport à la vérité terrain d'une montre connectée lors de sessions pilotes. Tous les algorithmes prennent des séquences temporelles de valeurs RGB moyennes des ROI faciales et produisent une estimation du BPM par fenêtre d'analyse.

POS (*Plane-Orthogonal-to-Skin*, Wang et al., 2017) — Projette le signal de chrominance temporel sur un plan orthogonal au vecteur de couleur de la peau, supprimant les réflexions spéculaires et les changements d'illumination diffuse. Algorithme le plus performant dans notre évaluation : MAE = 2.96 BPM, Pearson $r = 0.636$, biais = -0.70 BPM par rapport à la référence montre connectée (pilote S15, fenêtre 30 s).

CHROM (*Chrominance-based*, De Haan & Jeanne, 2013) — Construit deux combinaisons linéaires des canaux RGB ($X_f = 3R - 2G$ et $Y_f = 1.5R + G - 1.5B$) pour construire un signal de chrominance robuste aux variations d'intensité induites par le mouvement. Deuxième meilleure performance : MAE = 9.32 BPM.

GREEN (Verkruyse et al., 2008) — Extrait le signal rPPG directement de la variation temporelle de la moyenne du canal vert. L'approche la plus simple, reposant sur l'observation que l'absorption de l'hémoglobine est la plus forte dans le spectre vert. Sensible aux artefacts de mouvement et d'illumination. MAE = 13.13 BPM.

ICA (*Independent Component Analysis*, Poh et al., 2010) — Applique la séparation aveugle de sources pour décomposer le signal RGB multivarié en composantes statistiquement indépendantes, dont l'une devrait correspondre au pouls du volume sanguin. Utilise l'algorithme JADE pour la décomposition ICA. MAE = 9.78 BPM.

WAVELET — Applique la transformée en ondelettes continue (ondelette de Morlet) au signal rPPG pour effectuer une analyse temps-fréquence. La fréquence cardiaque est identifiée comme la crête d'énergie maximale dans le scalogramme au sein de la bande cardiaque. Moins précis dans notre évaluation : MAE = 23.35 BPM.

CONSENSUS — Notre estimateur composite du BPM implémentant une fusion pondérée par le SNR des cinq algorithmes. Pour chaque fenêtre d’analyse : (1) calculer le BPM et le SNR par algorithme, (2) retenir les algorithmes avec un $\text{SNR} \geq 2.0$, (3) calculer la moyenne pondérée du BPM avec le SNR comme poids. Se replie sur la médiane de tous les algorithmes si aucun ne dépasse le seuil de SNR. Limitation critique : les algorithmes avec de grandes erreurs absolues (GREEN, WAVELET) peuvent toujours contribuer au consensus si leur SNR dépasse 2.0, diluant l’estimation supérieure de POS. Cela a été identifié comme la cause principale du résultat nul initial dans la corrélation avec la peur ($d = 0.042$ pour CONSENSUS vs $d = 0.696$ pour POS seul à la taille de fenêtre optimale).

1.1.2. Variabilité de la fréquence cardiaque

RMSSD (*Root Mean Square of Successive Differences*) — La métrique temporelle de référence de la variabilité de la fréquence cardiaque (VFC), calculée comme :

$$\text{RMSSD} = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} (\text{RR}_{i+1} - \text{RR}_i)^2} \quad (1.1)$$

où RR_i désigne le i -ème intervalle inter-battement en millisecondes. Nécessite la détection des battements individuels avec une haute précision temporelle (typiquement via la détection de pic R par ECG à un échantillonnage ≥ 250 Hz). Le RMSSD reflète principalement la modulation parasympathique (vagale) de la fréquence cardiaque et est sensible au stress aigu et à l’excitation émotionnelle. Les enregistrements standards de courte durée utilisent des fenêtres de 5 minutes.

Variabilité du BPM (notre métrique) — Écart-type des estimations du BPM sur des fenêtres d’analyse consécutives (par ex., des fenêtres toutes les 2–5 s). *Fondamentalement différent du RMSSD* : notre pipeline estime le BPM par fenêtre via la détection du pic FFT, donc la résolution temporelle la plus fine est égale au pas de la fenêtre (2–5 s), et non aux intervalles entre battements individuels (~ 0.6 – 1.0 s). Cette métrique capture les fluctuations de fréquence cardiaque à l’échelle macro (tendances sur des dizaines de secondes) mais ne peut pas mesurer la variabilité battement par battement que le RMSSD quantifie. Bien que les deux métriques répondent à l’activation sympathique, la variabilité

du BPM est un proxy plus grossier qui n'isole pas les contributions parasympathiques.

1.2. RECONNAISSANCE DES ÉMOTIONS FACIALES

FER (*Facial Emotion Recognition*) — La tâche de classifier automatiquement les états émotionnels à partir des expressions faciales dans des images ou des vidéos. Les approches incluent les méthodes basées sur l'apparence (apprentissage profond sur les pixels bruts) et les méthodes basées sur la géométrie (analyse de la configuration spatiale des landmarks faciaux).

Action Units (AU) — Mouvements élémentaires des muscles faciaux définis par le système FACS. Chaque AU correspond à la contraction d'un muscle facial spécifique ou d'un groupe musculaire. Exemples : AU1 (lever du sourcil interne, frontalis pars medialis), AU4 (abaissement du sourcil, corrugator supercilii), AU5 (lever de la paupière supérieure, levator palpebrae), AU20 (étireur de lèvres, risorius). Les expressions de peur impliquent typiquement AU1+AU4+AU5+AU20.

FACS (*Facial Action Coding System*) — Un système exhaustif, basé sur l'anatomie, pour décrire tous les mouvements faciaux visuellement distinguables, développé par Ekman et Friesen (1978). Il définit 44 action units plus des descripteurs pour la position de la tête et les mouvements oculaires. Le codage FACS est réalisé par des annotateurs humains entraînés et sert de standard de vérité terrain pour l'analyse automatique des expressions faciales.

HSEmotion — Un modèle léger de reconnaissance des émotions faciales par Savchenko (2022) basé sur l'architecture EfficientNet-B0. Il a été pré-entraîné sur des jeux de données de reconnaissance faciale à grande échelle et ajusté pour la classification émotionnelle et l'estimation continue de l'affect. Le modèle produit : (1) des probabilités softmax pour 8 émotions discrètes (colère, mépris, dégoût, peur, joie, neutre, tristesse, surprise), et (2) des scores continus d'arousal et de valence. Dans notre pipeline, le modèle traite des crops de visages de 224×224 pixels à environ 20 FPS.

EfficientNet-B0 — La variante de base de la famille de réseaux de neurones convolutifs

EfficientNet (Tan & Le, 2019). Elle atteint une précision ImageNet compétitive avec 5.3M de paramètres grâce à un scaling composé de la profondeur, largeur et résolution du réseau. Son faible coût computationnel la rend adaptée à l'inférence temps réel dans les applications à ressources limitées.

Softmax — Une fonction mathématique qui généralise la fonction logistique à plusieurs classes : $\sigma(z_i) = e^{z_i} / \sum_j e^{z_j}$. Elle normalise un vecteur de logits bruts en une distribution de probabilité, garantissant que toutes les valeurs sont dans l'intervalle $[0, 1]$ et somment à exactement 1. Elle est largement appliquée à la couche finale des réseaux de classification pour produire des probabilités par classe.

MediaPipe — Le framework open-source de Google pour construire des pipelines ML multimodaux. Dans notre système, nous utilisons la solution FaceLandmarker, qui fournit : (1) 478 landmarks faciaux 3D (468 visage + 10 iris) dans un système de coordonnées normalisé, (2) 52 coefficients de blendshapes compatibles ARKit quantifiant les déformations faciales. Le traitement s'exécute sur CPU à environ 30 FPS.

DeepFace — Bibliothèque Python open-source pour l'analyse faciale (détection, reconnaissance, classification d'attributs, reconnaissance émotionnelle) encapsulant plusieurs modèles backend (VGG-Face, FaceNet, ArcFace, etc.). Évaluée pendant la Phase 1 mais non sélectionnée en raison d'une latence d'inférence plus élevée et d'une configurabilité inférieure par rapport à la combinaison HSEmotion + MediaPipe.

Py-Feat — Boîte à outils Python pour l'analyse des expressions faciales utilisant le système FACS. Fournit la détection des Action Units (AU) et la classification émotionnelle. Évaluée pendant la Phase 1 ; connue pour la confusion peur-surprise due au chevauchement de AU4 (abaissement du sourcil) et AU5 (lever de la paupière supérieure). Non sélectionnée pour le pipeline de production.

Blendshapes — Coefficients scalaires dans $[0, 1]$ représentant le niveau d'activation de 52 déformations faciales prédéfinies, calculés par MediaPipe FaceLandmarker à l'aide d'un modèle de régression sur les landmarks détectés. Chaque coefficient correspond à une action faciale spécifique (par ex., *eyeWideLeft*, *browInnerUp*, *jawOpen*, *mouthPressLeft*). Ces coefficients sont utilisés pour calculer des métriques dérivées telles que *mp_tension* (composite de tension faciale) et le score de sursaut (vélocité de l'écarquille des yeux et du lever des sourcils).

Arousal — La dimension d'activation du modèle circumplexe de l'affect (Russell, 1980),

allant de faible (calme, somnolent) à élevé (excité, agité). Estimé par HSEmotion comme une valeur continue dans $[-1, +1]$. La peur produit un arousal élevé ; l'ennui produit un arousal faible. Dans notre formule F12, l'arousal reçoit un poids de 30 % aux côtés de 70 % de probabilité de peur.

Valence — La dimension d'agrément du modèle circumplexe de l'affect, allant de négatif (en détresse, triste) à positif (heureux, enthousiaste). La peur est caractérisée par un arousal élevé et une valence négative. La valence n'est pas directement utilisée dans la formule de détection F12 mais est enregistrée pour l'analyse hors ligne.

mp_tension — Un score composite de tension faciale calculé à partir des 52 blendshapes de MediaPipe via la formule **v5e**. Les activations brutes des blendshapes sont regroupées en trois catégories fonctionnelles : (1) un *groupe stress* (pression des lèvres, retroussement du nez, lever de la lèvre supérieure, gonflement des joues), (2) un *groupe contexte* (abaissement du sourcil, plissement des yeux, froncement de la bouche) modulé par des multiplicateurs de contexte qui atténuent le signal pendant la concentration, la joie ou la tristesse pour réduire les faux positifs, et (3) un *groupe peur* (lever du sourcil interne, écarquillement des yeux, ouverture de la mâchoire) contrôlé par un facteur d’atténuation du sourire. Les trois scores de groupe sont mélangés avec une moyenne pondérée par rang ($0.50 \times \text{max} + 0.30 \times \text{mid} + 0.20 \times \text{min}$), multipliés par un facteur de gain global de 1.8, et bornés à $[0, 1]$. Un module de contrôle automatique du gain (AGC) normalise le score par rapport à une ligne de base ambiante adaptative à la session, le rendant indépendant de l’éclairage. Des valeurs plus élevées indiquent une configuration faciale plus tendue ou effrayée. Utilisé comme amplificateur multiplicatif dans la formule F12 (voir Section 5.5.2 pour la spécification complète).

F12 (hybrid_amp) — La formule de détection de peur verrouillée pour la production, sélectionnée par évaluation systématique (Phase 4, 15 formules candidates) :

$$F12 = (0.7 \times hs_fear + 0.3 \times hs_arousal) \times (1 + mp_tension) \quad (1.2)$$

La combinaison linéaire fusionne deux signaux complémentaires : la probabilité de peur du modèle d’apprentissage profond (*hs_fear*, poids 70 %) et son estimation d’arousal (*hs_arousal*, poids 30 %). Le terme multiplicatif $(1 + mp_tension)$ amplifie le score lorsque la tension faciale physique corrobore la prédiction du modèle, implémentant un mécanisme de déclenchement souple où le modèle d’apparence et le traqueur géométrique doivent concorder pour un score composite élevé. Aux paramètres d’évaluation verrouillés ($\theta = 0.70$, $\text{min_frames} = 5$, $\text{window} = 10$), F12 atteint un $F1 = 0.6971$ sur six sessions de gameplay (voir Éq. 5.2, Section 5.5).

F15 (rppg_amp) — La formule de production augmentée par rPPG qui étend F12 avec

les données cardiaques :

$$F15 = F12 \times (1 + 0.5 \times bpm_norm) \quad (1.3)$$

où $bpm_norm = \text{clip}((BPM - \text{baseline})/\text{baseline}, 0, 1)$ avec une ligne de base médiane glissante de 60 s. La structure multiplicative garantit que l'augmentation rPPG ne peut qu'augmenter le score F12 (lorsque la fréquence cardiaque est élevée au-dessus de la ligne de base) et n'a aucun effet lorsque la fréquence cardiaque est à ou en dessous de la ligne de base ($bpm_norm = 0$). Sur les quatre sessions de gameplay avec données rPPG (54 événements de vérité terrain), F15 atteint un $F1 = 0.7660$, $P = 90.0\%$, $R = 66.7\%$, améliorant F12 de +4.69 pp de F1 tout en préservant la précision (voir Éq. 5.3, Section 5.6).

Score composite — Une valeur scalaire produite par la fusion de multiples signaux hétérogènes (par ex., probabilités émotionnelles d'apprentissage profond, géométrie des landmarks faciaux, signaux physiologiques) en une seule métrique de détection de peur via une combinaison pondérée ou une fonction de déclenchement.

1.3. MÉTRIQUES D'ÉVALUATION

Précision — La valeur prédictive positive du système de détection : $P = VP/(VP + FP)$. Représente la fraction de toutes les détections générées par le système qui correspondent à de véritables événements de peur. Une précision élevée indique peu de fausses alarmes. Dans notre système : F12 atteint 70.1 % de précision aux paramètres verrouillés (six sessions).

Rappel (Sensibilité) — Le taux de vrais positifs : $R = VP/(VP + FN)$. Représente la fraction de tous les événements de peur réels que le système a détectés avec succès. Un rappel élevé indique peu d'événements manqués. Dans notre système : F12 atteint 69.3 % de rappel aux paramètres verrouillés (six sessions).

F1-Score — La moyenne harmonique de la précision et du rappel : $F1 = 2PR/(P + R)$. Varie de 0 (pire) à 1 (parfait). La moyenne harmonique pénalise davantage les déséquilibres extrêmes entre précision et rappel que la moyenne arithmétique, ce qui en fait une

métrique unique adaptée lorsque les deux types d'erreurs important.

Vrai positif (VP) — Un événement de peur existant dans les annotations de vérité terrain et correctement apparié par une détection du système dans la fenêtre de tolérance temporelle.

Faux positif (FP) — Une détection du système qui ne correspond à aucun événement de peur de la vérité terrain. Représente une fausse alarme.

Faux négatif (FN) — Un événement de peur de la vérité terrain qui n'a été apparié par aucune détection du système. Représente un événement manqué.

Évaluation au niveau événementiel vs au niveau image — Deux paradigmes pour mesurer les performances de détection. *Au niveau image* : chaque image vidéo reçoit une étiquette binaire ; les métriques sont calculées sur toutes les images. *Au niveau événementiel* : les annotations de vérité terrain définissent des intervalles temporels ; une détection est un VP si elle tombe dans une fenêtre de tolérance rembourrée autour d'un événement de vérité terrain. Notre pipeline utilise l'évaluation au niveau événementiel avec un rembourrage configurable en début/fin (par défaut : 0.5 s avant, 1.0 s après) pour tenir compte de l'incertitude temporelle de l'annotation.

Détecteur à fenêtre glissante — Un mécanisme de détection temporelle qui maintient une fenêtre de taille fixe (par ex., 10 s ou « strict » = images consécutives) et calcule le ratio de remplissage des images au-dessus du seuil à l'intérieur. Un événement est déclaré lorsque le ratio de remplissage dépasse un minimum (par défaut : 0.65) pendant au moins *min_frames* images qualifiantes consécutives.

Ratio de remplissage — La fraction d'images dans la fenêtre de détection glissante dont le score composite dépasse le seuil de détection. Un ratio de remplissage de 0.65 signifie que 65 % des images de la fenêtre doivent être au-dessus du seuil avant que le détecteur ne se déclenche, fournissant un lissage temporel qui empêche les pics de bruit brefs de provoquer de fausses détections.

1.3.1. Tests statistiques

Test *t* de Welch — Un test d'hypothèse paramétrique pour comparer les moyennes de deux groupes avec des variances et tailles d'échantillon potentiellement inégales. Statistique de test :

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}} \quad (1.4)$$

Utilisé pour comparer le BPM moyen pendant les événements de peur ($n \approx 50$) vs les fenêtres sans peur ($n \approx 200$). Les degrés de liberté sont estimés via l'équation de Welch-Satterthwaite.

***d* de Cohen** — Une mesure standardisée de la taille de l'effet : $d = (\bar{X}_1 - \bar{X}_2)/s_{\text{pooled}}$. Fournit une mesure indépendante de l'échelle de la signification pratique d'une différence, indépendante de la taille de l'échantillon. Seuils conventionnels (Cohen, 1988) : $d < 0.2$ = négligeable, $0.2-0.5$ = petit, $0.5-0.8$ = moyen, > 0.8 = large.

Valeur *p* — La probabilité, sous l'hypothèse nulle (aucun effet réel), d'observer une statistique de test aussi extrême ou plus extrême que celle calculée à partir des données. Un $p < 0.05$ est conventionnellement interprété comme une preuve suffisante pour rejeter l'hypothèse nulle, bien que ce seuil soit une convention, non une constante physique.

Corrélation de Pearson (r) — Une mesure de la force et de la direction de l’association linéaire entre deux variables continues, allant de -1 (relation linéaire négative parfaite) à $+1$ (relation linéaire positive parfaite). Suppose des distributions approximativement normales et est sensible aux valeurs aberrantes.

Corrélation de Spearman (ρ) — Un coefficient de corrélation de rang non paramétrique mesurant la relation monotone entre deux variables. Calculé comme la corrélation de Pearson des données transformées en rangs. Plus robuste que Pearson face aux valeurs aberrantes et distributions non normales.

Test de permutation — Un test d’hypothèse non paramétrique basé sur le rééchantillonnage. La distribution nulle est construite empiriquement en réassignant aléatoirement les étiquettes (par ex., peur/non-peur) aux points de données observés et en recalculant la statistique de test pour chaque permutation (10 000 permutations dans notre implémentation). La valeur p est la fraction de permutations produisant une statistique de test aussi extrême que la valeur observée. Avantages : ne fait aucune hypothèse distributionnelle et tient naturellement compte de la structure de corrélation spécifique des données.

FWER (*Family-Wise Error Rate*) — La probabilité de commettre au moins une erreur de Type I (faux positif) parmi une famille de tests d’hypothèses simultanés. Lors du test de k configurations, la probabilité d’au moins un faux positif augmente avec k (Bonferroni : jusqu’à $k \times \alpha$). Notre correction par permutation familiale y remédie : pour chacune des 10 000 permutations d’étiquettes, les $k = 48$ configurations sont évaluées et la *meilleure* valeur p est enregistrée. La valeur p corrigée est la fraction de permutations dont la meilleure valeur p est $\leq$ la meilleure valeur p observée. Cette approche tient naturellement compte de la corrélation entre configurations (données chevauchantes, tailles de fenêtre similaires) sans être excessivement conservatrice comme la correction de Bonferroni.

1.4. ARCHITECTURE DU SYSTÈME

Cascade de Haar (Viola & Jones, 2001) — Un classificateur en cascade boosté pour la détection d’objets utilisant des caractéristiques rectangulaires de type Haar calculées

via des images intégrales. Atteint des performances temps réel grâce à une structure en cascade qui rejette rapidement les régions non faciales. Limitations : repose sur le contraste des contours et textures, menant à de faibles performances dans les environnements à faible contraste (sombres). Dans notre évaluation, Haar seul a atteint seulement 30.4 % de taux de détection faciale sous éclairage moniteur uniquement.

MediaPipe FaceLandmarker (Google, 2023) — Une solution d’analyse faciale temps réel fournissant : (1) la détection faciale via un modèle SSD BlazeFace, (2) 478 landmarks faciaux 3D (468 visage + 10 iris) via un réseau de régression, (3) 52 coefficients de blendshapes compatibles ARKit via un modèle de blendshapes dédié. S’exécute sur CPU via l’API MediaPipe Tasks à 25–35 FPS selon la résolution de l’image.

Détection hybride — Notre stratégie de détection faciale combinant deux détecteurs dans une chaîne de priorité avec repli : la cascade de Haar est tentée en premier (coût computationnel inférieur) ; en cas d’échec, MediaPipe FaceLandmarker sert de repli. La source du crop (« haar » ou « mp ») est enregistrée par image pour analyse. Cela atteint 99.9 % de couverture de détection faciale dans toutes les conditions d’éclairage, contre 30.4 % pour Haar seul en environnements sombres. L’équivalence de classification HSEmotion entre les crops Haar et MediaPipe a été validée ($r = 0.935$).

ROI (*Region of Interest*) — La sous-région faciale utilisée pour l’extraction du signal rPPG. Notre MultiROIExtractor définit trois ROI via les indices de landmarks MediaPipe : front (primaire, 11 landmarks définissant la zone du visage supérieur), glabellle (6 landmarks couvrant la région inter-sourcilière), et malaire (région des pommettes). Une chaîne de priorité avec repli (front → glabellle → malaire) garantit l’extraction du signal même sous occlusion partielle. Le ROI du front inclut une étape de validation de la couleur de peau dans l’espace colorimétrique HSV (exigeant que $\geq 60\%$ des pixels se trouvent dans les limites de la teinte de peau) pour rejeter les régions occultées ou hors cadre.

Socket TCP — Une connexion réseau fiable, ordonnée et en flux d’octets (Transmission Control Protocol) utilisée pour la communication inter-processus entre le pipeline d’analyse Python et le moteur de jeu Unity. Les messages sont échangés dans un protocole texte simple sur localhost, avec la latence complète du pipeline (capture d’image → inférence FER → transmission socket → réponse du jeu) mesurant environ 53 ms de bout en bout, bien en deçà du seuil temps réel de 100 ms.

FPS (*Frames Per Second*) — Débit de traitement du pipeline d’analyse. Le module FER (HSEmotion + MediaPipe) s’exécute à environ 20 FPS sur le matériel de développement

(GPU NVIDIA + CPU Intel). Le module rPPG s'exécute à environ 30 FPS (charge computationnelle plus légère, pas d'inférence GPU requise). Les deux dépassent le seuil minimum pour un retour affectif en temps réel dans les applications interactives.

B. GLOSSAIRE SIMPLIFIÉ

Ce glossaire explique les termes techniques utilisés dans ce rapport en langage courant. Il est destiné aux lecteurs qui n'ont pas nécessairement de formation en traitement du signal, apprentissage automatique ou statistiques. Pour des définitions techniques précises, voir l'Annexe A.

2.1. MESURE DE LA FRÉQUENCE CARDIAQUE PAR VIDÉO

BPM (*Beats Per Minute*) — Le nombre de fois que votre cœur bat en une minute. Un adulte en bonne santé au repos a typiquement une fréquence cardiaque entre 60 et 100 BPM. Lorsque vous avez peur, votre fréquence cardiaque tend à augmenter.

PPG (*Photopléthysmographie*) — Une façon de mesurer vos battements cardiaques à l'aide de lumière. L'oxymètre de pouls qui se clip au doigt chez le médecin en est un exemple courant : il éclaire la peau et mesure les minuscules changements d'absorption lumineuse causés par le sang circulant à chaque battement.

rPPG (*Photopléthysmographie à distance*) — La même idée que la PPG, mais sans toucher la personne. Au lieu d'un capteur à clipser, une webcam ordinaire enregistre le visage. Bien qu'invisible à l'œil nu, la couleur de la peau change très légèrement à chaque battement cardiaque (le sang entrant et sortant des petits vaisseaux). Un logiciel peut détecter ces changements de couleur infimes et extraire la fréquence cardiaque à partir de la vidéo seule.

FFT (*Fast Fourier Transform*) — Un outil mathématique qui prend un signal changeant dans le temps (comme la couleur de la peau qui fluctue) et trouve les motifs répétitifs qu'il contient. Pensez-y comme identifier quelles notes jouent dans un accord : la FFT nous dit quelles fréquences sont présentes. Nous l'utilisons pour trouver la fréquence du battement cardiaque caché dans le signal rPPG.

SNR (*Signal-to-Noise Ratio*) — La clarté avec laquelle nous pouvons voir le signal du battement cardiaque par rapport au bruit aléatoire dans la vidéo. Imaginez essayer d’entendre quelqu’un parler dans une pièce bruyante : s’il crie, le SNR est élevé et vous l’entendez clairement ; s’il chuchote, le SNR est faible et le bruit le noie. Dans notre système, l’algorithme POS atteint un SNR typiquement entre 3 et 6, ce qui signifie que le signal du battement cardiaque est plusieurs fois plus fort que le bruit de fond — suffisant pour une mesure fiable (validé contre une montre connectée : MAE = 2.96 BPM). Un bon SNR signifie que nous pouvons mesurer la fréquence cardiaque précisément, mais ne nous dit pas si la personne a peur.

Filtre passe-bande — Un filtre qui ne laisse passer qu’une plage spécifique de fréquences et bloque tout le reste. Nous en utilisons un pour ne conserver que les fréquences correspondant à des fréquences cardiaques réalistes (60–180 BPM) et rejeter les fluctuations non pertinentes comme la respiration ou les vibrations de la caméra.

Filtre de Butterworth — Un type spécifique de filtre passe-bande connu pour sa réponse douce et plate dans la plage de fréquences qu’il laisse passer. Il évite de déformer le signal tout en filtrant les fréquences indésirables.

Désambiguïsation harmonique — Parfois, la FFT détecte une fréquence qui est la *moitié* de la fréquence cardiaque réelle (un « sous-harmonique », causé par des artefacts respiratoires autour de 15–20 respirations par minute). Cette technique vérifie si le pic détecté pourrait être un sous-harmonique en cherchant un pic au double de la fréquence détectée. Si le pic à $2f$ a une puissance suffisante ($\geq 60\%$ du pic original), l’algorithme conclut que la vraie fréquence cardiaque est $2f$ et corrige en conséquence.

2.1.1. Algorithmes rPPG

Notre système implémente cinq méthodes différentes pour extraire la fréquence cardiaque à partir de la vidéo. Chacune traite les changements de couleur du visage différemment. Leur précision a été validée contre une montre connectée portée par les participants.

POS (*Plane-Orthogonal-to-Skin*) — La méthode la plus précise dans nos tests (erreur moyenne : seulement 3 BPM par rapport à la montre connectée). Elle fonctionne en séparant mathématiquement les changements de couleur de la peau causés par le flux sanguin de ceux causés par les mouvements de la tête ou l'éclairage. Elle le fait en projetant le signal de couleur sur un plan perpendiculaire à la direction moyenne de la couleur de la peau.

CHROM (*Chrominance-based*) — La deuxième meilleure méthode (erreur moyenne : 9 BPM). Elle combine les canaux de couleur d'une manière spécifique pour annuler les artefacts liés au mouvement, en se concentrant sur la chrominance (différence de couleur) plutôt que sur la luminosité.

GREEN — La méthode la plus simple : elle suit simplement comment la couleur verte de la peau change dans le temps. Bien que directe, elle est facilement perturbée par les mouvements de la tête et les changements d'éclairage (erreur moyenne : 13 BPM).

ICA (*Independent Component Analysis*) — Une méthode statistique qui essaie de séparer le signal du battement cardiaque des autres sources de variation (mouvement, éclairage) en les traitant comme des signaux mélangés indépendants, similaire au « problème du cocktail party » de séparation des voix individuelles dans une foule. Erreur moyenne : 10 BPM.

WAVELET — Utilise une technique mathématique appelée décomposition en ondelettes pour analyser le signal à différentes échelles temporelles simultanément. Dans nos tests, c'était la moins précise (erreur moyenne : 23 BPM).

CONSENSUS — Notre estimateur combiné qui essaie d'utiliser les cinq algorithmes ensemble. Il calcule une moyenne pondérée des algorithmes, donnant plus de poids à

ceux avec des signaux plus clairs (SNR plus élevé). Cependant, nous avons découvert un problème : les algorithmes plus faibles (GREEN, WAVELET) contribuent souvent encore à la moyenne malgré leurs grandes erreurs, ce qui dilue l'estimation précise de POS et rend le résultat combiné pire que POS seul.

2.1.2. Variabilité de la fréquence cardiaque

RMSSD (*Root Mean Square of Successive Differences*) — La façon standard de mesurer la variation du temps entre les battements cardiaques consécutifs. Elle nécessite la détection de chaque battement individuel avec une haute précision (typiquement en utilisant un ECG ou une ceinture thoracique à résolution milliseconde). Le RMSSD reflète l'activité du système nerveux parasympathique (la branche « repos et digestion ») et est un indicateur bien établi du stress et de l'excitation émotionnelle.

Variabilité du BPM (notre métrique) — Comme notre système basé sur webcam ne peut pas détecter les battements individuels (il estime le BPM sur des fenêtres de 2–5 secondes), nous ne pouvons pas calculer le vrai RMSSD. À la place, nous mesurons combien l'estimation du BPM fluctue d'une fenêtre d'analyse à la suivante. Cela capture les changements de fréquence cardiaque à grande échelle (par ex., la fréquence cardiaque passant de 75 à 85 BPM en 10 secondes) mais manque les variations fines battement par battement que le RMSSD mesure. Les deux métriques sont liées mais non interchangeables.

2.2. RECONNAISSANCE DES ÉMOTIONS FACIALES

FER (*Facial Emotion Recognition*) — Une technologie qui identifie automatiquement les émotions à partir des expressions faciales dans des images ou vidéos. Notre système utilise deux approches complémentaires : un modèle d'apprentissage profond (HSEmotion) et un suivi géométrique facial (MediaPipe).

Action Units (AU) — Une façon standardisée de décrire les mouvements musculaires faciaux individuels. Par exemple, AU1 est le lever du sourcil interne (quand on a l'air surpris), AU4 est l'abaissement du sourcil (quand on fronce les sourcils). La peur implique

typiquement AU1 + AU4 + AU5 (lever du sourcil + abaissement + lever de la paupière supérieure) + AU20 (étireur de lèvres).

FACS (*Facial Action Coding System*) — Le catalogue complet de tous les mouvements musculaires faciaux possibles, développé par les psychologues Paul Ekman et Wallace Friesen. Il définit 44 action units qui peuvent être combinées pour décrire n'importe quelle expression faciale.

HSEmotion — Le modèle d'apprentissage profond que notre système utilise pour classer les émotions à partir d'une photographie du visage. Étant donné une image de visage, il produit une probabilité pour chacune des huit émotions (colère, mépris, dégoût, peur, joie, neutre, tristesse, surprise) plus des scores continus d'arousal et de valence. Il est construit sur une architecture EfficientNet-B0 (voir ci-dessous) et a été pré-entraîné sur de grands jeux de données émotionnelles.

EfficientNet-B0 — Une architecture de réseau de neurones compacte conçue pour reconnaître efficacement les motifs dans les images. C'est le moteur interne que HSEmotion utilise pour traiter les images de visages. « B0 » indique la variante la plus petite et la plus rapide de la famille EfficientNet.

Softmax — Une fonction mathématique qui convertit une liste de scores bruts en probabilités qui somment à 100 %. Par exemple, si le modèle donne des scores bruts de [3.2, 1.1, 0.5] pour [peur, surprise, neutre], le softmax les convertit en probabilités comme [78 %, 15 %, 7 %].

MediaPipe — Une bibliothèque de vision par ordinateur développée par Google. Dans notre système, elle sert deux objectifs : (1) détecter le visage et y placer 478 points précis (landmarks) — 468 pour le visage et 10 pour les iris —, et (2) calculer 52 coefficients de blendshapes qui mesurent des mouvements faciaux spécifiques.

Blendshapes — Des nombres entre 0 et 1 qui décrivent combien chaque partie du visage bouge. Par exemple, *eyeWideLeft* = 0.8 signifie que l'œil gauche est ouvert à 80 % de son maximum, tandis que *jawOpen* = 0.3 signifie que la mâchoire est légèrement ouverte. Notre système calcule 52 de ces valeurs à chaque image.

Arousal — Le degré d'activation émotionnelle d'une personne, sur une échelle de calme (−1) à excité (+1). Avoir peur produit un arousal élevé. S'ennuyer ou être détendu produit un arousal faible. Ceci est estimé par le modèle HSEmotion.

Valence — Le caractère positif ou négatif d'une émotion, sur une échelle de désagréable (−1) à agréable (+1). La peur a une valence négative (c'est désagréable) et un arousal élevé (c'est intense).

mp_tension — Un score que nous calculons à partir des blendshapes de MediaPipe pour mesurer la tension faciale globale. Il combine les signaux des sourcils froncés, des yeux écarquillés, de la mâchoire crispée et des lèvres pressées — les signes physiques de tension ou de peur sur le visage. Des valeurs plus élevées signifient une expression plus tendue.

F12 (hybrid_amp) — Notre formule la plus performante pour détecter les événements de peur. Elle combine l'estimation de peur du modèle d'apprentissage profond avec la mesure de tension faciale :

$$F12 = (0.7 \times hs_fear + 0.3 \times hs_arousal) \times (1 + mp_tension) \quad (2.1)$$

La première partie mélange la probabilité de peur du modèle (poids 70 %) avec son estimation d'arousal (poids 30 %). La seconde partie amplifie le score lorsque le visage montre une tension physique. Ainsi, la classification émotionnelle de l'IA et les mouvements musculaires mesurables doivent concorder pour un score élevé.

F15 (rppg_amp) — Une version améliorée de F12 qui prend aussi en compte la fréquence cardiaque du joueur. Si la fréquence cardiaque est élevée au-dessus de la ligne de base personnelle du joueur, F15 augmente le score de peur :

$$F15 = F12 \times (1 + 0.5 \times bpm_norm) \quad (2.2)$$

Ici, *bpm_norm* mesure de combien la fréquence cardiaque actuelle dépasse la ligne de base (0 = à la ligne de base, 1 = significativement élevée). Quand la fréquence cardiaque est normale, F15 égale F12 — pas de changement. Quand la fréquence cardiaque est élevée (par ex., après un sursaut), le score augmente jusqu'à 50 %. Cela signifie que le jeu répond non seulement à ce que votre visage montre mais aussi à ce que votre corps ressent.

Score composite — Un nombre unique produit en combinant plusieurs signaux (par ex., la probabilité de peur du modèle IA et le score de tension du suivi facial) en une seule

mesure unifiée de la probabilité que la personne éprouve de la peur.

2.3. COMMENT NOUS MESURONS LES PERFORMANCES DU SYSTÈME

Précision — De toutes les fois où notre système a dit « c’est un événement de peur », combien étaient réellement de vrais événements de peur ? Une précision de 90 % signifie que 9 détections sur 10 étaient correctes, et seulement 1 était une fausse alarme. Formule : $VP/(VP + FP)$.

Rappel — De tous les événements de peur réels qui se sont produits, combien notre système en a-t-il réellement détectés ? Un rappel de 60 % signifie que le système a capté 6 événements réels sur 10 et en a manqué 4. Formule : $VP/(VP + FN)$.

F1-Score — Un nombre unique qui équilibre la précision et le rappel. C’est la moyenne harmonique des deux : $2 \times P \times R / (P + R)$. Un F1 de 1.0 signifierait une précision et un rappel parfaits. Notre meilleure formule FER uniquement (F12) atteint un $F1 = 0.70$ sur six sessions ; avec l’augmentation par fréquence cardiaque (F15), $F1 = 0.77$ sur quatre sessions avec données cardiaques. Ni la précision ni le rappel ne sont parfaits, mais le système capte la plupart des événements de peur avec peu de fausses alarmes.

Vrai positif (VP) — Un événement de peur qui s’est réellement produit et que notre système a correctement détecté.

Faux positif (FP) — Notre système a dit « événement de peur » mais il n’y avait pas de véritable événement de peur. Une fausse alarme.

Faux négatif (FN) — Un véritable événement de peur s’est produit mais notre système l’a manqué.

Évaluation au niveau événementiel vs au niveau image — Nous pouvons évaluer le système de deux façons. *Au niveau image* : vérifier chaque image vidéo individuelle (30 par seconde). *Au niveau événementiel* : vérifier si le système a détecté chaque événement de peur dans son ensemble, dans une fenêtre temporelle raisonnable. Nous utilisons l’évaluation au niveau événementiel car un événement de peur dure plusieurs secondes, et le détecter avec 1–2 secondes de retard reste utile dans un contexte de jeu.

Détecteur à fenêtre glissante — Notre mécanisme de détection fonctionne comme une

loupe mobile balayant le temps. Il regarde une fenêtre d'images (par ex., 10 secondes) et compte quelle fraction de ces images a un score de peur au-dessus du seuil. Si suffisamment d'images sont au-dessus du seuil (le *ratio de remplissage*), il déclare un événement de peur.

Ratio de remplissage — La proportion d’images dans la fenêtre de détection dont le score dépasse le seuil. Une exigence de ratio de remplissage de 0.65 signifie qu’au moins 65 % des images de la fenêtre doivent montrer des scores de peur élevés avant que le système ne déclare un événement de peur. Cela empêche les pics de bruit brefs de déclencher de fausses détections.

2.3.1. Tests statistiques

Test t de Welch — Un test statistique qui répond à la question : « Ces deux groupes sont-ils vraiment différents, ou la différence pourrait-elle être due au hasard ? » Nous l’utilisons pour comparer la fréquence cardiaque pendant les événements de peur vs les moments sans peur. Le test tient compte du fait que les groupes peuvent avoir des quantités différentes de variabilité.

d de Cohen — Une mesure de l’ampleur d’une différence en termes pratiques. Même si une différence est statistiquement significative, elle pourrait être trop petite pour compter. Le d de Cohen exprime la différence en unités d’écart-type : $d < 0.2$ = trivialement petit, $0.2-0.5$ = petit, $0.5-0.8$ = moyen (notable), > 0.8 = large. Notre meilleur résultat (POS@10s, $d = 0.70$) est un effet moyen à large.

Valeur p — La probabilité d’observer un résultat aussi extrême s’il n’y avait vraiment aucun effet réel. Une valeur p de 0.003 signifie qu’il n’y a que 0.3 % de chance que le résultat soit dû au hasard. Par convention, $p < 0.05$ (5 %) est considéré comme statistiquement significatif.

Corrélation de Pearson (r) — Un nombre entre -1 et $+1$ mesurant la relation linéaire entre deux variables. $r = +1$ signifie une relation positive parfaite, $r = 0$ signifie aucune relation linéaire, $r = -1$ signifie une relation inverse parfaite.

Corrélation de Spearman (ρ) — Similaire à Pearson, mais mesure si deux variables tendent à augmenter ou diminuer ensemble *selon n’importe quel motif cohérent*, pas seulement en ligne droite. Plus robuste lorsque les données contiennent des valeurs aberrantes.

Test de permutation — Une façon de tester si un résultat est réel sans faire d’hypothèses sur la distribution des données. Nous prenons nos données réelles et mélangeons aléatoirement les étiquettes (par ex., quelles fenêtres de BPM sont « peur » et lesquelles sont « non-peur ») des milliers de fois. Si notre résultat réel est plus extrême que presque tous les résultats mélangés, l’effet est probablement réel et non dû au hasard.

FWER (*Family-Wise Error Rate*) — Lorsque nous testons de nombreuses configurations (par ex., 48 combinaisons différentes d’algorithmes et de fenêtres), la chance de trouver au moins un faux positif augmente. La correction FWER y remédie : nous mélangeons les étiquettes 10 000 fois, et chaque fois nous enregistrons la *meilleure* valeur p sur *toutes* les configurations. La valeur p corrigée est la fraction de mélanges qui ont produit une meilleure valeur p aussi bonne que la nôtre. Cela tient rigoureusement compte du fait d’avoir testé de nombreuses configurations.

2.4. ARCHITECTURE DU SYSTÈME

Cascade de Haar — L’un des algorithmes de détection faciale les plus anciens et les plus rapides, datant de 2001. Il fait glisser une fenêtre sur l’image à la recherche de motifs de régions claires et sombres caractéristiques des visages. Rapide mais en difficulté dans les environnements sombres où les traits faciaux manquent de contraste.

MediaPipe FaceLandmarker — Le détecteur facial moderne de Google qui non seulement trouve les visages mais y place aussi 478 points précis (468 visage + 10 iris) (sourcils, nez, lèvres, mâchoire, etc.) et calcule 52 coefficients de blendshapes. Fonctionne en temps réel sur du matériel grand public.

Détection hybride — Notre stratégie pour gérer les environnements de jeu sombres : le système essaie d’abord le détecteur rapide à cascade de Haar. Si Haar échoue (fréquent en faible éclairage, où il ne détectait les visages que 30 % du temps), il se replie sur MediaPipe. Cette combinaison atteint 99.9 % de couverture de détection faciale même sous éclairage moniteur uniquement.

ROI (*Region of Interest*) — La zone spécifique du visage utilisée pour l'extraction du signal rPPG. Toutes les régions du visage ne sont pas également bonnes pour mesurer le signal du battement cardiaque. Notre système utilise trois régions ordonnées par préférence : le front (meilleur signal, 11 points de landmarks), la glabelle (la zone entre les sourcils, 6 points), et la région malaire (pommettes). Si le front est occulté (par ex., par la main du joueur), le système se replie automatiquement sur la prochaine région disponible. Une vérification de la couleur de peau dans l'espace colorimétrique HSV s'assure que la région sélectionnée contient effectivement de la peau.

Socket TCP — Une connexion réseau fiable entre notre logiciel d'analyse Python et le moteur de jeu Unity. Il envoie les scores de peur et les données de fréquence cardiaque en temps réel, avec l'aller-retour complet (capture d'image → analyse → réponse du jeu) prenant environ 53 millisecondes.

FPS (*Frames Per Second*) — Le nombre d'images vidéo que le système traite chaque seconde. Notre analyse des émotions faciales tourne à environ 20 FPS, et l'extraction de la fréquence cardiaque à environ 30 FPS. Les deux sont suffisamment rapides pour une interaction de jeu en temps réel.

Bibliographie

- Abdeldayem, M. A., Hamed, H. F. A., & Nagy, A. M. (2026). Facial expression recognition: A survey of techniques, datasets, and real-world challenges. *Statistics, Optimization and Information Computing*, 15, 733–761.
- Acharya, B., Saakyan, W., Hammer, B., & Drimalla, H. (2025). The reliability of remote photoplethysmography under low illumination and elevated heart rates. *npj Digital Medicine*.
- Alqahtani, N., Shaikh, A., & Keerio, I. K. (2025). Robust detection of partially occluded faces in low-light scenarios using YOLOv7 and YOLOv6. *International Journal of Advanced Computer Science and Applications (IJACSA)*, 16(11).
- Cheong, J. H., Jolly, E., Xie, T., Byrne, S., Kenney, M., & Chang, L. J. (2023). Py-feat: Python facial expression analysis toolbox. *Affective Science*, 4, 781–796.
- Gutiérrez, R., Villegas-Ch, W., & Luján-Mora, S. (2025). Implementing federated learning for privacy-preserving emotion detection in educational environments. *Frontiers in Artificial Intelligence*, 8, 1644844.
- Hossan, M. M., Tasnim, R. A., & Eishita, F. Z. (2025). Can you keep calm?: Adaptive gameplay using heart rate as a controller. In *2025 Intermountain Engineering, Technology and Computing (IETC)*: IEEE.
- Karani, R. & Desai, S. (2022). Review on multimodal fusion techniques for human emotion recognition. *International Journal of Advanced Computer Science and Applications (IJACSA)*, 13(10).
- Kopalidis, T., Solachidis, V., Vretos, N., & Daras, P. (2024). Advances in facial expression recognition: A survey of methods, benchmarks, models, and datasets. *Information*, 15(3), 135.
- Li, Y., Zhou, Z., Feng, Q., & Li, H. (2025). Analysis and comparison of machine learning-based facial expression recognition algorithms. *Algorithms*, 18(12), 800.
- Moghimi, M. & Grailu, H. (2024). General ROI selection approach in rPPG for accurate heart rate estimation. *Journal of Electrical Systems*, 20(3), 4445–4456.
- Moschovitis, P. & Denisova, A. (2022). Keep calm and aim for the head: Biofeedback-controlled dynamic difficulty adjustment in a horror game. *IEEE Transactions on Games*, 15(3), 368–377.
- Savchenko, A. V. (2025). HSEmotion team at ABAW-8 competition: Audiovisual ambivalence/hesitancy, emotional mimicry intensity and facial expression recognition. *arXiv preprint arXiv:2503.10399*.
- Shao, H., Luo, L., Qian, J., Yan, M., Chen, S., & Yang, J. (2025). Remote photoplethysmography in real-world and extreme lighting scenarios. *arXiv preprint arXiv:2503.11465*.
- Wang, W., den Brinker, A. C., Stuijk, S., & de Haan, G. (2017). Algorithmic principles of remote PPG. *IEEE Transactions on Biomedical Engineering*, 64(7), 1479–1491.
- Yan, J., Li, P., Du, C., Zhu, K., Zhou, X., Liu, Y., & Wei, J. (2024). Multimodal emotion recognition based on facial expressions, speech, and body gestures. *Electronics*, 13(18), 3756.
- Yang, S., Yoon, B., Kang, S., Song, H., & Woo, W. (2026). OFERA: Blendshape-driven 3D gaussian control for occluded facial expression to realistic avatars in VR. *arXiv preprint arXiv:2602.01748*.