

Reconnaissance Émotionnelle et Mécaniques de Jeu Adaptatives : Une Revue de Littérature sur l'Informatique Affective dans le Survival Horror

Ali Burak Saraç
Université Galatasaray
İstanbul, Turquie
Email : 21401932@ogr.gsu.edu.tr

Résumé—Cette revue de littérature examine l'état actuel de la recherche sur la reconnaissance des expressions faciales (FER), la photopléthysmographie à distance (rPPG) et l'ajustement dynamique de la difficulté (DDA) basé sur le biofeedback pour les jeux de survival horror. La revue répond à sept questions de recherche concernant la fusion de capteurs multimodaux, la fiabilité de détection en faible luminosité et les contraintes de latence pour un gameplay immersif. L'analyse révèle que, bien que des progrès significatifs aient été réalisés pour chaque modalité individuellement, la combinaison de FER et rPPG spécifiquement pour les jeux d'horreur reste inexplorée.

Index Terms—Reconnaissance des expressions faciales, Photopléthysmographie à distance, Biofeedback, Ajustement dynamique de la difficulté, Survival Horror, Reconnaissance des émotions multimodale, Informatique affective

I. INTRODUCTION

Les jeux vidéo ont évolué, passant de simples divertissements à des expériences interactives sophistiquées. Les jeux de survival horror offrent des opportunités uniques pour l'intégration du biofeedback, car ils provoquent des réponses émotionnelles fortes comme la peur et la tension. Détecter ces émotions en temps réel ouvre de nouvelles possibilités pour créer des expériences d'horreur personnalisées.

A. Motivation personnelle et vision

Les jeux traditionnels reposent sur des appuis de boutons comme seul canal de communication. Pourtant, les expériences les plus mémorables émergent quand les jeux reconnaissent nos réactions involontaires : hésitation, peur, tension.

Until Dawn (2015) illustre cette philosophie : pendant les séquences « Ne bougez pas », les joueurs devaient physiquement maintenir leur manette immobile. Tout tremblement détecté pouvait mener à la mort du personnage. Soudainement, l'état physiologique réel du joueur influençait directement le résultat du jeu.

Cette expérience a fait naître une question : *Et si un jeu pouvait détecter si vous avez vraiment peur ?* Le concept de « Façade Fissurée » est né de cette vision : un jeu de survival horror qui surveille l'état émotionnel du joueur via expressions faciales et rythme cardiaque, puis adapte ses éléments d'horreur. Le jeu défie les joueurs de littéralement « rester calmes » face à la terreur.

B. Questions de recherche

Cette revue de littérature est guidée par sept questions de recherche fondamentales :

- 1) **RQ1** : Comment combiner FER et rPPG pour la détection d'émotions en temps réel ?
- 2) **RQ2** : Quels mécanismes DDA fonctionnent le mieux pour les jeux d'horreur ?
- 3) **RQ3** : Comment la faible luminosité et l'occlusion affectent-elles la fiabilité de détection ?
- 4) **RQ4** : Les systèmes webcam peuvent-ils égaler les performances des capteurs portables ?
- 5) **RQ5** : Py-Feat peut-il maintenir sa précision dans des conditions sombres ?
- 6) **RQ6** : Comment la logique de fusion doit-elle prioriser le rythme cardiaque quand la détection faciale échoue ?
- 7) **RQ7** : Quelle est la latence maximale acceptable avant que l'immersion ne se brise ?

C. Approche technique

Le système proposé utilisera deux modalités complémentaires pour la détection d'émotions :

- 1) **Reconnaissance des expressions faciales (FER)** : Utilisation de techniques de vision par ordinateur pour analyser les unités d'action faciale et classifier les états émotionnels (particulièrement la peur, la surprise et la tension) à partir de l'entrée webcam. Cela fournit une classification émotionnelle discrète avec une haute résolution temporelle.
- 2) **Photopléthysmographie à distance (rPPG)** : Extraction des informations de rythme cardiaque à partir de variations subtiles de couleur dans la vidéo faciale sans nécessiter de capteurs physiques. Cela fournit des données continues d'éveil physiologique qui complètent les classifications FER discrètes.

En fusionnant ces modalités, le jeu peut obtenir une compréhension plus robuste de l'état émotionnel du joueur et ajuster les éléments de gameplay en conséquence, y compris les taux d'apparition des ennemis, la proximité des menaces, les conditions d'éclairage, le design sonore ambiant, et le timing et la fréquence des jump scares.

D. Lacunes identifiées dans la littérature

Grâce à une analyse systématique de la recherche récente, plusieurs lacunes émergent qui motivent ce projet :

- 1) **Pas d'intégration FER+rPPG pour les jeux d'horreur** : Bien que les deux modalités aient été étudiées indépendamment, leur fusion spécifiquement pour les applications de survival horror reste inexplorée.
- 2) **Défis de performance en faible luminosité** : Les jeux d'horreur présentent typiquement des environnements sombres, mais la plupart des benchmarks FER et rPPG utilisent des conditions de laboratoire bien éclairées.
- 3) **Gestion de l'occlusion pendant le gameplay** : Les joueurs couvrent instinctivement leur visage pendant les moments effrayants, créant des défis de détection que les systèmes existants n'abordent pas adéquatement.
- 4) **Exigences de traitement en temps réel** : Les applications de jeu demandent une détection d'émotions à faible latence, que de nombreux systèmes académiques actuels ne peuvent garantir.
- 5) **Considérations de confidentialité** : Le traitement des données faciales soulève des préoccupations de confidentialité qui n'ont pas été adéquatement abordées dans les contextes de jeu.

Cette revue de littérature examine dix articles académiques qui fournissent les fondements théoriques et techniques pour relever ces défis.

II. REVUE DE LITTÉRATURE

A. Article 1 : *Py-Feat—Python Facial Expression Analysis Toolbox*

1) *Données*: Cheong et al. [1] présentent Py-Feat, une boîte à outils Python open-source conçue pour démocratiser l'analyse des expressions faciales pour les chercheurs de toutes disciplines. L'article répond à une lacune critique : bien que l'informatique affective ait fait des avancées remarquables dans la détection automatique des expressions faciales, ces capacités restent largement inaccessibles aux chercheurs en sciences sociales qui manquent d'expertise en vision par ordinateur.

Les approches automatisées de vision par ordinateur offrent une alternative convaincante, permettant aux chercheurs de traiter de grands ensembles de données vidéo sans annotation manuelle. Cependant, les auteurs identifient deux principales barrières à l'adoption en sciences sociales : (1) la barrière technique élevée pour entraîner et accéder aux modèles de pointe, nécessitant des connaissances sur les architectures de réseaux de neurones, la programmation GPU et les grands ensembles de données étiquetées ; et (2) l'absence de logiciels open-source conviviaux qui intègrent détection, prétraitement, analyse et visualisation dans un flux de travail cohérent. Py-Feat vise à répondre à ces deux barrières.

Les auteurs effectuent un benchmarking complet sur cinq ensembles de données établis, chacun ciblant différents aspects de l'analyse des expressions faciales :

- **WIDER FACE** : Un benchmark de détection faciale à grande échelle contenant 393 703 annotations de boîtes englobantes sur 32 203 images. L'ensemble de données comprend trois niveaux de difficulté (Facile, Moyen, Difficile) basés sur la taille du visage, l'occlusion et la variation de pose. C'est particulièrement pertinent pour évaluer la robustesse de la détection faciale.
- **300W** : Un benchmark de détection de points de repère avec plus de 600 participants et 600 images capturées dans des conditions variables de luminance, d'échelle, de pose de tête, d'expressions faciales et d'occlusion partielle. Cet ensemble de données est critique pour évaluer la robustesse dans des conditions non idéales similaires aux environnements de jeux d'horreur.
- **BIWI Kinect** : Un ensemble de données d'estimation de pose de tête contenant 15 000 images de 20 participants, capturées avec des caméras de profondeur Microsoft Kinect. La vérité terrain est fournie via des capteurs magnétiques attachés à la tête des participants.
- **DISFA+** : Un benchmark de détection d'unités d'action avec 57 000 images de 9 participants. Chaque image est annotée avec des intensités d'UA sur une échelle de 0-5 par des codeurs FACS certifiés, fournissant une vérité terrain de haute qualité pour l'analyse au niveau des UA.
- **AffectNet** : L'un des plus grands ensembles de données de reconnaissance d'émotions « in-the-wild », contenant environ 440 000 images annotées manuellement à travers sept catégories d'émotions (colère, mépris,

dégoût, peur, joie, tristesse, surprise) plus neutre. Les images sont collectées à partir de recherches Internet, fournissant des conditions « sauvages » écologiquement valides.

2) *Méthodologie*: Py-Feat utilise une architecture modulaire basée sur un pipeline qui sépare l'analyse des expressions faciales en étapes distinctes, chacune avec plusieurs options de détecteurs interchangeable :

Étape de détection faciale : La première étape identifie les boîtes englobantes des visages dans les images ou les frames vidéo. La boîte à outils implémente plusieurs algorithmes de détection tels que RetinaFace, MTCNN et FaceBoxes.

Étape de détection de points de repère : Après la détection faciale, 68 points de repère faciaux sont localisés pour permettre l'analyse géométrique et l'alignement du visage. Les options incluent PFLD (Practical Facial Landmark Detector), des détecteurs basés sur MobileNet, et MobileFaceNet optimisé pour l'extraction de caractéristiques spécifiques au visage.

Estimation de pose de tête : Utilisant Img2Pose, une approche basée sur CNN qui détecte conjointement les visages et estime la pose de tête à 6-DoF (tangage, roulis, lacet).

Pipeline de détection d'unités d'action : Les UA représentent l'activation de groupes musculaires faciaux spécifiques (par exemple, AU1 = relèvement du sourcil interne, AU12 = tireur du coin des lèvres, AU4 = abaissement du sourcil pertinent pour la peur). Le système peut détecter 20 UA couramment étudiées, chacune représentant des mouvements musculaires faciaux spécifiques.

Détection d'émotions : La classification catégorielle des émotions emploie ResMaskNet, un Residual Masking Network qui combine un backbone de réseau résiduel profond (ResNet) pour l'apprentissage hiérarchique de caractéristiques avec des blocs de masquage basés sur l'attention qui se concentrent sur les régions faciales pertinentes pour les émotions tout en supprimant le bruit de fond. Le système classe sept émotions de base : colère, dégoût, peur, joie, tristesse, surprise et neutre.

3) Résultats clés:

- RetinaFace a atteint la plus haute précision de détection faciale sur WIDER FACE (Facile : 0,760, Moyen : 0,669, Difficile : 0,347 précision moyenne).
- MobileFaceNet a surpassé les autres détecteurs de points de repère avec 4,99 RMSE sur 300W-Test.
- Pour la détection d'UA, le commercial FACET-iMotions a atteint le score F1 moyen le plus élevé, suivi d'Open-Face. Le modèle XGB de Py-Feat a obtenu les meilleurs résultats sur AU20 et AU26.
- Pour la détection d'émotions sur AffectNet, ResMask-Net a atteint un score F1 moyen de 0,55, avec la détection de joie atteignant 0,77.
- Les tests de robustesse ont révélé que la détection faciale reste relativement robuste aux changements modérés de luminosité, mais la détection d'UA et d'émotions montre des baisses de performance significatives dans des conditions de faible luminosité.
- Les occlusions partielles nuisent significativement à la détection : les occlusions du bas du visage affectent AU12, AU25, AU26 ; les occlusions du haut du visage affectent AU1, AU2, AU4 (UA liées à la peur).
- La rotation de la tête au-delà de 45° cause une baisse brusque de la précision ; les vues de profil sont inutilisables pour l'analyse d'expressions.

4) Points forts:

- Open-source, gratuit et multiplateforme (Mac, Windows, Unix).
- Accélération GPU via PyTorch pour le traitement en temps réel.
- Conception modulaire permettant le benchmarking de différents modèles.
- Outils complets de prétraitement, d'analyse et de visualisation.
- Développement actif avec contributions de la communauté.

5) Limitations:

- La détection d'UA utilise l'apprentissage superficiel (SVM/XGB) plutôt que l'apprentissage profond, limitant potentiellement la généralisation.
- Les scores F1 de détection d'émotions sont modérés (moyenne 0,55), avec une détection de peur probablement plus faible.
- Pas d'interface graphique : nécessite des connaissances en programmation Python.
- Les expériences de robustesse montrent une dégradation claire des performances dans des conditions difficiles.

6) *Relation avec notre travail:* Py-Feat est le candidat principal pour le composant de reconnaissance des expressions faciales de « Façade Fissurée ». Plusieurs facteurs le rendent particulièrement adapté :

Faisabilité d'intégration : L'architecture basée sur Python permet une intégration directe avec un moteur de jeu Unity via communication par socket (par exemple, ZeroMQ ou WebSocket). Un processus Python peut exécuter Py-Feat en boucle continue, capturant les frames de la webcam, les traitant à travers le pipeline de détection, et envoyant les prédictions d'émotions à Unity en temps réel.

Pertinence pour les questions de recherche :

- **RQ1** (combinaison FER + rPPG) : Py-Feat fournit le composant FER ; sa sortie modulaire (probabilités d'émotions, intensités d'UA) peut être fusionnée avec les données de rythme cardiaque de rPPG.
- **RQ3** (effets faible luminosité/occlusion) : Les expériences de robustesse quantifient la dégradation de performance attendue, informant les exigences de prétraitement.
- **RQ5** (Py-Feat dans des conditions sombres) : Preuve directe que le prétraitement sera nécessaire.

Stratégies d'atténuation pour les limitations identifiées :

- **Faible luminosité** : Appliquer CLAHE (Contrast Limited Adaptive Histogram Equalization) aux frames webcam avant le traitement Py-Feat.
- **Occlusion** : Utiliser la détection faciale basée sur YOLOv7 (Article 8) comme première étape robuste avant de passer à Py-Feat.
- **Confusion peur/surprise** : Comme la peur et la surprise partagent des patterns d'UA similaires (yeux grands ouverts, sourcils relevés), fusionner les prédictions FER avec les données de rythme cardiaque : un rythme cardiaque élevé permet de désambiguïser vers la peur plutôt que vers la surprise neutre.

La conception modulaire offre de la flexibilité : si la précision émotionnelle de Py-Feat s'avère insuffisante pendant le développement, des modèles alternatifs peuvent être substitués sans reconcevoir l'ensemble du pipeline.

B. Article 2 : *Advances in Facial Expression Recognition—A Survey*

1) *Données*: Kopalidis et al. [2] fournissent une revue complète des méthodes, benchmarks, modèles et ensembles de données dans la reconnaissance des expressions faciales (FER). Cet article établit les fondements théoriques pour comprendre la technologie FER et sa maturité en tant que domaine. Les auteurs cataloguent 21 ensembles de données couramment utilisés couvrant trois décennies de recherche :

Ensembles de données contrôlés en laboratoire :

- **CK+ (Extended Cohn-Kanade)** : 593 séquences de 123 sujets avec des frames d'expression maximale. Expressions posées de haute qualité mais diversité limitée.
- **MMI** : 740 séquences de 32 sujets incluant la dynamique temporelle.
- **Oulu-CASIA** : Séquences VIS et NIR sous éclairage variable.
- **JAFFE** : 213 images de 10 femmes japonaises—souvent critiqué pour biais culturel et de genre.

Ensembles de données « in-the-wild » :

- **AffectNet** : ~440 000 images avec annotations catégorielles et valence-arousal. Le plus grand ensemble FER disponible publiquement.
- **FER2013** : 35 887 images en niveaux de gris 48×48—benchmark largement utilisé mais connu pour ses étiquettes bruitées.
- **RAF-DB** : 30 000 images avec annotations crowdsourcées et haute fiabilité inter-annotateurs.
- **ExpW** : Ensemble à grande échelle « in-the-wild » collecté par crawling web.

Ensembles vidéo/temporels : AFEW (Acted Facial Expressions in the Wild) et DFEW (Dynamic FER in the Wild) capturent la dynamique temporelle des expressions, permettant l'analyse du début, de l'apex et de la fin des expressions.

2) *Méthodologie*: La revue retrace l'évolution des méthodes FER :

Traditionnelles (avant 2012) : Caractéristiques géométriques (points de repère, distances, angles), d'apparence (Gabor, LBP, HOG), et classifieurs (SVM, k-NN, Random Forests).

Deep Learning (2012-présent) : CNNs (VGGNet, ResNet, EfficientNet), GANs pour l'augmentation, Graph CNs pour les dépendances spatiales, et Vision Transformers pour le contexte global.

Représentation : Catégorielle (6 émotions d'Ekman + mépris/neutre) ou dimensionnelle (valence-arousal).

3) *Résultats clés*:

- **Supériorité du Deep Learning** : L'apprentissage profond surpasse significativement le ML traditionnel sur tous les benchmarks, avec les modèles basés sur l'attention atteignant l'état de l'art.
- **Croissance du marché** : Le marché de la reconnaissance d'émotions devrait passer de 21,7 milliards \$ (2021) à 136,2 milliards \$ d'ici 2031, indiquant un fort intérêt commercial.

- **Confusion peur/surprise** : Ces émotions sont fréquemment mal classifiées en raison d'activations musculaires faciales similaires (yeux grands ouverts, sourcils relevés)—défi critique pour les jeux d'horreur.

- **Cinq défis non résolus** : Surapprentissage sur petits ensembles, variation d'illumination, variation de pose de tête, faible résolution d'image, biais d'identité où les modèles apprennent l'identité du sujet plutôt que l'expression.

- **Illumination critique** : La dégradation des performances sous éclairage variable est systématiquement rapportée—directement pertinent pour les environnements sombres des jeux d'horreur.

4) *Points forts*:

- Couverture complète d'environ 60 méthodes couvrant trois décennies.
- Taxonomie claire distinguant ensembles contrôlés vs. « in-the-wild », et méthodes traditionnelles vs. apprentissage profond.
- Identification de défis spécifiques avec stratégies d'atténuation proposées.
- Discussion des représentations d'émotions catégorielles et dimensionnelles.

5) *Limitations*:

- Le format de revue privilégie la largeur sur la profondeur—méthodes individuelles non analysées en détail.
- Discussion limitée des contraintes temps réel et de vitesse d'inférence.
- N'aborde pas la fusion multimodale avec les signaux physiologiques (rythme cardiaque, conductance cutanée).
- Analyse de performance spécifique à la peur manquante malgré son importance pour le jeu affectif.

6) *Relation avec notre travail*: Cette revue fournit les fondements théoriques essentiels pour « Façade Fissurée » :

- **RQ1** : Établit la FER comme un domaine mature avec des méthodes prouvées. Les approches d'apprentissage profond sont validées sur plusieurs benchmarks.

- **RQ3** : La variation d'illumination est explicitement identifiée comme un défi majeur non résolu, confirmant le besoin de prétraitement (CLAHE) dans les conditions des jeux d'horreur.

- **Sélection d'algorithme** : Compromis entre précision (transformers les plus précis mais plus lents) et vitesse (CNNs légers pour le jeu temps réel). Pour « Façade Fissurée », nous priorisons la vitesse avec une précision acceptable.

- **Gestion peur/surprise** : La confusion documentée entre ces émotions renforce le besoin de fusion multimodale—les données de rythme cardiaque peuvent désambiguïser.

C. Article 3 : Analysis and Comparison of ML-Based FER Algorithms

1) *Données*: Li et al. [3] présentent une analyse comparative complète de douze algorithmes FER basés sur le machine learning, établissant un cadre de benchmark unifié pour évaluer les méthodes des paradigmes ML traditionnel et deep learning. L'étude évalue sur quatre ensembles de données « in-the-wild » choisis pour leur taille, diversité et pertinence réelle :

- **AffectNet** : Plus de 450 000 images étiquetées manuellement avec 8 catégories d'émotions. Le plus grand ensemble FER public avec haute variabilité en éclairage, pose et occlusion.
- **FERPlus** : 35 887 images en niveaux de gris 48×48 avec raffinement d'étiquettes crowdsourcé pour réduire le bruit des étiquettes FER2013 originales.
- **FER-2013** : 35 887 images avec 7 catégories, collectées automatiquement mais connues pour les étiquettes bruitées.
- **RAF-DB** : Environ 30 000 images « in-the-wild » avec annotations crowdsourcées et haut accord inter-annotateurs.

2) *Méthodologie*: Les douze méthodes ont été implémentées dans des conditions identiques : GPU NVIDIA RTX 3090, même environnement logiciel (PyTorch/TensorFlow), pipeline de prétraitement identique et protocole d'évaluation unifié. Cette standardisation est la contribution méthodologique clé de l'article.

Machine Learning traditionnel (4 méthodes) :

- **GLCM-SVM** : Caractéristiques de matrice de co-occurrence de niveaux de gris avec classifieur SVM—capture les patterns de texture au niveau pixel.
- **HOG-SVM** : Histogramme de gradients orientés avec SVM—caractéristiques de contours robustes à l'illumination.
- **LBP-SVM** : Local Binary Patterns avec SVM—encode efficacement la texture locale.
- **LPQ-SRC** : Local Phase Quantization avec classification par représentation sparse—caractéristiques invariantes au flou.

Deep Learning (8 méthodes) :

- **ADA-DF** : Deep Forest adaptatif combinant apprentissage d'ensemble et deep learning.
- **CNN-SIFT** : CNN hybride avec extraction Scale-Invariant Feature Transform.
- **EmoNext** : Architecture ConvNeXt modifiée pour la reconnaissance d'émotions.
- **FERGCN/GCN** : Graph Convolutional Networks modélisant les relations entre régions faciales.
- **ResEmoteNet** : Réseau résiduel avec mécanismes d'attention spécifiques aux émotions.
- **ResNet** : Baseline ResNet-18 standard adaptée pour FER.
- **Poster** : Pyramid Cross-Fusion Transformer—modèle basé sur l'attention état de l'art.

3) Résultats clés:

- **Performance ML** : HOG-SVM a atteint la meilleure précision moyenne (50,12%) parmi les quatre méthodes ML traditionnelles, confirmant que les caractéristiques de contours restent pertinentes.
- **Performance DL** : Poster (Pyramid Cross-Fusion Transformer) a atteint la plus haute précision moyenne (75,98%) parmi les méthodes DL, démontrant la puissance des mécanismes d'attention.
- **Difficulté par émotion** : « Mépris » était l'émotion la plus difficile : 10,00% (ML), 40,06% (DL). Cela souligne que même le DL a du mal avec les expressions subtiles.
- **Écart de performance** : L'apprentissage profond atteint environ 25 points de pourcentage de plus que le ML traditionnel en moyenne, justifiant le passage aux approches neuronales.

s

4) Points forts:

- Première étude à comparer 12 méthodes FER sur 4 ensembles de données dans des conditions hardware/software identiques, éliminant les facteurs de confusion.
- Critères de sélection assurant couverture des paradigmes et reproductibilité (code open-source uniquement).
- Inclut discussion des directions futures combinant les LLMs avec FER pour la compréhension contextuelle.
- Fournit des décompositions de précision par émotion, utiles pour sélectionner des méthodes basées sur les émotions cibles.

5) Limitations:

- Limité à la FER basée sur images—pas d'analyse vidéo ou de séquences temporelles.
- Ne teste pas dans des conditions de faible luminosité ou d'occlusion, limitant l'applicabilité aux scénarios de jeux d'horreur.
- Confusion peur/surprise non spécifiquement analysée malgré son importance pour les applications d'horreur.
- Pas de mesures de temps d'inférence, laissant les questions de faisabilité temps réel sans réponse.

6) *Relation avec notre travail*: Cet article répond directement à la sélection d'algorithme pour **RQ1** :

- La précision de 75,98% de Poster démontre que les modèles basés sur transformer peuvent atteindre une forte performance FER, bien que la latence temps réel doive être vérifiée.
- Pour « Façade Fissurée », le fait que « peur » et « surprise » bénéficient toutes deux des méthodes DL suggère que les approches neuronales sont appropriées pour nos émotions cibles.
- L'écart de 26 points de pourcentage entre ML et DL (50,12% vs. 75,98%) justifie la priorité aux détecteurs DL de Py-Feat sur les extracteurs de caractéristiques traditionnels.

D. Article 4 : Can You Keep Calm?—Adaptive Gameplay Using Heart Rate

1) **Données:** Hossan et al. [4] introduisent un jeu contrôlé par rythme cardiaque conçu pour étudier la gestion du stress à travers un gameplay adaptatif basé sur le biofeedback. L'étude est motivée par le potentiel thérapeutique des jeux qui encouragent l'autorégulation physiologique.

Participants : 25 individus (18 hommes, 7 femmes), âgés de 15 à 40 ans. Participants recrutés via réseaux sociaux et universitaires, représentant un mélange de joueurs occasionnels et réguliers.

Matériel : Le rythme cardiaque a été mesuré avec une Google Pixel Watch, une montre connectée commerciale qui transmet les données de rythme cardiaque via Bluetooth à environ 1 lecture par seconde. Ce choix de matériel grand public rend l'étude facilement reproductible.

Établissement de la baseline : Le rythme cardiaque au repos de chaque participant a été établi pendant une période de repos de 3 minutes avant le jeu. Cette baseline a été utilisée pour calculer le seuil adaptatif (baseline + 5 BPM).

2) **Méthodologie:** Le jeu était inspiré de *Flappy Bird*, un jeu casual où les joueurs tapent pour faire voler un oiseau à travers des obstacles. Trois conditions expérimentales ont été comparées intra-sujets, avec ordre randomisé :

- **Niveau 1 (Contrôle) :** Difficulté progressivement croissante standard sans adaptation HR. La vitesse des obstacles augmente avec le temps indépendamment de l'état du joueur.
- **Niveau 2 (HR-Adaptatif) :** La vitesse du jeu diminue de 30% quand le HR du joueur dépasse baseline + 5 BPM, fournissant un soulagement quand le stress est détecté.
- **Niveau 3 (HR-Adaptatif + Objectif) :** Même adaptation que le Niveau 2, mais les joueurs reçoivent un objectif explicite : atteindre un score de 30. Cela ajoute une motivation guidée par un but à la mécanique de relaxation.

Mesures psychologiques :

- **PANAS (Positive and Negative Affect Schedule) :** Questionnaire validé de 20 items mesurant l'affect positif (AP) et négatif (AN) avant et après chaque condition.
- **PXI (Player Experience Inventory) :** Mesure plusieurs dimensions de l'expérience joueur incluant autonomie, compétence, immersion et facilité de contrôle.
- **Réactivité cardiaque (RC) :** Calculée comme l'augmentation du HR moyen pendant le jeu comparé à la baseline, servant de mesure physiologique objective du stress.

Analyse statistique : ANOVA à mesures répétées a été utilisée pour comparer les conditions, avec corrections post-hoc de Bonferroni.

3) Résultats clés:

- **Affect positif :** Le Niveau 3 (adaptatif guidé par objectif) a produit un affect positif significativement plus élevé que le Niveau 1 Contrôle ($F = 4,491$, $p = 0,016$). La combinaison du biofeedback et d'objectifs clairs a amélioré le plaisir.
- **Affect négatif :** Les niveaux HR-adaptatifs (2 et 3) ont montré un affect négatif significativement plus faible que la condition contrôle ($F = 3,87$, $p = 0,041$), démontrant que la difficulté adaptative réduit la frustration.
- **Réactivité cardiaque :** Le Niveau 3 a montré la plus faible réactivité cardiaque parmi toutes les conditions, indiquant que le gameplay guidé par objectif avec adaptation biofeedback réduit efficacement la réponse au stress physiologique.
- **Contrôle perçu :** Les joueurs ont rapporté une plus grande facilité de contrôle significative dans les niveaux HR-adaptatifs ($F = 32,765$, $p < 0,001$).

4) Points forts:

- La montre connectée grand public rend la réplication faisable pour chercheurs et développeurs sans équipement spécialisé.
- Mesures psychologiques validées (PANAS, PXI) fournissent une évaluation scientifiquement rigoureuse de l'expérience joueur.
- Résultat clair : guidé par objectif + adaptatif surpasse à la fois la difficulté statique et les approches purement adaptatives.

5) Limitations:

- Petit échantillon ($n=25$) limite la généralisabilité et la puissance statistique.
- Le seuil +5 BPM est arbitraire—aucune justification fournie pour cette valeur spécifique.
- Sessions courtes (1 minute par niveau) peuvent ne pas capturer les effets d'habituation ou les patterns d'engagement à long terme.
- Échantillon principalement de jeunes adultes peut ne pas représenter des populations de joueurs plus larges.

6) **Relation avec notre travail:** Cet article fournit des insights importants pour **RQ2** (approche DDA) et **RQ4** (matériel) :

- **RQ2 :** Le fait que le gameplay adaptatif guidé par objectif produise les meilleurs résultats suggère que « Façade Fissurée » devrait incorporer des objectifs clairs aux côtés de l'adaptation physiologique.
- **RQ4 :** L'utilisation de montres connectées grand public démontre la faisabilité du monitoring HR par wearables, mais motive l'investigation de rPPG comme alternative sans contact. Les joueurs peuvent résister à porter une montre pendant des sessions de jeu prolongées.
- **Implication design :** Pour « Façade Fissurée », nous devrions considérer implémenter des « zones sûres » ou objectifs vers lesquels les joueurs peuvent travailler quand stressés, plutôt que simplement réduire la difficulté.

E. Article 5 : *Keep Calm and Aim for the Head—Biofeedback DDA in Horror*

1) **Données :** Moschovitis et Denisova [5] présentent « Caroline », un jeu d'horreur avec DDA contrôlé par biofeedback qui implémente une mécanique « Relax-to-Win ». Cet article est la référence la plus directement pertinente pour « Façade Fissurée », car il démontre une implémentation fonctionnelle du concept central : un jeu d'horreur où l'état physiologique du joueur influence directement la difficulté du jeu.

Participants : 42 participants (35 hommes, 5 femmes, 2 non déclarés), recrutés principalement dans des communautés de joueurs. Expérience de jeu moyenne de 15,1 ans, indiquant un échantillon familier avec les conventions des jeux d'horreur.

Design expérimental : Comparaison inter-sujets—groupe DDA (n=21) a joué avec adaptation du rythme cardiaque activée ; groupe contrôle (n=21) a joué avec difficulté fixe. Durée de session environ 20 minutes par participant.

Matériel : Rythme cardiaque mesuré avec un microcontrôleur Arduino Uno connecté à un capteur de rythme cardiaque à clip d'oreille (coût < 50\$). L'Arduino transmettait les données HR via communication série en temps réel.

2) **Méthodologie :** « Caroline » est un jeu de survival horror en première personne (Unreal Engine 4.22). Le joueur navigue dans des environnements sombres tout en étant poursuivi par un ennemi. Le jeu incorpore des éléments classiques d'horreur : espaces sombres confinés, sons d'horreur ambiants, indices audio directionnels, et une mécanique de bruit où les actions du joueur attirent l'ennemi.

Trois paramètres de jeu sont modulés par le rythme cardiaque utilisant des formules mathématiques explicites :

Vitesse maximale de l'ennemi :

$$\text{maxspeed} = \text{HeartRate} \times 2.5 \quad [\text{unités Unreal/s}] \quad (1)$$

Accélération maximale de l'ennemi :

$$\text{maxacceleration} = \text{HeartRate} \times 2.5 \quad [\text{unités Unreal/s}^2] \quad (2)$$

Rayon de détection de bruit du joueur :

$$\text{maxnoiseradius} = \frac{\text{HeartRate}}{60} \times 2250 \quad [\text{unités Unreal}] \quad (3)$$

Ces formules créent une boucle de rétroaction encourageant la régulation émotionnelle.

Mesures psychologiques :

- **Intrinsic Motivation Inventory (IMI) :** Mesure intérêt/plaisir, compétence perçue, effort, valeur/utilité, pression/tension, et choix perçus.
- **CORGIS (Challenge Originating from Recent Gameplay Interaction Scale) :** Distingue les dimensions de défi cognitif, émotionnel, performatif et décisionnel.

3) **Résultats clés :**

- **Motivation intrinsèque :** Les joueurs DDA ont rapporté une motivation et compétence perçue significativement plus élevées—malgré une performance objectivement similaire.

- **Défi décisionnel :** Le groupe DDA a rapporté un défi décisionnel plus faible, interprétant les décisions difficiles comme pilotées par le système plutôt que les leurs.

- **Tension :** Pas de différence significative de tension perçue entre les groupes—la mesure n'a pas créé d'« effet d'observation » confondant.

- **Corrélation Flow :** Corrélation positive modérée ($r = 0,455$, $p = 0,002$) entre motivation intrinsèque et défi perçus, supportant la théorie du flow que le défi adapté mène à un plus grand engagement.

4) **Points forts :**

- Implémentation pratique utilisant du matériel accessible et peu coûteux reproductible par des développeurs indépendants.

- Formules mathématiques explicites pour le mapping HR-vers-paramètres-de-jeu, permettant une adaptation directe.

- Contexte spécifique à l'horreur—contrairement aux jeux de biofeedback stress généraux, adresse l'induction et la gestion d'émotions négatives.

- Design inter-sujets avec instruments psychologiques validés fournit des preuves crédibles.

5) **Limitations :**

- Modalité unique (HR seulement)—pas d'analyse d'expression faciale, conductance cutanée ou autres signaux physiologiques.

- Matériel à clip d'oreille intrusif peut ne pas être acceptable pour l'adoption du jeu casual.

- Sessions courtes de 20 minutes peuvent ne pas capturer les effets d'habituation ou l'apprentissage à long terme.

- Pas de mesure de si les joueurs ont réellement appris à se calmer (développement de la compétence « Relax-to-Win »).

- Échantillon principalement masculin, joueurs expérimentés peuvent ne pas représenter les audiences typiques.

6) **Relation avec notre travail :** Cet article est la référence fondamentale pour « Façade Fissurée », fournissant à la fois une preuve de concept et des conseils d'implémentation pratiques.

- **RQ2 :** Valide que les mécaniques « Relax-to-Win » améliorent l'expérience joueur sans briser l'immersion. Les formules spécifiques fournissent des points de départ pour l'adaptation Unity.

- **RQ7 :** Le système basé sur Arduino a atteint une réactivité temps réel, suggérant qu'une latence sous 100ms est atteignable et suffisante.

- **Lacunes motivant notre recherche :** Utilise HR uniquement—motive RQ1 (ajouter FER pour des données d'émotion plus riches), RQ4 (rPPG sans contact pour remplacer le clip d'oreille), RQ6 (logique de fusion pour combiner les modalités).

- **Implémentation :** Nous adapterons la structure de formules pour Unity, étendant potentiellement le concept de rayon de bruit à la détection visuelle (les ennemis « voient » la peur sur le visage du joueur).

F. Article 6 : Multimodal Emotion Recognition (Face, Speech, Gesture)

1) *Données*: Yan et al. [6] proposent un système de reconnaissance d'émotions trimodal combinant expressions faciales, parole et gestes corporels en utilisant un nouvel algorithme de fusion appelé SLSMKCCA (Supervised Locality Preserving Sparse Multi-view Kernel Canonical Correlation Analysis). Cet article fournit le traitement mathématiquement le plus rigoureux de la fusion multimodale parmi ceux examinés.

Ensembles de données :

- **GEMEP (Geneva Multimodal Emotion Portrayals)** : Acteurs professionnels exprimant des émotions à travers visage, voix et geste coordonnés. Contient 10 acteurs représentant 17 catégories d'émotions avec des enregistrements contrôlés de haute qualité.
- **Polish Database** : Un corpus d'émotions multimodal avec enregistrements synchronisés de visage, parole et geste de locuteurs polonais natifs, fournissant une validation interculturelle.

Les deux ensembles fournissent des modalités synchronisées, permettant des expériences de fusion au niveau des caractéristiques où l'alignement temporel est garanti.

2) *Méthodologie*: Les auteurs cadrent leur travail dans l'Analyse de Corrélation Canonique (CCA), une technique statistique pour trouver des relations entre ensembles de variables. Le CCA standard est limité par l'hypothèse de relations linéaires et l'ignorance de la structure locale des données. SLSMKCCA étend CCA avec quatre innovations clés :

- 1) **Extension kernel** : Projette les données dans des espaces de caractéristiques de haute dimension utilisant des kernels RBF pour capturer les relations non linéaires.
- 2) **Multi-vue** : S'étend au-delà de deux modalités à un nombre arbitraire.
- 3) **Préservation de localité** : Maintient la structure de voisinage local via des termes de Laplacien de graphe.
- 4) **Régularisation sparse** : Pénalité L1 encourage les projections sparse pour l'interprétabilité.

Extraction de caractéristiques :

- **Facial** : 68 points de repère faciaux, réponses aux filtres de Gabor, intensités d'unités d'action.
- **Parole** : Caractéristiques prosodiques (pitch, énergie), MFCCs, qualité vocale (jitter, shimmer).
- **Geste** : Points clés de pose corporelle, trajectoires de mouvement, qualités de mouvement expressif.

Pipeline de fusion : Mapping kernel → Préservation de localité → Régularisation sparse → Contrainte supervisée → Classification SVM avec kernel RBF.

3) Résultats clés:

- **Supériorité multimodale** : La fusion trimodale (visage + parole + geste) surpasse significativement toute combinaison unimodale ou bimodale, validant la valeur de multiples canaux d'entrée.
- **Résolution de conflits** : La fusion au niveau des caractéristiques dans le sous-espace partagé résout implicitement les conflits entre modalités en trouvant des projections qui maximisent la corrélation globale.
- **Gestion temporelle** : L'algorithme accommode l'asynchronie temporelle à travers des caractéristiques au niveau frame avec fenêtrage approprié.
- **Bénéfices de la sparsité** : Les projections sparse identifient les caractéristiques les plus discriminantes de chaque modalité, permettant l'interprétabilité.

4) Points forts:

- Fournit un cadre mathématique rigoureux pour la fusion multimodale avec garanties théoriques.
- Architecture flexible peut accommoder n'importe quel nombre de modalités avec dimensions de caractéristiques arbitraires.
- Projections sparse interprétables révèlent quelles caractéristiques contribuent le plus à la reconnaissance d'émotions.
- Adresse les défis de synchronisation à travers le cadre kernel.

5) Limitations:

- **Complexité computationnelle** : Les méthodes kernel scalent mal avec les grands ensembles de données ; l'optimisation itérative ajoute du overhead, limitant potentiellement les applications temps réel.
- **Exigence de modalité complète** : L'algorithme suppose que toutes les modalités sont disponibles ; les modalités manquantes nécessitent un traitement séparé.
- **Pas de validation temps réel** : Les expériences utilisent un traitement batch hors ligne ; la latence temps réel n'est pas évaluée.
- **Conditions contrôlées** : Les ensembles de données utilisent des acteurs professionnels dans des environnements contrôlés, limitant la généralisation aux expressions spontanées.

6) *Relation avec notre travail*: Cet article fournit des fondements théoriques pour **RQ1** et **RQ6** :

- **Résolution de conflits** : SLSMKCCA offre une approche rigoureuse au problème du « Fake Out »—quand l'expression faciale et le rythme cardiaque sont en désaccord (par exemple, sourire nerveux pendant HR élevé). En projetant les modalités dans un sous-espace partagé, les conflits sont implicitement résolus.
- **Simplification pour le gaming** : Pour « Façade Fissurée », l'algorithme SLSMKCCA complet peut être computationnellement excessif. Cependant, une fusion pondérée plus simple au niveau décision peut suffire pour deux modalités (FER + HR), avec la compréhension théorique de cet article informant la sélection des poids.

G. Article 7 : Review on Multimodal Fusion Techniques for Emotion Recognition

1) *Données*: Karani et Desai [7] fournissent une revue détaillée des techniques de fusion multimodale pour la reconnaissance d'émotions. Cet article est essentiel pour « Façade Fissurée » car nous devons déterminer comment combiner la reconnaissance des expressions faciales avec les données de rythme cardiaque—deux modalités avec des caractéristiques temporelles et des modes de défaillance différents.

Ensembles de données utilisés pour la validation :

- **CMU-MOSI** : Ensemble Multimodal Opinion Sentiment Intensity avec annotations vidéo, audio et texte.
- **IEMOCAP** : Base Interactive Emotional Dyadic Motion Capture avec enregistrements audio-visuels de dialogues émotionnels joués.

2) *Méthodologie*: Trois principales stratégies de fusion sont analysées en détail :

Fusion au niveau des caractéristiques (fusion précoce) :

Les caractéristiques de toutes les modalités sont concaténées en un seul vecteur de haute dimension avant classification.

- **Concaténation** : Empilement simple de vecteurs de caractéristiques—rapide mais souffre de la malédiction de la dimensionnalité.
- **CCA** : Projette les caractéristiques dans un sous-espace partagé où les corrélations sont maximisées.

Exigence : Synchronisation temporelle stricte entre les modalités.

Fusion au niveau décision (fusion tardive) : Chaque modalité est traitée indépendamment, produisant des prédictions séparées qui sont ensuite combinées.

- **SVR** : Apprend la pondération optimale des sorties des classifieurs de base.
- **Blending** : Entraîne un méta-classifieur sur les prédictions des classifieurs de base.
- **Dempster-Shafer** : Combine les croyances probabilistes avec gestion de l'incertitude.
- **Basé sur règles** : Logique codée en dur pour la priorisation des modalités (par exemple, « si HR > 100 ET visage montre peur, alors haute confiance peur »).

Avantage : Ne nécessite pas de synchronisation ; chaque modalité opère indépendamment.

Fusion hybride : Combine fusion au niveau caractéristiques et au niveau décision basée sur les caractéristiques des modalités.

- Fusion au niveau caractéristiques pour les modalités étroitement synchronisées (par exemple, visage + audio de la même vidéo).
- Fusion au niveau décision pour les modalités asynchrones (par exemple, EEG, signaux physiologiques).
- Meilleur résultat rapporté : 66,67% sur CMU-MOSI avec approche hybride.

3) *Résultats clés*:

- **L'hybride surpasse les approches pures** : La flexibilité pour adapter la stratégie de fusion aux caractéristiques des modalités donne les meilleurs résultats.
- **Niveau décision plus robuste** : Quand une modalité échoue (par exemple, visage occlus), le système fonctionne encore sur les modalités restantes.
- **Niveau caractéristiques meilleur pour synchronisé** : Quand l'alignement temporel est garanti, la fusion précoce capture les interactions inter-modales.
- **Blending a atteint 81,36%** : Combiner les sorties CNN et SVM via méta-classifieur a démontré une forte performance pratique.

4) *Points forts*:

- Taxonomie complète distinguant clairement les approches de fusion avec avantages/inconvénients.
- Validation pratique à travers des comparaisons expérimentales sur des ensembles de données réels.
- Conseils de décision clairs pour choisir la stratégie de fusion basée sur les exigences de synchronisation et de tolérance aux pannes.

5) *Limitations*:

- Pas d'analyse temps réel/latence—n'aborde pas les exigences de gaming.
- Couvre principalement audio/visuel/texte ; discussion limitée des signaux physiologiques comme HR.
- Pas de contexte spécifique au gaming—les résultats peuvent ne pas se transférer directement aux applications d'horreur.

6) *Relation avec notre travail*: Cet article répond directement à **RQ6** (logique de fusion) et fournit des conseils architecturaux :

Architecture recommandée pour Façade Fissurée :

- **Fusion au niveau décision pour FER + rPPG** : Puisque FER et rythme cardiaque ont des résolutions temporelles différentes (FER : par frame, rPPG : fenêtres de 5 secondes), la fusion au niveau décision est plus appropriée.
- **Combinaison pondérée par confiance** : Pondérer les contributions par les scores de confiance de chaque modalité. Quand la confiance FER est faible (faible luminosité, occlusion), prioriser HR ; quand la confiance HR est faible (erreurs d'estimation HR élevé), prioriser FER.
- **Résolution de conflits** : Quand les modalités sont en désaccord (visage neutre + HR élevé, ou expression de peur + HR bas), appliquer la connaissance du domaine : dans les jeux d'horreur, par défaut interpréter vers « plus effrayé » sauf quand le pattern suggère une habitude.

Dégradation gracieuse :

- Visage non détecté → se fier à HR seul.
- Qualité du signal rPPG faible → se fier à FER seul.
- Les deux modalités disponibles → prédiction fusionnée avec pondération par confiance.

H. Article 8 : Robust Detection of Occluded Faces in Low-Light Using YOLO

1) *Données*: Alqahtani et al. [8] évaluent YOLOv6 et YOLOv7 pour détecter des visages partiellement occlus dans des scénarios de faible luminosité—conditions très pertinentes pour les environnements de jeux d'horreur où les joueurs peuvent couvrir leur visage en réaction aux frayeurs, et l'éclairage ambiant est délibérément sombre.

Ensemble de données original :

- 500 images de visages partiellement occlus
- Types d'occlusion : masques médicaux, casques, mains, lunettes de soleil, écharpes
- Diverses conditions de faible luminosité simulant un éclairage intérieur tamisé

Augmentation de données : Pour répondre à la taille limitée de l'ensemble, une augmentation extensive a été appliquée :

- Ajustement de luminosité : $\pm 30\%$ pour simuler une illumination variable
- Modification du contraste : $\pm 20\%$ pour la variation d'exposition
- Changements de netteté : Flou et netteté pour la variation de focus
- Retournement horizontal et rotation ($\pm 15^\circ$) pour la variation de pose

Après augmentation : 1100 images totales, divisées 80% entraînement / 10% validation / 10% test.

2) *Méthodologie*: YOLO (You Only Look Once) effectue la détection en une seule passe avant, le rendant bien adapté aux applications temps réel. Les auteurs comparent deux versions :

YOLOv6 : Conçu pour les applications industrielles avec focus sur la vitesse.

YOLOv7 : Introduit l'architecture E-ELAN (Extended Efficient Layer Aggregation Network) avec :

- Cardinalité étendue (voies parallèles) pour une représentation de caractéristiques plus riche
- Scaling de modèle composé optimisant profondeur, largeur et résolution conjointement
- Entraînement de tête auxiliaire avec perte guidée par tête principale pour un meilleur flux de gradient

Configuration d'entraînement : GPU Tesla T4, 150 époques, résolution d'entrée 640×640 , optimiseur SGD (momentum 0,937, weight decay 0,0005). Temps d'entraînement : YOLOv6 = 44 minutes, YOLOv7 = 2 heures 19 minutes.

TABLE I – Comparaison de YOLOv6 et YOLOv7 pour la détection de visages occlus

Modèle	Précision	Rappel	F1	mAP50
YOLOv6	0,90	0,79	0,845	0,886
YOLOv7	0,92	0,89	0,90	0,922

3) Résultats clés:

— **YOLOv7 surpasse YOLOv6** sur toutes les métriques, avec l'amélioration la plus significative sur le rappel (0,89 vs. 0,79)—critique pour s'assurer que les visages ne sont pas manqués.

— **L'architecture E-ELAN** fournit une extraction de caractéristiques supérieure, particulièrement pour les visages partiellement visibles où les détecteurs traditionnels échouent souvent.

— **Compromis vitesse-précision** : YOLOv7 nécessite 3× plus de temps d'entraînement mais maintient des vitesses d'inférence temps réel sur GPUs grand public.

4) Points forts:

- Adresse directement les scénarios de faible luminosité et d'occlusion partielle attendus dans le gaming d'horreur.
- Fournit des chiffres de performance concrets (0,92 précision, 0,89 rappel) pour planifier la fiabilité du système.
- Stratégies d'augmentation transférables peuvent être appliquées aux données d'entraînement personnalisées.
- Les deux modèles atteignent une inférence temps réel sur GPUs grand public, critique pour le gaming.

5) Limitations:

- Petit ensemble de données (1100 images après augmentation) peut ne pas capturer la pleine variabilité des occlusions réelles.
- Détection uniquement—l'article évalue la détection faciale, pas la reconnaissance d'expression. Les visages détectés nécessitent encore Py-Feat pour l'analyse d'émotion.
- Pas de mesures de latence d'inférence—bien que le temps d'entraînement soit rapporté, la vitesse d'inférence pour le gaming temps réel n'est pas explicitement mesurée.
- Images statiques uniquement—la cohérence temporelle dans la détection vidéo n'est pas évaluée.

6) *Relation avec notre travail*: Cet article répond directement à **RQ3** (effets faible luminosité/occlusion) et informe le pipeline de prétraitement :

Architecture de détection en deux étapes pour Façade Fissurée :

- **Étape 1 - YOLOv7** : Détection faciale robuste dans des conditions difficiles (0,89 rappel sur visages occlus en faible luminosité).
- **Étape 2 - Py-Feat** : Analyse d'expression sur les régions faciales détectées, recadrées et améliorées.

Cela répond à une limitation clé du détecteur RetinaFace de Py-Feat, qui peut avoir du mal sous l'éclairage des jeux d'horreur. Utiliser YOLOv7 comme première étape robuste permet :

- Des taux de détection élevés même quand les visages sont partiellement couverts (par exemple, mains couvrant la bouche de peur)
- Scores de confiance pour la qualité de détection faciale, informant les poids de fusion

I. Article 9 : Reliability of rPPG Under Low Illumination and Elevated HR

1) *Données*: Acharya et al. [9] abordent une lacune critique dans la recherche sur la photopléthysmographie à distance (rPPG) : l'absence d'évaluation systématique dans des conditions communes aux applications réelles mais sous-représentées dans les benchmarks existants. Spécifiquement, ils étudient la faible illumination et les rythmes cardiaques élevés—les deux très pertinents pour les applications de jeux d'horreur.

L'ensemble de données CHILL (Challenging Heart Rate and Illumination) :

- 45 participants (28 femmes, 17 hommes), âgés de 18 à 32 ans, types de peau Fitzpatrick I-III
- 180 enregistrements d'une minute (4 conditions par participant)
- Vidéo : 1920×1080 à 25 fps (DSLR Canon EOS 550D)
- Vérité terrain : Oxymètre de pouls digital Biosignalplus à 1000 Hz

Quatre conditions expérimentales :

- **Repos-Lumineux** : Éclairage normal, HR au repos (baseline)
- **Repos-Sombre** : Faible illumination, HR au repos
- **Élevé-Lumineux** : Éclairage normal, HR élevé (post-exercice)
- **Élevé-Sombre** : Faible illumination, HR élevé (le plus difficile)

Plage HR : 54-141 BPM (médiane 79,83 BPM), significativement plus élevée que COHFACE (68,85) et PURE (67,68).

2) *Méthodologie*: Huit méthodes rPPG représentant à la fois le traitement du signal classique et les approches d'apprentissage profond ont été évaluées :

Méthodes de traitement du signal :

- **GREEN** : Utilise directement le canal vert, exploitant l'absorption de l'hémoglobine
- **CHROM** : Méthode basée sur la chrominance éliminant les réflexions spéculaires via différences de canaux
- **POS** : Méthode Plane-Orthogonal-to-Skin projetant la lumière sur un plan orthogonal au teint de peau
- **ICA** : Analyse en Composantes Indépendantes pour la séparation aveugle des sources

Méthodes d'apprentissage profond :

- **DeepPhys** : Architecture à double branche (voies mouvement + apparence)
- **TS-CAN** : Convolutions à décalage temporel pour une modélisation temporelle efficace
- **PhysNet** : 3D-CNN pour l'extraction de caractéristiques spatio-temporelles
- **rPPGNet** : Module d'attention de détection de peau pour les régions pertinentes

Protocole d'évaluation :

- Intra-ensemble : Validation croisée 10-fold avec divisions par participant
- Inter-ensemble : Entraînement sur PURE/COHFACE, test sur CHILL pour évaluer la généralisation

3) Résultats clés:

- **Le traitement du signal surpasse le DL sur CHILL** : POS a atteint le MAE le plus bas (1,1 BPM), CHROM 1,8 BPM. Contre-intuitif mais pratiquement important—les méthodes plus simples sont plus robustes.
- **Impact de la faible illumination plus faible que prévu** : L'obscurité seule n'a pas catastrophiquement altéré la performance. La dégradation n'était pas statistiquement significative pour la plupart des méthodes.
- **Le HR élevé est le défi critique** : 5/8 méthodes ont montré une baisse statistiquement significative à HR élevé (Wilcoxon $p < 0,05$).
- **Échec de généralisation** : Les modèles DL atteignant <3 BPM MAE sur PURE ont montré >10 BPM MAE sur CHILL, démontrant un « surapprentissage aux benchmarks ».

4) Points forts:

- Nouvel ensemble de données comblant une lacune critique dans les benchmarks rPPG avec variation systématique des conditions.
- Méthodologie rigoureuse avec divisions par participant empêchant les fuites de données.
- Recommandation actionnable : utiliser le traitement du signal pour les conditions difficiles.
- Conditions directement pertinentes (faible luminosité + HR élevé) pour le gaming d'horreur.

5) Limitations:

- Qualité de caméra : DSLR à 1080p/25fps peut ne pas correspondre à la qualité webcam typique (720p, compression variable).
- Le HR induit par l'exercice peut différer de l'élévation induite par la peur.
- Sujets statiques : Participants assis et immobiles ; les contextes de gaming peuvent impliquer des mouvements de tête.

6) *Relation avec notre travail*: Cet article est essentiel pour les décisions d'architecture de « Façade Fissurée » :

RQ3, RQ4, RQ5 : La faible luminosité seule n'altère pas catastrophiquement le rPPG. POS atteint 1,1 BPM MAE, cliniquement acceptable et comparable aux wearables grand public. Cela supporte la faisabilité de détection HR par webcam seule.

Implication design critique : La dégradation à HR élevé est paradoxalement préoccupante pour les jeux d'horreur, où le HR élevé est exactement ce que nous voulons détecter avec précision. Cela motive fortement la fusion multimodale (**RQ6**) : quand la confiance rPPG baisse à HR élevé, pondérer plus fortement les données FER. La logique de fusion devrait inclure :

- Scoring de confiance basé sur des métriques de qualité du signal
- Validation croisée : si FER détecte la peur mais rPPG rapporte un HR bas, faire confiance à FER

Sélection d'algorithme : Nous implémenterons POS ou CHROM plutôt que les méthodes d'apprentissage profond, basé sur les preuves que le traitement du signal est plus robuste dans des conditions difficiles.

J. Article 10 : Federated Learning for Privacy-Preserving Emotion Detection

1) **Données:** Gutiérrez et al. [10] explorent l'apprentissage fédéré comme mécanisme pour entraîner des modèles de détection d'émotions sans centraliser les données vidéo faciales sensibles. Bien qu'appliqué aux environnements éducatifs, cet article aborde une préoccupation critique pour « Façade Fissurée » : la confidentialité des joueurs lors de l'analyse de données biométriques.

Déploiement :

- 150 étudiants et 20 enseignants de la Faculté des Technologies
- Appareils personnels : smartphones, tablettes, ordinateurs portables avec caméras intégrées

Les auteurs soutiennent que la détection d'émotions traditionnelle basée sur le cloud soulève des préoccupations significatives de confidentialité : les images faciales et les données comportementales peuvent révéler des informations sensibles sur les états mentaux des utilisateurs.

2) **Méthodologie:** L'article implémente l'apprentissage fédéré utilisant l'algorithme FedAvg (Federated Averaging) :

Principe central : Au lieu de centraliser les données d'entraînement, chaque appareil s'entraîne localement sur ses propres données. Seules les mises à jour de modèle sont partagées avec un serveur central.

Étapes de l'architecture :

- 1) **Entraînement local :** Chaque appareil s'entraîne sur les données d'émotion capturées localement
- 2) **Extraction de mise à jour de modèle :** Différence entre poids du modèle local et global calculée
- 3) **Agrégation sécurisée :** Mises à jour chiffrées (AES-256) avant transmission
- 4) **Agrégation serveur :** Le serveur fait la moyenne des mises à jour reçues pour produire un modèle global amélioré
- 5) **Distribution du modèle :** Modèle global mis à jour renvoyé à tous les clients

Support multimodal :

- Images faciales : Classifieurs CNN entraînés sur FER2013/AffectNet
- Voix : Caractéristiques prosodiques/spectrales utilisant RAVDESS/IEMOCAP
- Texte : Modèles transformer utilisant GoEmotions

3) Résultats clés:

- **Précision maintenue :** Les modèles fédérés ont atteint 87% de précision, 85% de rappel, 86% F1—comparable aux approches d'entraînement centralisé.
- **Robustesse faible luminosité :** Le modèle fédéré a maintenu 80% de précision en faible luminosité vs. 75% pour le centralisé, possiblement dû à l'entraînement sur des données réelles plus diverses.
- **Confidentialité préservée :** Les données biométriques brutes sont restées sur les appareils ; seules les mises à jour de gradient chiffrées ont été transmises.

4) Points forts:

- Conception confidentialité-d'abord abordant les préoccupations fondamentales sur la collecte de données biométriques.
- Validation réelle avec 170 utilisateurs réels démontrant la faisabilité pratique.
- Architecture scalable accommodant de nombreux utilisateurs sans stockage serveur proportionnel.
- Conformité réglementaire : La conception s'aligne avec le RGPD et réglementations similaires de confidentialité.
- Support multimodal : Le cadre gère la combinaison de plusieurs modalités.

5) Limitations:

- Le contexte éducatif diffère du gaming en motivation utilisateur, durée de session et gamme émotionnelle.
- Exigences de edge computing : Les appareils doivent avoir une puissance de calcul suffisante pour l'entraînement local.
- Overhead de communication : L'apprentissage fédéré nécessite plusieurs tours de mises à jour de modèle.
- Compromis de personnalisation : Les modèles globaux agrégés peuvent ne pas capturer les caractéristiques individuelles aussi bien que les modèles locaux.

6) **Relation avec notre travail:** Cet article aborde une préoccupation implicite mais importante pour « Façade Fissurée » : la confidentialité des joueurs.

Préoccupation de confidentialité : Les joueurs peuvent être réticents à avoir leurs expressions faciales et réponses physiologiques analysées, surtout pour un jeu détectant la peur—un état émotionnel vulnérable. Toute perception que les données sont transmises à l'extérieur pourrait nuire à l'adoption et à la confiance des joueurs.

Implémentation immédiate (portée de la thèse) : Pour la thèse, l'apprentissage fédéré complet est hors portée. Cependant, l'article informe les décisions d'architecture critiques :

- Tout traitement biométrique se produit localement via le pont Python ↔ Unity
- Aucune donnée vidéo brute transmise sur le réseau
- Les prédictions d'émotion et l'adaptation du jeu se produisent entièrement sur la machine du joueur

Amélioration future : Pour une version commerciale, l'apprentissage fédéré pourrait permettre :

- Des modèles améliorés entraînés sur de nombreux joueurs sans centraliser les données
- Calibration personnalisée s'adaptant à l'expressivité individuelle et au HR baseline
- Réglage à l'échelle de la communauté des paramètres DDA basé sur les patterns agrégés de réponse à la peur

III. ANALYSE COMPARATIVE

Le Tableau II présente une comparaison complète des dix articles examinés, analysant chacun selon six dimensions : sources de données, méthodologie, résultats clés, points forts, limitations et relation avec notre travail. Ce tableau synthétise les analyses détaillées présentées dans la Section II.

A. Synthèse des Résultats

À travers les dix articles examinés, plusieurs thèmes cohérents émergent qui informent directement la conception et l'implémentation de « Façade Fissurée ». Cette section synthétise les résultats par question de recherche, établissant des connexions entre les articles.

1) *RQ1 : Comment combiner FER et rPPG pour la détection d'émotions en temps réel?*: Aucun article examiné ne combine directement la reconnaissance des expressions faciales avec la photopléthysmographie à distance pour les applications de gaming, confirmant que « Façade Fissurée » aborde une véritable lacune dans la littérature. Cependant, les composants existent :

- **Py-Feat** fournit un pipeline FER mature et modulaire avec classification d'émotions (0,55 F1) et détection d'UA.
- **CHILL** évalue les méthodes rPPG dans des conditions difficiles, recommandant les approches de traitement du signal (POS : 1,1 BPM MAE).
- **Karani & Desai** et **Yan et al.** fournissent des cadres de fusion applicables à la combinaison de ces modalités.

2) *RQ2 : Quels mécanismes DDA sont les plus efficaces pour les jeux d'horreur?*: Deux articles abordent directement le DDA biofeedback dans les jeux :

- **Caroline** démontre que les mécanismes « Relax-to-Win » (la difficulté augmente avec HR élevé) améliorent la motivation intrinsèque sans augmenter la tension perçue.
- **Keep Calm Flappy** montre que le gameplay guidé par objectif avec adaptation HR produit les meilleurs résultats affectifs.

3) *RQ3 : Comment la faible luminosité et l'occlusion affectent-elles la précision de détection?*: Trois articles fournissent des preuves critiques :

- Les expériences de robustesse de **Py-Feat** montrent que la détection faciale et d'émotions se dégrade sous luminosité réduite.
- **YOLOv7** atteint 0,92 précision et 0,89 rappel sur visages occlus en faible luminosité.
- **CHILL** trouve de manière surprenante que la faible illumination a un impact comparativement plus petit sur rPPG que le rythme cardiaque élevé.

4) *RQ4 : La détection par webcam seule peut-elle égaler la précision des wearables?*: La littérature suggère un optimisme prudent :

- **POS rPPG** atteint 1,1 BPM MAE sur CHILL, comparable à la précision des wearables grand public.
- Cependant, la précision rPPG se dégrade à rythmes cardiaques élevés—précisément quand nous avons le plus besoin d'une détection HR précise dans les jeux d'horreur.

5) *RQ5 : Quelle est l'efficacité de Py-Feat dans les environnements de jeu sombres?*: Les expériences de robustesse de Py-Feat abordent directement ceci :

- La détection faciale (RetinaFace) reste relativement robuste aux changements modérés de luminosité.
- La détection de points de repère se dégrade progressivement avec l'illumination réduite.
- La détection d'UA et d'émotions montre les baisses de performance les plus significatives en faible luminosité.
- La détection de peur spécifiquement semble avoir une précision plus faible que la joie, aggravée par la confusion avec la surprise.

6) *RQ6 : Quelle logique de fusion devrait prioriser quand les modalités sont en conflit?*: La littérature sur la fusion fournit des conseils clairs :

- La **fusion au niveau décision** est plus robuste que le niveau caractéristiques quand les modalités ont des résolutions temporelles ou modes de défaillance différents.
- La **fusion hybride** surpasse les approches pures, suggérant des stratégies de fusion adaptatives.
- L'algorithme **SLSMKCCA** démontre que des solutions rigoureuses existent pour résoudre les conflits de modalités.

7) *RQ7 : Quel seuil de latence est requis pour l'immersion?*: Aucun article ne quantifie explicitement les seuils de latence, mais les preuves indirectes suggèrent :

- Le système **Caroline** a atteint une adaptation temps réel avec communication série Arduino, typiquement <100ms de latence.
- La **comparaison ML-FER** montre que les modèles d'attention légers peuvent atteindre une précision compétitive avec une inférence plus rapide.

B. Lacunes de la Littérature Adressées par ce Projet

La littérature examinée révèle quatre lacunes clés que « Façade Fissurée » adresse :

- 1) **Pas d'implémentations gaming multimodales (FER + rPPG)**—les jeux biofeedback existants utilisent HR seul.
- 2) **Éclairage spécifique à l'horreur sous-exploré**—la plupart des benchmarks FER utilisent des conditions bien éclairées.
- 3) **Seuils de latence non quantifiés**—pas de seuil établi de rupture d'immersion.
- 4) **Logique de fusion pour modalités en conflit non définie**—les scénarios « Fake Out » manquent de solutions.

TABLE II – Analyse Comparative de la Littérature

Article	Données	Méthode	Résultats	Forces	Limites	Relation avec notre travail
Py-Feat	WIDER FACE, 300W, DISFA+, AffectNet	HOG+SVM/XGB pour UA ; ResMaskNet pour émotion	F1=0,55 moy ; dégrade dans l'obscurité ; confusion peur/surprise	Open-source ; modulaire ; GPU	F1 peut bas ; pas temporel	Outil FER central ; fournit pipeline FER pour Façade Fissurée
FER Survey	21 ensembles (CK+ à AffectNet)	Taxonomie : traditionnel à transformers ; 60 méthodes	DL surpasse ML ; illumination défi clé	Complet ; taxonomie claire	Largeur de survey	Fondement théorique ; confirme défi faible luminosité
ML-FER Comp.	AffectNet, FER2013, RAF-DB	12 algorithmes ; comparaison équitable	Poster 75,98% ; HOG-SVM 50,12%	Première comparaison équitable 12 méthodes	Image seul	Sélection algorithme ; valide choix DL
Keep Calm	25 participants ; Pixel Watch	Flappy Bird HR-adaptatif ; PANAS, PXI	AP↑ en L3 ; AN↓	Matériel accessible	Petit n=25	Design DDA ; objectif + adaptatif optimal
Caroline	42 joueurs ; Arduino clip	DDA Relax-to-Win ; IMI, CORGIS	Motivation↑ ; défi↓	Bas coût ; formules concrètes	HR seul ; intrusif	Référence centrale ; formules adaptées
SLSMKCCA	GEMEP, Polish DB	Fusion kernel CCA (visage, parole, geste)	Trimodal > unimodal	Rigueur math.	Computational	Théorie fusion ; résolution conflits
Fusion Review	CMU-MOSI, IEMOCAP	Fusion caractéristiques, décision, hybride	Hybride meilleur (66,67%)	Taxonomie claire	Pas physiologique	Architecture fusion ; niveau décision recommandé
YOLO Occlusion	1100 images faible lum.	YOLOv6 vs YOLOv7 ; E-ELAN	YOLOv7 : 0,92P, 0,89R	Pertinent horreur	Détection seul	Prétraitement ; YOLOv7 détecteur robuste
rPPG CHILL	45 participants ; 4 conditions	8 méthodes rPPG ; POS, CHROM, etc.	POS 1,1 BPM MAE ; traitement signal > DL	Novel dataset ; stats rigoureuses	HR exercice	Détection HR ; méthode POS choisie
Federated	150 étudiants ; Moodle	FedAvg ; AES-256	87% précision ; confid. préservée	Confidentialité d'abord	Pas gaming	Design confidentialité ; traitement local

IV. CONCLUSION

Cette revue de littérature a examiné dix articles couvrant la reconnaissance des expressions faciales, la photopléthysmographie à distance, le gaming biofeedback, la fusion multimodale et l'apprentissage machine préservant la confidentialité. La combinaison spécifique requise pour « Façade Fissurée »—adaptation biofeedback multimodale pour survival horror en faible luminosité—reste inexplorée, positionnant ce projet pour apporter une contribution nouvelle.

A. Points Techniques Clés

- 1) **FER** : Py-Feat fournit FER modulaire (0,55 F1) ; YOLOv7 permet une détection faciale robuste (0,92P/0,89R) en faible luminosité.
- 2) **rPPG** : Le traitement du signal POS/CHROM atteint 1,1 BPM MAE ; le HR élevé dégrade paradoxalement la précision.
- 3) **DDA** : « Relax-to-Win » + gameplay guidé par objectif produit les meilleurs résultats affectifs ; les formules Caroline fournissent un point de départ.

- 4) **Fusion** : Fusion au niveau décision recommandée ; combinaison pondérée par confiance avec règles de résolution de conflits.
- 5) **Confidentialité** : Traitement local via pont Python↔Unity ; aucune vidéo faciale transmise à l'extérieur.
- 6) **Latence** : Cible <100ms bout-en-bout ; mesure empirique requise pendant le développement.

B. Remarques Finales

Les dix articles établissent collectivement que l'informatique affective a suffisamment mûri pour le gaming temps réel, bien que des défis demeurent en faible luminosité et états physiologiques élevés. « Façade Fissurée » occupe une position nouvelle à l'intersection de la FER, du rPPG et du game design d'horreur—une combinaison non abordée par aucun article examiné. En implémentant les recommandations synthétisées, le projet vise à démontrer que l'état émotionnel authentique d'un joueur peut piloter l'adaptation du jeu pour améliorer à la fois l'immersion et l'engagement.

RÉFÉRENCES

- [1] J. H. Cheong, E. Jolly, T. Xie, S. Byrne, M. Kenney, and L. J. Chang, "Py-feat : Python facial expression analysis toolbox," *Affective Science*, vol. 4, pp. 781–796, 2023.
- [2] T. Kopalidis, V. Solachidis, N. Vretos, and P. Daras, "Advances in facial expression recognition : A survey of methods, benchmarks, models, and datasets," *Information*, vol. 15, no. 3, p. 135, 2024.
- [3] Y. Li, Z. Zhou, Q. Feng, and H. Li, "Analysis and comparison of machine learning-based facial expression recognition algorithms," *Algorithms*, vol. 18, no. 12, p. 800, 2025.
- [4] M. M. Hossan, R. A. Tasnim, and F. Z. Eishita, "Can you keep calm ? : Adaptive gameplay using heart rate as a controller," in *2025 Intermountain Engineering, Technology and Computing (IETC)*. IEEE, 2025, preprint/Conference Paper.
- [5] P. Moschovitis and A. Denisova, "Keep calm and aim for the head : Biofeedback-controlled dynamic difficulty adjustment in a horror game," *IEEE Transactions on Games*, 2022.
- [6] J. Yan, P. Li, C. Du, K. Zhu, X. Zhou, Y. Liu, and J. Wei, "Multimodal emotion recognition based on facial expressions, speech, and body gestures," *Electronics*, vol. 13, no. 18, p. 3756, 2024.
- [7] R. Karani and S. Desai, "Review on multimodal fusion techniques for human emotion recognition," *International Journal of Advanced Computer Science and Applications (IJACSA)*, vol. 13, no. 10, 2022.
- [8] N. Alqahtani, A. Shaikh, and I. K. Keerio, "Robust detection of partially occluded faces in low-light scenarios using yolov7 and yolov6," *International Journal of Advanced Computer Science and Applications (IJACSA)*, vol. 16, no. 11, 2025.
- [9] B. Acharya, W. Saakyan, B. Hammer, and H. Drimalla, "The reliability of remote photoplethysmography under low illumination and elevated heart rates," *npj Digital Medicine*, 2025.
- [10] R. Gutiérrez, W. Villegas-Ch, and S. Luján-Mora, "Implementing federated learning for privacy-preserving emotion detection in educational environments," *Frontiers in Artificial Intelligence*, vol. 8, p. 1644844, 2025.